Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЁТ
Задание №1

Дисциплина: 《Эргатические системы》

Студент Чэнь Цзяхэ
фамилия, имя, отчество

Группа ИУ1И-41М

Преподаватель 01/04/2026 А.С. Кучин
(Подпись, дата) (И.О. Фамили

2026

Цель задания

Освоить базовые понятия машинного обучения и настроить полноценный пайплайн работы с Git. Ключевые навыки — это генерация случайной выборки и борьба с переобучением с помощью регуляризации и других методов, что позволяет на практике повысить обобщающую способность модели и эффективность управления версиями.

Ссылка на Git-репозиторий:
https://github.com/bowewe17/MachineLearning_Labs/blob/main/lab1.ipynb

1. **В чем состоит основная проблема переобучения?**

   Переобучение — это ситуация, когда модель слишком точно подстраивается под обучающие данные, запоминая их шум и выбросы, а не обобщая закономерности. В результате модель отлично работает на обучающей выборке, но показывает низкое качество на новых, невидимых данных.

2. **Почему мы не можем оценивать качество модели на тех данных, на которых она обучалась?**

   Оценка на обучающих данных даёт смещённую (оптимистичную) оценку качества, поскольку модель уже «видела» эти примеры и могла подстроиться под них. Чтобы объективно оценить способность модели к обобщению, необходимо использовать отдельную выборку, не участвовавшую в обучении (валидационную или тестовую).

3. **Что такое регуляризация и как она помогает бороться со сложностью модели?**

   Регуляризация — это набор методов, которые вводят дополнительные ограничения или штрафы в процессе обучения, чтобы уменьшить сложность модели. Она помогает бороться с переобучением, ограничивая величину параметров (например, L1 и L2 регуляризация) или добавляя шум, что не позволяет модели чрезмерно подстраиваться под обучающие данные и способствует лучшему обобщению.

Результаты

Шаг 1. Загрузка набора данных и визуализация результатов анализа (Pairplot)

Использовать Seaborn для загрузки набора данных Iris и построения графика распределения его характеристик.

Анализ диаграммы рассеяния показал:

1. Сорт *Setosa* продемонстрировал явное группирование по всем характерным комбинациям и полностью отделился от двух других сортов.
2. *Petal Length* (длина лепестка) и *Petal Width* (ширина лепестка) являются ключевыми показателями для различения сортов.
3. У сортов *Versicolor* и *Virginica* наблюдаются некоторые сходства в признаках чашелистиков, но их можно различить по линейным границам в признаках лепестков.

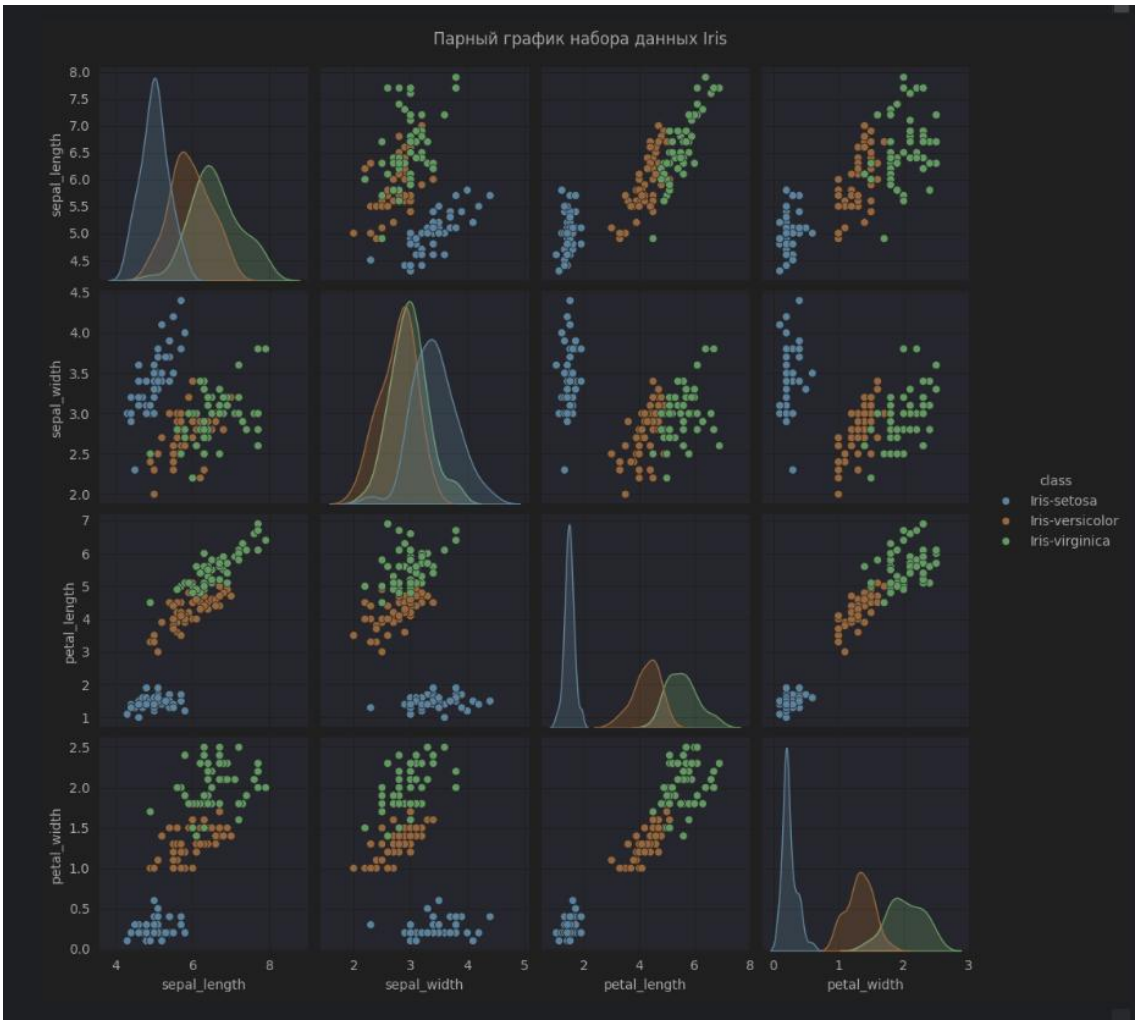

Шаг 2. Построение модели бинарной классификации на основе логистической регрессии

В этом разделе была произведена фильтрация данных с сохранением только двух разновидностей для обучения бинарной классификации.

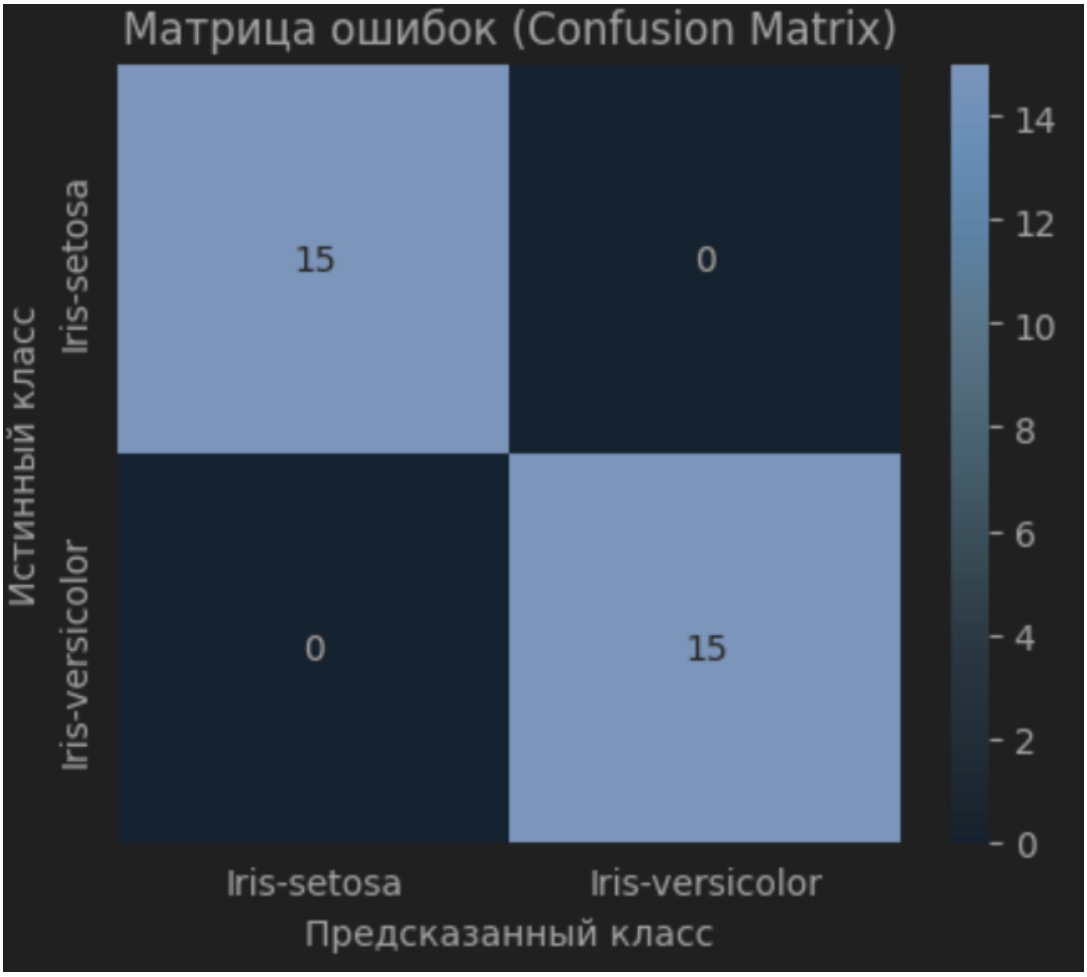

Шаг 3. Демонстрация переобучения в линейной регрессии

Путем добавления шума к синусоидальной функции для генерации данных, а затем аппроксимации данных полиномами разных порядков, демонстрируются различия между недообучением, нормальным обучением и переобучением.

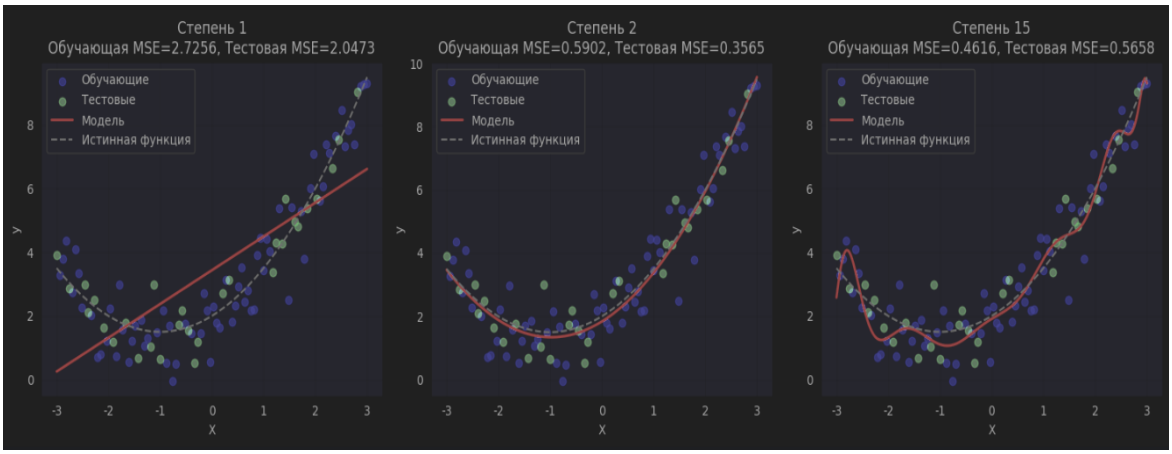

Шаг 4. Влияние регуляризации на модель

Для борьбы с переобучением были использованы методы Ridge (L2) и Lasso (L1). Влияние параметра alpha на модель было оценено с использованием разных значений alpha.

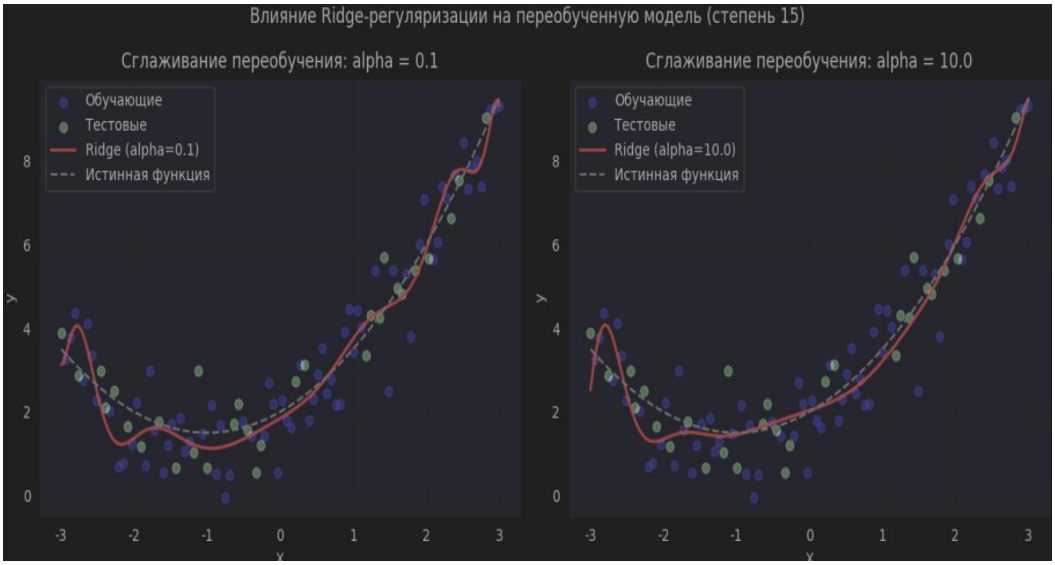

Модели машинного обучения, такие как линейная регрессия, сильно зависят от выбора степени сложности модели. Мы наблюдали, как регуляризация помогает предотвратить переобучение, а правильный выбор признаков способствует лучшему обобщению. Эти методы крайне важны для построения эффективных и обобщающих моделей.