



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

Информатика и системы управления

КАФЕДРА

Системы автоматического управления

ОТЧЁТ
Задание №1

Дисциплина: «Эргатические системы»

Студент ИУ1И-41М

Дун Боян

преподаватель

А. С. Кучин

2026 г.

1. Цель работы

Целью лабораторной работы является освоение базовых понятий машинного обучения и настройка простого рабочего пайплайна эксперимента. В ходе работы необходимо выполнить загрузку набора данных Iris, провести визуальный анализ признаков, обучить модель LogisticRegression для бинарной классификации, а также показать явление переобучения на примере линейной регрессии с полиномиальными признаками.

2. Анализ требований задания

Требование задания	Как реализовано в предоставленном коде	Комментарий
Загрузить набор данных Iris с UCI	Используется <code>sklearn.datasets.load_iris()</code>	Набор данных соответствует классическому Iris. Для строгого соответствия можно дополнительно указать или реализовать загрузку по ссылке UCI.
Построить pairplot для визуального анализа	Используется <code>seaborn.pairplot(df, hue="class")</code>	Требование выполнено. График показывает распределение и взаимосвязи признаков по классам.
Построить LogisticRegression для бинарной классификации	Выбраны классы versicolor и virginica; выполнено <code>train_test_split</code> и обучение LogisticRegression	Требование выполнено. Для оценки используются accuracy, confusion matrix и classification report.
Показать переобучение на примере линейной регрессии	Сгенерированы данные $y = \sin(x) + \text{шум}$; применена LinearRegression с PolynomialFeatures степеней 1, 4 и 15	Требование выполнено. Degree=1 демонстрирует недообучение, degree=15 - переобучение.
Настроить пайплайн работы с Git	В коде Git-команды не представлены	Это организационная часть задания. Ее можно оформить через <code>git init</code> , <code>git add</code> , <code>git commit</code> и хранение notebook в репозитории.

3. Используемые инструменты

В работе применялись следующие библиотеки Python: NumPy и Pandas для обработки данных, Seaborn и Matplotlib для визуализации, Scikit-learn для загрузки данных, разделения выборки, обучения моделей и расчета метрик. В качестве моделей использовались LogisticRegression и LinearRegression. Для демонстрации влияния сложности модели применялись PolynomialFeatures и Pipeline.

4. Ход выполнения работы

4.1. Загрузка и первичный анализ Iris

Набор Iris содержит 150 объектов и 4 числовых признака: sepal length, sepal width, petal length и petal width. В коде дополнительно создан столбец class, поэтому итоговая таблица имеет размер 150 x 5. Все три класса представлены равномерно: setosa - 50 объектов, versicolor - 50 объектов, virginica - 50 объектов.

4.2. Визуальный анализ с помощью pairplot

Для визуальной оценки структуры данных построена матрица парных графиков. По графику видно, что класс setosa хорошо отделяется от двух остальных классов, особенно по признакам, связанным с длиной и шириной лепестка. Классы versicolor и virginica частично пересекаются, поэтому они лучше подходят для демонстрации бинарной классификации с ненулевым числом ошибок.




Рисунок 1 - Pairplot набора данных Iris

4.3. Бинарная классификация LogisticRegression

Для бинарной классификации были выбраны два наиболее близких класса: *versicolor* и *virginica*. Целевая переменная была закодирована следующим образом: *versicolor* = 0, *virginica* = 1. Данные разделены на обучающую и тестовую выборки в соотношении 80/20 с параметром *stratify*, что сохраняет баланс классов.

Показатель	Значение
Размер обучающей выборки	80
Размер тестовой выборки	20
Ассурасу	0.90
Матрица ошибок	[[10, 0], [2, 8]]
Macro avg F1-score	0.899

Полученная точность классификации составила 0.90. Матрица ошибок показывает, что все объекты класса *versicolor* были классифицированы правильно, а у класса *virginica* две записи были ошибочно отнесены к *versicolor*.




Рисунок 2 - Матрица ошибок модели LogisticRegression

4.4. Демонстрация недообучения и переобучения

Для регрессионного эксперимента в коде сгенерирована синусоидальная зависимость с добавлением случайного шума. На этих данных обучались полиномиальные модели разной сложности. Степень 1 соответствует слишком простой модели и приводит к недообучению. Степень 4 описывает зависимость достаточно хорошо. Степень 15 слишком гибкая: она лучше подстраивается под обучающие точки, но хуже обобщает результат на тестовую выборку.

Тип модели	Степень	Train MSE	Test MSE	Train R2	Test R2
Недообучение	1	0.2300	0.2799	0.5270	0.4300
Подходящая модель	4	0.0494	0.0522	0.8984	0.8937
Переобучение	15	0.0305	0.1834	0.9373	0.6266

По результатам видно, что при степени 15 ошибка на обучающей выборке минимальна среди трех выбранных моделей, однако тестовая ошибка заметно возрастает. Это является признаком переобучения. В данном запуске минимальная тестовая MSE по диапазону степеней 1-19 была получена при степени 3; при этом степень 4 остается наглядным примером сбалансированной модели.




Рисунок 3 - Сравнение моделей разной сложности




Рисунок 4 - Зависимость ошибки от степени полинома

5. Выводы

- В ходе работы были освоены базовые этапы машинного обучения: загрузка данных, визуальный анализ, разделение выборки, обучение модели и оценка качества.
- Pairplot показал, что признаки лепестков хорошо разделяют класс *setosa*, тогда как *versicolor* и *virginica* имеют частичное пересечение.
- Модель LogisticRegression для классов *versicolor* и *virginica* достигла $\text{accuracy} = 0.90$ на тестовой выборке.
- Регрессионный эксперимент подтвердил влияние сложности модели: простая линейная модель недообучается, а полином высокой степени переобучается.