**Министерство науки и высшего образования Российской Федерации**
**Федеральное государственное бюджетное образовательное учреждение высшего образования**
**«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»**
**(МГТУ им. Н.Э. Баумана)**

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

# ОТЧЁТ
# Задание №1

**Дисциплина:** 《Эргатические системы》

Студент Гэ Сюй
фамилия, имя, отчество

Группа ИУ1И-41М

Преподаватель 01/04/2026 А.С. Кучин
(Подпись, дата) (И.О. Фамили

*2026 2.*

**Цель задания:**

Освоить базовые понятия машинного обучения и настроить полноценный пайплайн работы с Git. Ключевые навыки— это генерация случайной выборки и борьба с переобучением с помощью регуляризации и других методов, что позволяет на практике повысить обобщающую способность модели и эффективность управления версиями.

**Ссылка на Git-репозиторий:**

https://github.com/bowewe17/MachineLearning_Labs/blob/main/lab1.ipynb

**Ответы на вопросы:**

1. В чем состоит основная проблема переобучения?

Переобучение — это ситуация, когда модель слишком точно подстраивается под обучающие данные, запоминая их шум и выбросы, а не обобщая закономерности. В результате модель отлично работает на обучающей выборке, но показывает низкое качество на новых, невидимых данных.

2. Почему мы не можем оценивать качество модели на тех данных, на которых она обучалась?

Оценка на обучающих данных даёт смещённую (оптимистичную) оценку качества, поскольку модель уже «видела» эти примеры и могла подстроиться под них. Чтобы объективно оценить способность модели к обобщению, необходимо использовать отдельную выборку, не участвовавшую в обучении (валидационную или тестовую).

3. Что такое регуляризация и как она помогает бороться со сложностью модели?

Регуляризация — это набор методов, которые вводят дополнительные ограничения или штрафы в процессе обучения, чтобы уменьшить сложность модели. Она помогает бороться с переобучением, ограничивая величину параметров (например, L1 и L2 регуляризация) или добавляя шум, что не позволяет модели чрезмерно подстраиваться под обучающие данные и способствует лучшему обобщению.

# Результаты

**Шаг 1:**

**Загрузка набора данных и визуализация результатов анализа (Pairplot).**

Использовать Seaborn для загрузки набора данных Iris и построения графика распределения его характеристик, чтобы наблюдать различия между разными сортами.

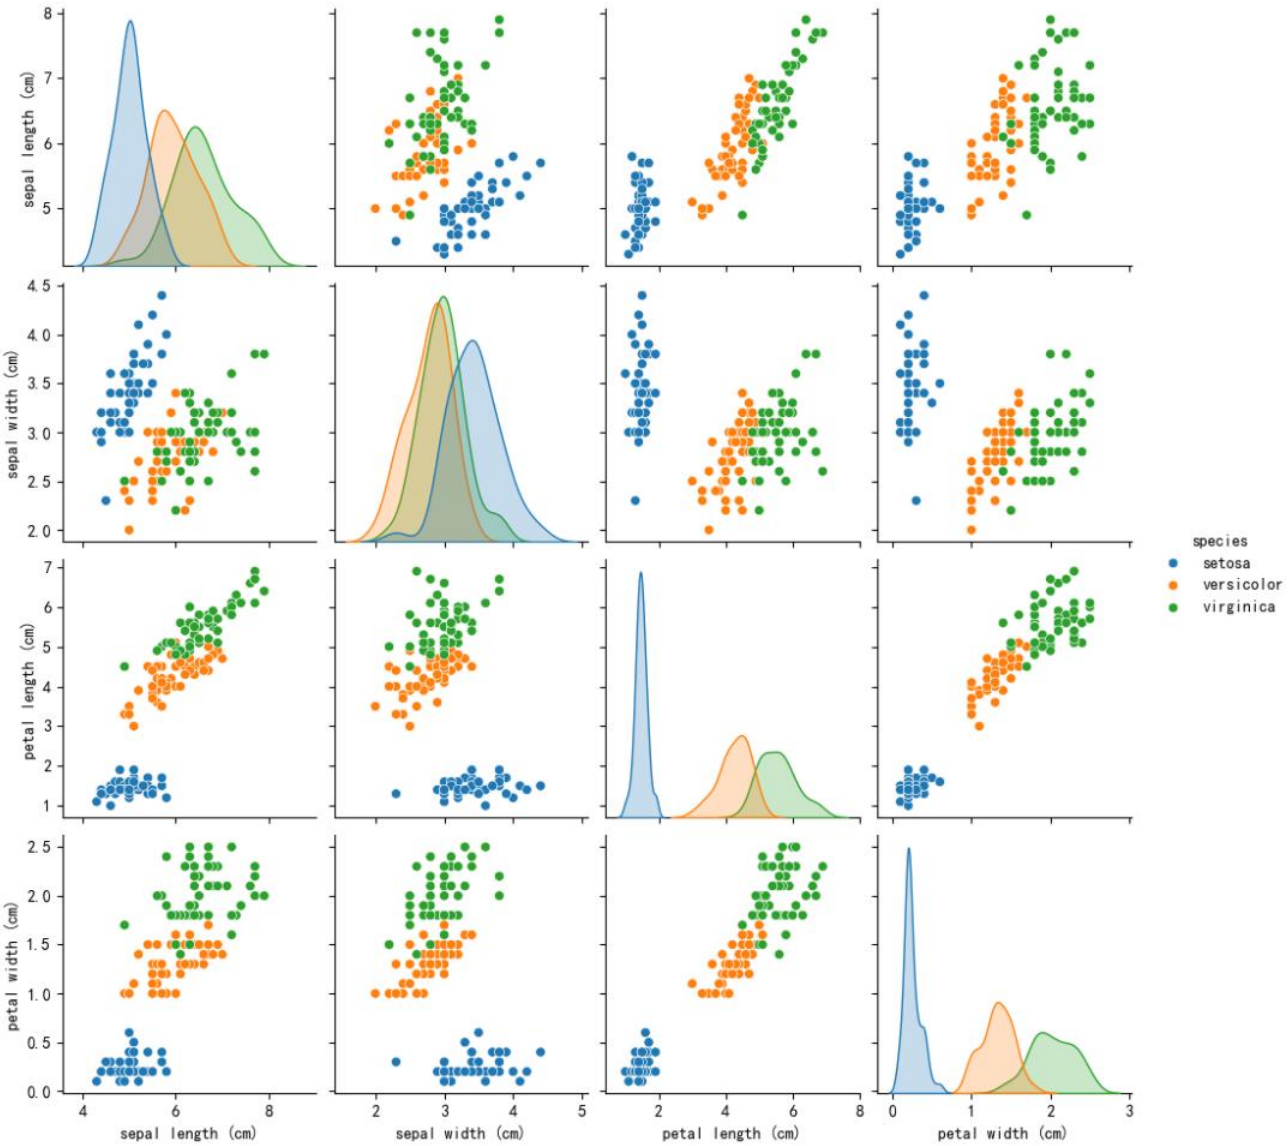


1. Анализ диаграммы рассеяния показал, что сорт 《 Setosa 》 продемонстрировал явное группирование по всем характерным комбинациям и полностью отделился от двух других сортов.

2. 《Petal Length》(длина лепестка) и 《Petal Width》(ширина лепестка) являются ключевыми показателями для различения сортов.

3. У сортов《Versicolor》и《Virginica》наблюдаются некоторые сходства в признаках чашелистиков, но их можно приблизительно различить по линейным границам в признаках лепестков.

**Шаг 2:**

**Построение модели бинарной классификации на основе логистической регрессии.**

В этом разделе будет произведена фильтрация данных с сохранением только двух разновидностей для обучения бинарной классификации, а также будет оценена точность модели.

```
【Оценка модели】
Столбцы признаков, используемые для обучения: ['sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)']
Точность бинарной классификации при логистической регрессии: 100.00%
Прогнозируемые значения первых 5 тестовых образцов: [1 1 1 0 0]
Истинные значения первых 5 тестовых образцов: [1 1 1 0 0]
```

**Шаг 3:**

**Демонстрация переобучения в линейной регрессии.**

Путем добавления шума к синусоидальной функции для генерации данных, а затем аппроксимации данных полиномами разных порядков, демонстрируются различия между **недообучение**, **нормальное обучение** и **переобучение**.

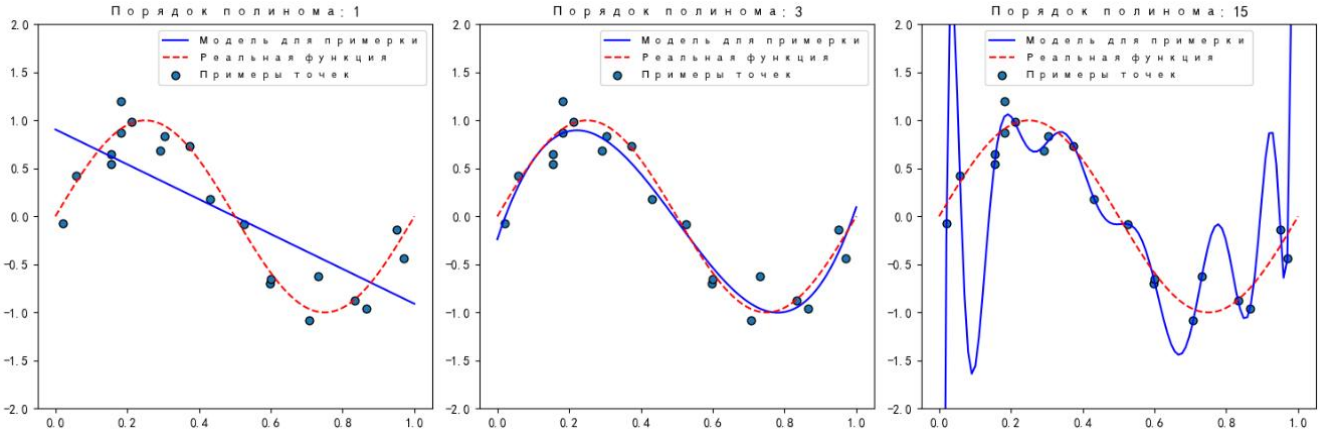


## Выходы

**1. Значимость признаков и линейная разделимость**

Проведенный разведочный анализ данных  датасета Iris подтвердил, что признаки лепестков (Petal Length/Width) обладают чрезвычайно высокой дискриминационной способностью. Матрица диаграмм рассеяния наглядно демонстрирует, что класс Setosa является полностью линейно разделимым в пространстве признаков, тогда как Versicolor и Virginica имеют частичное перекрытие, но сохраняют выраженную тенденцию к кластеризации. Это доказывает, что правильный выбор признаков является прерогативой построения эффективных классификационных моделей.

**2. Сложность модели и ошибка обобщения**

В эксперименте с полиномиальной регрессией мы наблюдали динамику компромисса между смещением и дисперсией. Модель низкого порядка продемонстрировала недообучение из-за недостаточной выразительной способности. Модель высокого порядка (15), несмотря на минимальный остаток на тренировочных точках, показала резкие осцилляции в интервалах между ними. Результаты количественно визуализируют феномен переобучения: модель уловила случайный шум вместо скрытой физической закономерности.

Эксперимент окончательно показал, что критерием качества модели машинного обучения является не точность на обучающей выборке, а её способность к обобщению на неизвестных данных.

Модель порядка 1 : Кривая представляет собой прямую линию и не может отразить колебания, что является случаем **недообучение**.

Модель порядка 3 : Она плавно вписывается в основной тренд и демонстрирует **нормальное обучение**.

3.Модель порядка 15 : Кривая сильно искажена, пытаясь пройти через каждую зашумленную точку. Хотя ошибка на обучающем наборе минимальна, модель полностью теряет способность прогнозировать новые данные, что является типичным случаем **переобучение**.