Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

Эргатические Системы

Лабораторная работа №1

Основы машинного обучения, бинарная классификация и переобучение

Студент Канаан Хусейн

Группа ИУ1И-41М

Преподаватель А.С. Кучин

2026 г

Цель работы

Изучить базовые понятия машинного обучения, выполнить визуальный анализ набора данных Iris, построить модель Logistic Regression для бинарной классификации и показать эффект переобучения на примере полиномиальной регрессии.

Краткие ответы на теоретические вопросы

• **Проблема переобучения:** Модель слишком сильно подстраивается под обучающие данные и хуже работает на новых примерах.

• **Почему нельзя оценивать модель на обучающей выборке:** Такая оценка завышена, потому что модель может просто запомнить данные.

• **Что такое регуляризация:** Регуляризация ограничивает сложность модели и уменьшает риск переобучения.

1. Набор данных Iris

Параметр	Значение
Размер набора данных	150 объектов, 6 столбцов
Признаки	sepal length, sepal width, petal length, petal width
Классы	setosa, versicolor, virginica
Распределение классов	50 / 50 / 50
Бинарная задача	setosa vs versicolor

набор данных сбалансирован по классам и удобен для демонстрации базовых методов классификации.

2. Визуальный анализ данных (pairplot)

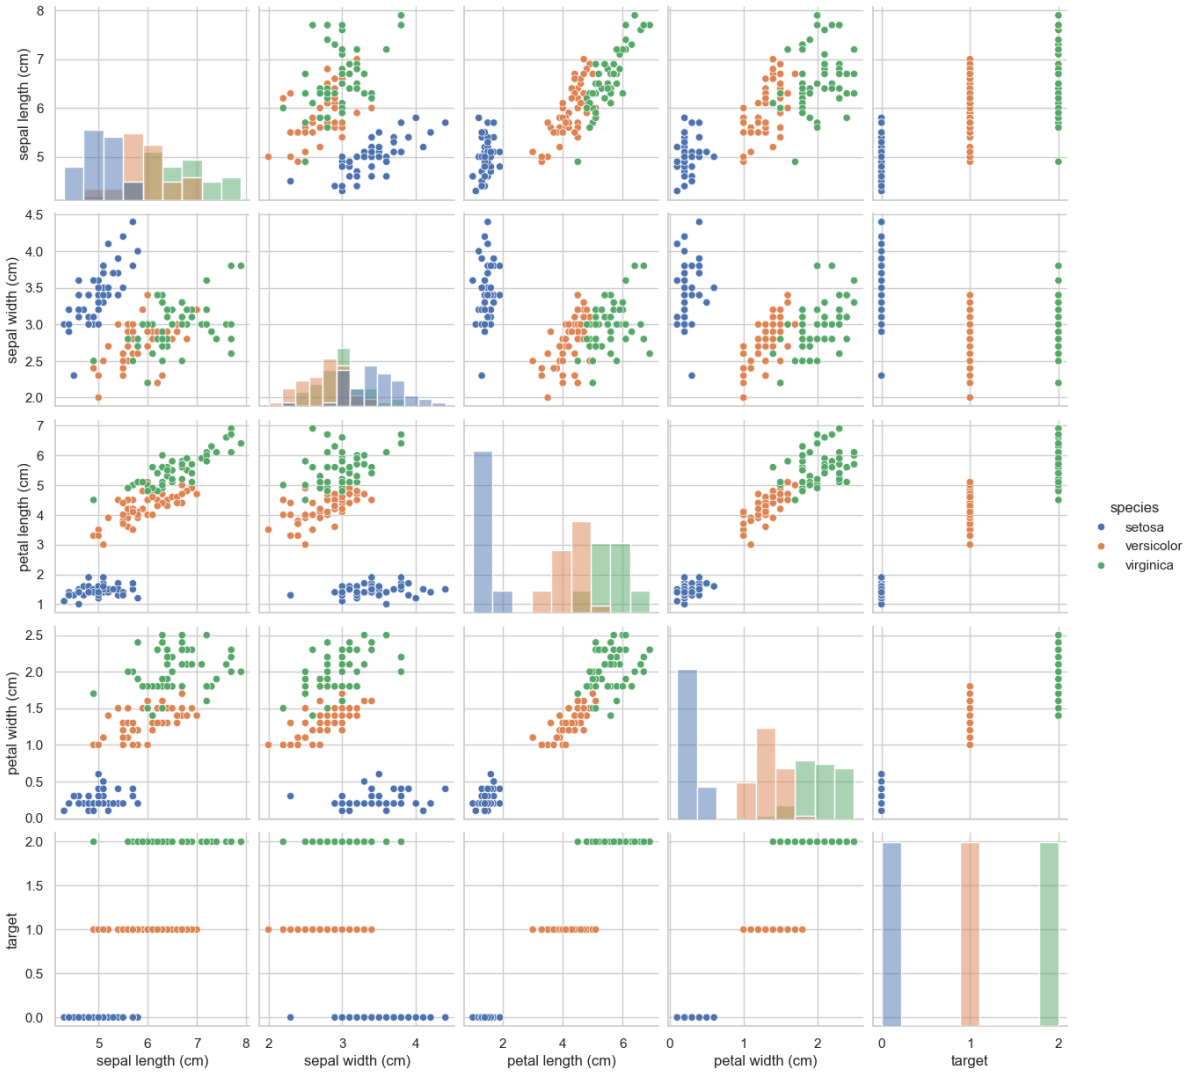

Рисунок 1 - Pairplot для набора данных Iris

класс setosa отделяется наиболее чётко. Между versicolor и virginica наблюдается частичное пересечение.

3. Бинарная классификация с помощью Logistic Regression

Показатель	Значение
Размер обучающей выборки	70
Размер тестовой выборки	30
Accuracy	1.00
Классы	setosa, versicolor

модель достигла точности 100% на тестовой выборке, так как выбранные классы хорошо разделяются по признакам.

Матрица ошибок

Истинный класс	Pred: setosa	Pred: versicolor
setosa	15	0
versicolor	0	15

неверных предсказаний нет. Все объекты из тестовой выборки распознаны правильно.

Основные метрики

Класс	Precision	Recall	F1-score	Support
setosa	1.00	1.00	1.00	15
versicolor	1.00	1.00	1.00	15
Среднее	1.00	1.00	1.00	30

значения precision, recall и F1-score равны 1.00, то есть модель не допустила ошибок на тесте.

4. Демонстрация переобучения

Степень полинома	Train MSE	Test MSE
1	0.2238	0.2348
3	0.0166	0.0214
10	0.0096	2.2025
15	0.0080	184193.0144

при увеличении степени полинома ошибка на обучении уменьшается, но ошибка на тесте резко возрастает. Это и есть переобучение.

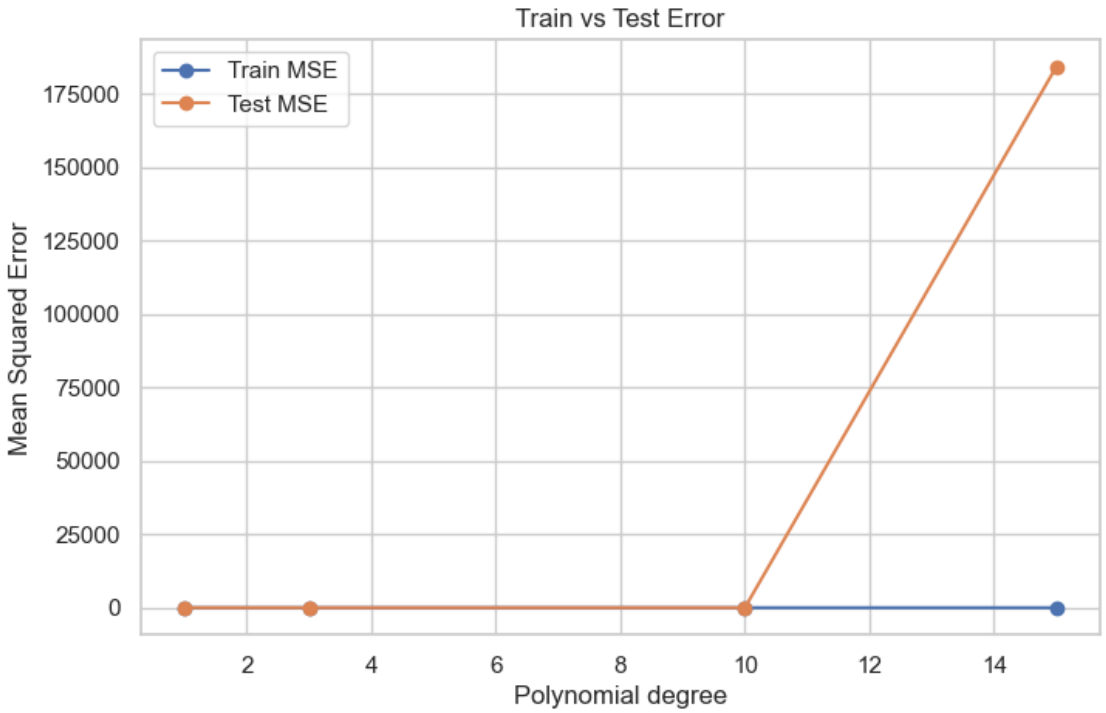

Рисунок 2 - Сравнение Train MSE и Test MSE

на степени 15 тестовая ошибка становится очень большой, хотя обучающая ошибка мала. Модель запоминает обучающие точки и плохо обобщает.

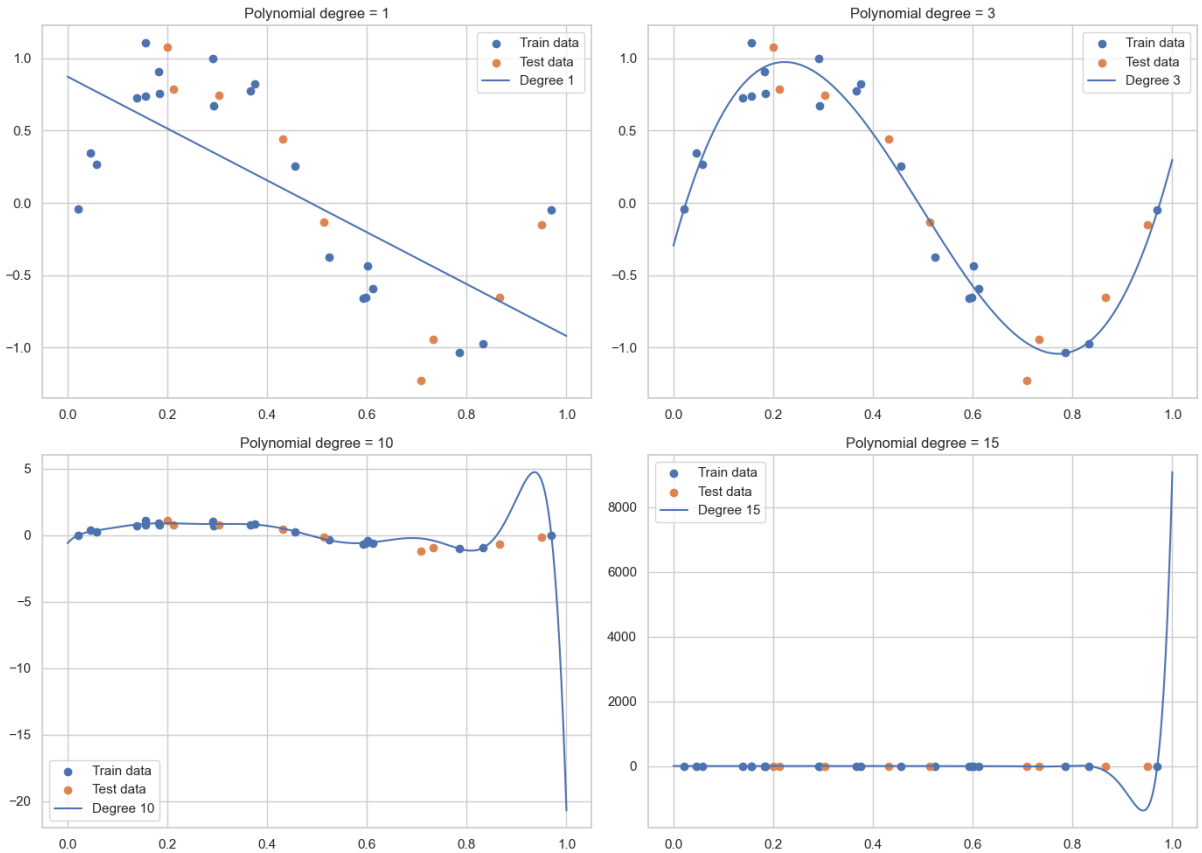

Рисунок 3 - Полиномиальная регрессия при разных степенях

степень 1 даёт слишком простую модель, степень 3 лучше описывает тренд, а степени 10 и 15 приводят к сильным колебаниям на краях интервала.

5. Влияние регуляризации

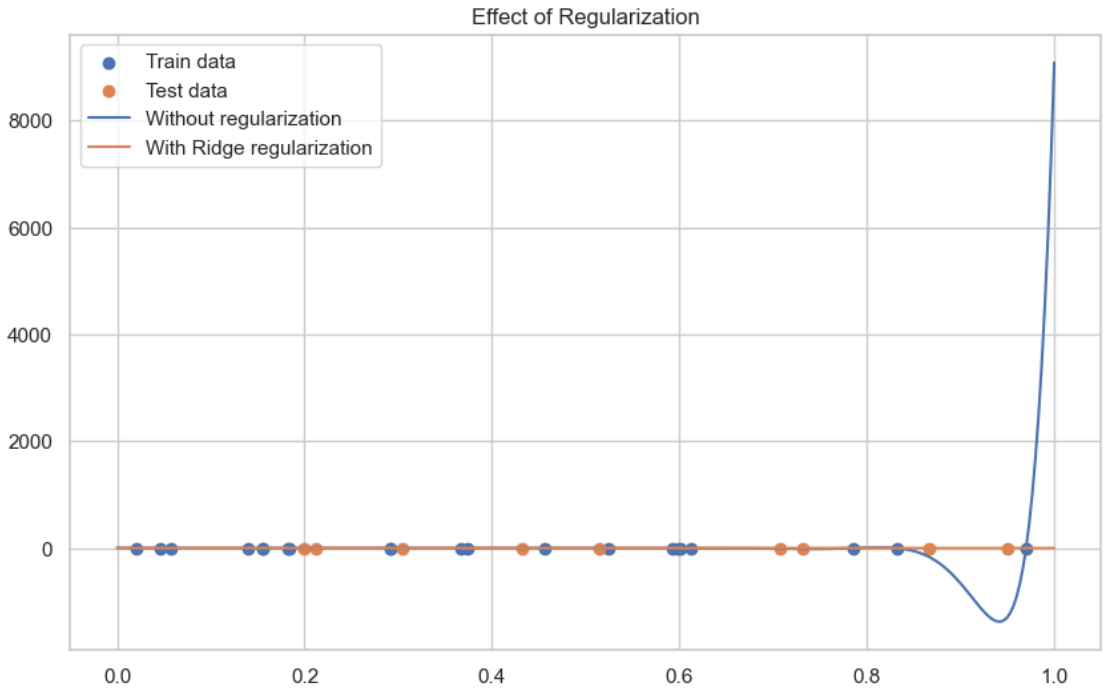

Рисунок 4 - Сравнение модели без регуляризации и с Ridge-регуляризацией

Ridge-регуляризация делает кривую более гладкой и устойчивой, поэтому модель лучше обобщает новые данные.

Вывод

• Набор данных Iris был успешно проанализирован визуально.

• Logistic Regression решила задачу бинарной классификации setosa и versicolor с точностью 100%.

• На примере полиномиальной регрессии показано, что усложнение модели может привести к переобучению.

• Регуляризация уменьшает переобучение и делает модель более стабильной.