



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Эргатические системы

Лабораторной работе №1

Выполнил: Ван Цзюньтао

Группа: ИУ1И-41М

Проверил: Андриков.Д.А.

Москва 2026

Цель работы:. Освоить основные концепции машинного обучения, ознакомиться с методами загрузки, предварительной обработки и визуализации набора данных Iris;

Освоить методы бинарной классификации на основе логистической регрессии (Logistic Regression), понять процесс обучения и оценки классификационных моделей;

Понять явления переобучения (Overfitting) и недообучения (Underfitting) в полиномиальной регрессии, ознакомиться с методами регуляризации (Regularization) и их ролью.

Теоретические основы

1. Логистическая регрессия

Логистическая регрессия (Logistic Regression) — это линейная модель, широко применяемая для задач бинарной классификации. Она использует сигмоидную функцию для отображения результатов линейной регрессии в интервал (0, 1), что отражает вероятность принадлежности образца к положительному классу.

Сигмоидная функция определяется следующим образом:

$$\sigma(z) = \frac{1}{1 + e^{(-z)}}$$

где $z = w^T x + b$. w — вектор весов, b — смещение.

Модель обучается параметрам путем максимизации функции логарифмической правдоподобия (или минимизации потери перекрестной энтропии). В задачах бинарной классификации, если вероятность превышает 0.5, прогнозируется положительный класс, в противном случае — отрицательный.

2. Полиномиальная регрессия

Полиномиальная регрессия представляет собой расширение линейной регрессии, позволяющее модели подстраиваться под нелинейные зависимости за счёт преобразования исходных признаков в полиномиальные признаки высокого порядка. Для входной переменной x модель полиномиальной регрессии степени d имеет вид:

$$y = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_d x^d$$

С увеличением степени d полинома выразительность модели повышается, но одновременно возрастает риск переобучения.

3. Переобучение и недообучение

Недообучение (Underfitting) означает, что модель слишком проста и не способна уловить скрытые закономерности в данных, в результате чего она демонстрирует низкую эффективность как на обучающей, так и на тестовой выборках. Переобучение (Overfitting) означает, что модель слишком сложна и не только усвоила реальные закономерности в данных, но и научилась распознавать шум и случайные колебания, что приводит к отличной эффективности на обучающей выборке, но к плохой способности к обобщению на новых данных.

Компромисс между смещением и дисперсией (Bias-Variance Tradeoff) является ключом к пониманию этой проблемы: простые модели имеют высокое смещение и низкую дисперсию; сложные модели имеют низкое смещение и высокую дисперсию. Идеальная модель должна обеспечивать баланс между этими двумя характеристиками.

4. Регуляризация

Регуляризация (Regularization) — это метод, позволяющий контролировать сложность модели и предотвращать переобучение путем наложения штрафного термина на параметры модели. К распространенным методам регуляризации относятся:

- 1) L2-регуляризация (Ridge): добавление в функцию потерь штрафного термина $\lambda \sum \theta_j^2$, представляющего собой сумму квадратов весов, что приводит к уменьшению значений весов, но не делает их строго нулевыми;
- 2) L1-регуляризация (Lasso): добавление в функцию потерь штрафного слагаемого, равного сумме абсолютных значений весов $\lambda \sum |\theta_j|$, что позволяет получить разреженное решение и автоматически выполнить выбор признаков.

Практическая часть

Анализ и визуализация наборов данных

1. Введение в набор данных Iris

Набор данных Iris (ирис) — один из самых классических наборов данных в области машинного обучения, представленный Рональдом Фишером в 1936 году. Набор данных содержит 150 образцов, разделенных на 3 категории (setosa, versicolor, virginica), по 50 образцов в каждой. Каждый образец включает 4 признака.

2. Визуальный анализ данных

С помощью библиотеки Seaborn построен матричный график Pairplot, демонстрирующий распределение точек по парам различных признаков, при этом три вида ирисов выделены разными цветами. На графике наглядно видно, что вид setosa линейно разделяется от двух

других видов, тогда как между видами *versicolor* и *virginica* наблюдается некоторое пересечение.




Рис. 1. Визуализация набора данных Iris с помощью Pairplot

Моделирование и реализация эксперимента

1. Задача бинарной классификации.

Из набора данных Iris были отобраны два вида: *setosa* и *versicolor*, которые составили набор данных для бинарной классификации. Набор данных был разделен на обучающую и тестовую части в соотношении 80%/20%, для обучения использовалась модель логистической регрессии. Настройки параметров модели: `max_iter=200` (максимальное количество итераций), `random_state=42` для обеспечения воспроизводимости результатов.

Модель достигла 100% точности (Accuracy = 1.0) на тестовом наборе, что объясняется хорошей линейной различимостью видов *setosa* и *versicolor* в пространстве признаков, в частности, признаки «длина лепестка» и «ширина лепестка» позволяют хорошо различать эти два класса.

2. Полиномиальная регрессия и переобучение

Для наглядной демонстрации явления переобучения было сгенерировано 10 точек выборки с шумом на основе косинусоидальной функции $y = \cos(1.5\pi \cdot x)$ с добавлением гауссова шума

(стандартное отклонение 0.1). Была проведена аппроксимация с использованием полиномов 1-й, 3-й и 15-й степени; результаты представлены ниже:

- Полином 1-й степени (недостаточная аппроксимация): модель слишком проста, не способна уловить нелинейную тенденцию данных, представляет собой прямую линию, погрешность значительна;
- Полином 3-й степени (хорошая аппроксимация): хорошо отражает общую тенденцию данных, демонстрирует сбалансированное поведение между обучающими и тестовыми точками;
- Полином 15-й степени (переобучение): модель слишком сложна, для точного прохождения каждой обучающей точки кривая резко колеблется между точками данных; хотя ошибка обучения практически равна нулю, способность к обобщению крайне низкая.




Рис. 2. Сравнение моделей полиномиальной регрессии разного порядка

Результаты эксперимента и анализ

1. Анализ результатов бинарной классификации

Модель логистической регрессии достигла точности 100% в задаче бинарной классификации Iris, что свидетельствует о линейной различимости классов *setosa* и *versicolor* в пространстве признаков. Как видно из диаграммы Pairplot, два признака — длина лепестка и ширина лепестка — позволяют эффективно р

2. Анализ переобучения при полиномиальной регрессии

Эксперименты с полиномиальной регрессией наглядно демонстрируют влияние сложности модели на способность к обобщению:

(1) $\text{degree}=1$: недообучение. Отклонение модели слишком велико, она не способна уловить нелинейные закономерности в данных.

(2) $\text{degree}=3$: оптимальное обучение. Сложность модели умеренная, она обеспечивает хороший баланс между отклонением и дисперсией, а также демонстрирует хорошую способность к прогнозированию новых данных.

(3) $\text{degree}=15$: переобучение. Дисперсия модели слишком высока; хотя она идеально подходит ко всем точкам обучения, результаты прогнозирования по тестовым точкам крайне плохие.

3. Роль регуляризации

Регуляризация ограничивает размер параметров модели путем добавления штрафного члена в функцию потерь, что позволяет эффективно сдерживать переобучение. L2-нормировка (Ridge) приводит к тому, что параметры стремятся к нулю, но не равны нулю, а L1-нормировка (Lasso) может сжать часть параметров до нуля, реализуя выбор признаков.

В данном эксперименте, если применить L2-нормировку к 15-степенному многочлену, коэффициенты слагаемых высоких степеней будут значительно сжаты, кривая станет более гладкой, приблизившись к разумному результату подгонки 3-степенного многочлена.