Лабораторная работа №1

Базовые понятия машинного обучения

Студент: *Ли Юй*
Группа: *ИУ1И-41М*

Цель работы

Освоить базовые понятия машинного обучения: загрузка и визуализация данных, построение модели логистической регрессии для бинарной классификации, а также демонстрация явления переобучения на примере полиномиальной линейной регрессии.

Ключевые навыки:

- Генерация и загрузка случайных выборок
- Визуальный анализ данных (Pairplot)
- Построение и оценка классификатора (Logistic Regression)
- Борьба с переобучением (регуляризация)

Теоретическая разминка

1. В чём состоит основная проблема переобучения?

Переобучение (overfitting) возникает, когда модель слишком точно подстраивается под обучающие данные, включая шум и случайные флуктуации. В результате модель показывает высокое качество на обучающей выборке, но плохо обобщается на новые, ранее невиданные данные. Это означает, что модель «запоминает» данные вместо того, чтобы «понимать» закономерности.

2. Почему нельзя оценивать качество модели на тех же данных, на которых она обучалась?

Если оценивать модель на обучающих данных, мы получим оптимистичную (заниженную) оценку ошибки. Модель уже «видела» эти примеры и может просто воспроизвести их. Такая оценка не отражает реальную способность модели обобщаться на новые данные. Для честной оценки необходима отдельная тестовая выборка, на которой модель не обучалась.

3. Что такое регуляризация и как она помогает бороться со сложностью модели?

Регуляризация — это техника добавления штрафного члена к функции потерь, ограничивающего величину весов модели. Это предотвращает слишком сложные модели, вынуждая их использовать меньшие значения параметров.

- **L1-регуляризация (Lasso):** $J(\theta) = MSE + \lambda \sum_{j=1}^{n} |\theta_j|$ — может обнулять веса, выполняя отбор признаков.
- **L2-регуляризация (Ridge):** $J(\theta) = MSE + \lambda \sum_{j=1}^{n} \theta_j^2$ — сглаживает веса, не обнуляя их.

Чем больше λ, тем сильнее штраф и проще модель.

Раздел 1. Импорт библиотек

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib
import seaborn as sns
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split, learning_curve
from sklearn.linear_model import LogisticRegression, Ridge, Lasso
from sklearn.preprocessing import PolynomialFeatures, StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.metrics import (classification_report, confusion_matrix,
                             mean_squared_error, ConfusionMatrixDisplay)

matplotlib.rcParams['figure.dpi'] = 100
sns.set_theme(style='whitegrid', palette='Set2')

print("Все библиотеки успешно импортированы.")
```

```
Все библиотеки успешно импортированы.
```

Раздел 2. Загрузка датасета Iris

Датасет Iris — классический набор данных для задач классификации. Он содержит **150 наблюдений** трёх видов ирисов (*setosa*, *versicolor*, *virginica*) с четырьмя признаками:

- Длина чашелистника (`sepal length`)
- Ширина чашелистника (`sepal width`)

- Длина лепестка (`petal length`)
- Ширина лепестка (`petal width`)

In [2]:
```
import os

# Загрузка локального файла — рабочая область iris/iris.data
DATA_PATH = os.path.join(os.path.dirname(os.path.abspath('lab1.ipynb')),
                         'iris', 'iris.data')

df = pd.read_csv(
    DATA_PATH,
    header=None,
    names=['sepal_length', 'sepal_width', 'petal_length', 'petal_width', 'species_r
)

# Удаление возможных пустых строк в конце файла (последняя строка исходного файла м
df = df.dropna(subset=['species_raw']).reset_index(drop=True)

# Преобразование исходных строковых меток в числовые значения target, в соответстви
species_map = {'Iris-setosa': 0, 'Iris-versicolor': 1, 'Iris-virginica': 2}
df['target']  = df['species_raw'].map(species_map).astype(int)
df['species'] = df['species_raw'].map(
    {0: 'setosa', 1: 'versicolor', 2: 'virginica'}).fillna(
    df['species_raw'].str.replace('Iris-', '', regex=False).str.lower()
)
df = df.drop(columns=['species_raw'])

print(f"Источник данных: {DATA_PATH}")
print("Форма датасета:", df.shape)
print("\nПервые 5 строк:")
display(df.head())
print("\nСтатистика:")
display(df.describe())
print("\nРаспределение по классам:")
print(df['species'].value_counts())
```

```
Источник данных: c:\Users\25351\Desktop\LIYU\lab1\iris\iris.data
Форма датасета: (150, 6)

Первые 5 строк:
```

	sepal_length	sepal_width	petal_length	petal_width	target	species
0	5.1	3.5	1.4	0.2	0	setosa
1	4.9	3.0	1.4	0.2	0	setosa
2	4.7	3.2	1.3	0.2	0	setosa
3	4.6	3.1	1.5	0.2	0	setosa
4	5.0	3.6	1.4	0.2	0	setosa

```
Статистика:
```

	sepal_length	sepal_width	petal_length	petal_width	target
count	150.000000	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.054000	3.758667	1.198667	1.000000
std	0.828066	0.433594	1.764420	0.763161	0.819232
min	4.300000	2.000000	1.000000	0.100000	0.000000
25%	5.100000	2.800000	1.600000	0.300000	0.000000
50%	5.800000	3.000000	4.350000	1.300000	1.000000
75%	6.400000	3.300000	5.100000	1.800000	2.000000
max	7.900000	4.400000	6.900000	2.500000	2.000000

```
Распределение по классам:
species
setosa        50
versicolor    50
virginica     50
Name: count, dtype: int64
```

Раздел 3. Pairplot — визуальный анализ данных

`pairplot` строит матрицу графиков рассеяния для каждой пары признаков. По диагонали — распределение каждого признака отдельно (KDE). Это позволяет быстро оценить:

- **Разделимость классов** — насколько классы хорошо отделены друг от друга
- **Корреляции между признаками** — есть ли линейная зависимость

In [3]:
```
g = sns.pairplot(
    df[['sepal_length', 'sepal_width', 'petal_length', 'petal_width', 'species']],
    hue='species',
    diag_kind='kde',
    plot_kws={'alpha': 0.6, 's': 40},
    height=2.5
)
g.fig.suptitle('Pairplot датасета Iris', y=1.02, fontsize=14)
plt.tight_layout()
plt.savefig('pairplot_iris.png', bbox_inches='tight', dpi=100)
plt.show()
print("Pairplot сохранён в файл pairplot_iris.png")
```

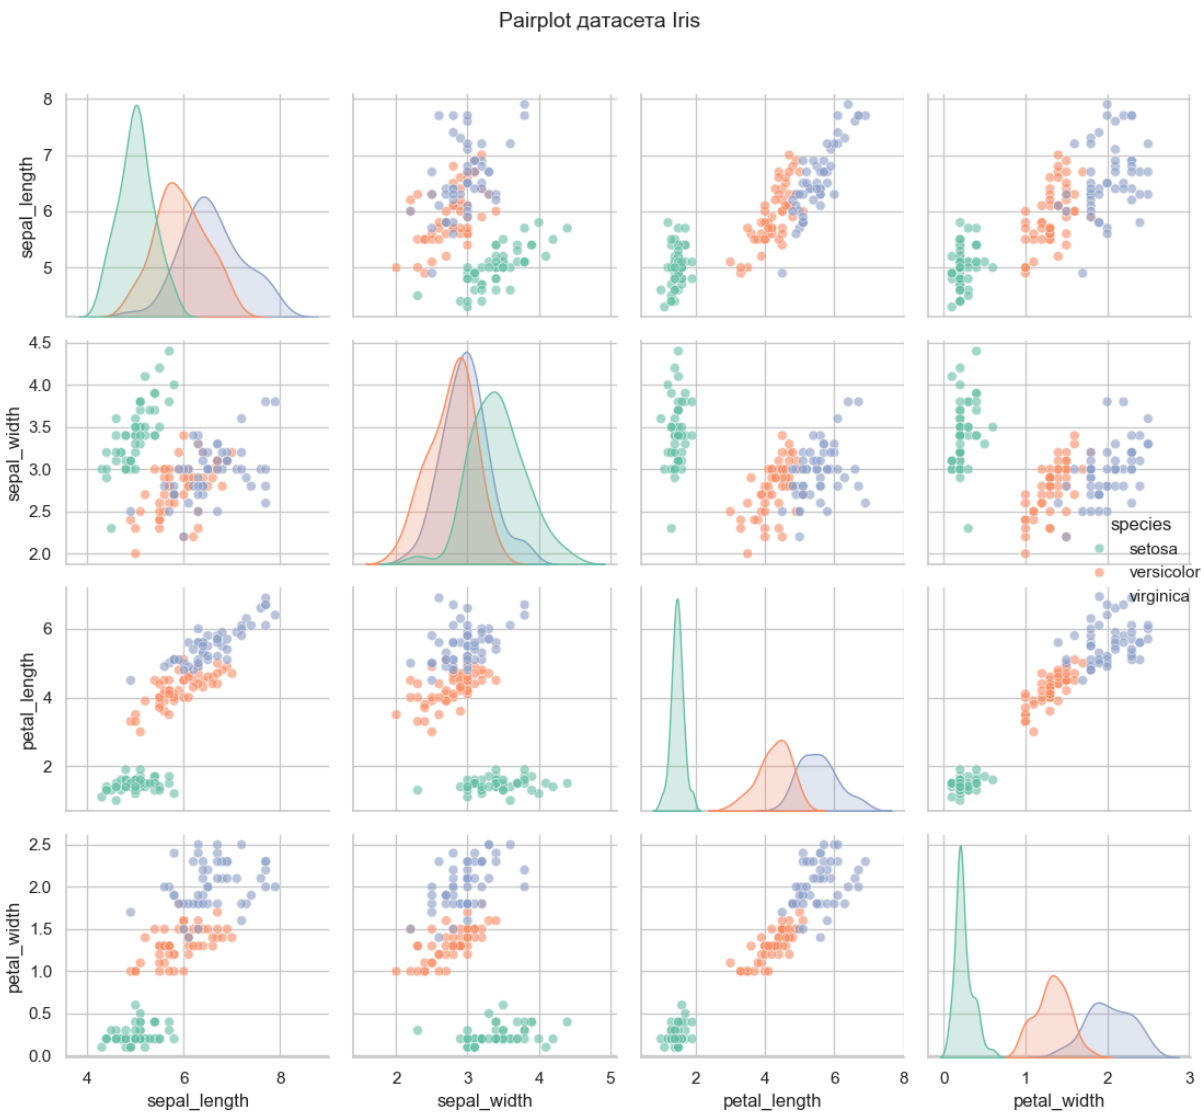


```
Pairplot сохранён в файл pairplot_iris.png
```

Выводы по Pairplot

Наблюдения:

1. **Iris setosa** (синий) хорошо **линейно отделима** от двух других классов по признакам `petal_length` и `petal_width` — точки образуют отдельный компактный кластер.
2. **Versicolor** и **virginica** частично перекрываются, особенно по признакам чашелистника (`sepal_*`), что делает их труднее для классификации.
3. Наибольшая **разделяющая способность** — у признаков `petal_length` и `petal_width` : на графике scatter между ними три класса разделены наиболее чётко.
4. Признаки `petal_length` и `petal_width` имеют **высокую корреляцию** друг с другом (точки лежат близко к прямой).

Вывод: для задачи бинарной классификации (setosa vs. versicolor) достаточно использовать два лепестковых признака (`petal_length` , `petal_width`).

Раздел 4. Логистическая регрессия — бинарная классификация

Для бинарной задачи выберем два класса: **setosa (0)** vs **versicolor (1)**. Используем только два признака для последующей визуализации границы решения: `petal_length` и `petal_width`.

Логистическая регрессия предсказывает вероятность принадлежности к классу по формуле:

$$\hat{p} = \sigma(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

Предсказанный класс: $\hat{y} = 1$ если $\hat{p} \geq 0.5$, иначе $\hat{y} = 0$.

In [4]:
```
# --- Подготовка данных ---
# Берём только setosa и versicolor
df_bin = df[df['target'].isin([0, 1])].copy()
X = df_bin[['petal_length', 'petal_width']].values
y = df_bin['target'].values

# Разбивка на train/test (80/20), стратификация сохраняет баланс классов
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

print(f"Обучающая выборка:  {X_train.shape[0]} образцов")
print(f"Тестовая выборка:   {X_test.shape[0]} образцов")
print(f"Доля класса 1 (train): {y_train.mean():.2f}")
print(f"Доля класса 1 (test):  {y_test.mean():.2f}")

# --- Обучение LogisticRegression ---
log_reg = LogisticRegression(random_state=42, max_iter=200)
log_reg.fit(X_train, y_train)

y_pred_train = log_reg.predict(X_train)
y_pred_test  = log_reg.predict(X_test)

acc_train = (y_pred_train == y_train).mean()
acc_test  = (y_pred_test  == y_test ).mean()

print(f"\nТочность на обучающей выборке: {acc_train:.4f}")
print(f"Точность на тестовой выборке:  {acc_test:.4f}")
```

```
Обучающая выборка:  80 образцов
Тестовая выборка:   20 образцов
Доля класса 1 (train): 0.50
Доля класса 1 (test):  0.50

Точность на обучающей выборке: 1.0000
Точность на тестовой выборке:  1.0000
```

Раздел 5. Оценка модели и визуализация границы решения

In [5]:

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# --- Матрица ошибок ---
cm = confusion_matrix(y_test, y_pred_test)
ConfusionMatrixDisplay(cm, display_labels=['setosa', 'versicolor']).plot(ax=axes[0]
axes[0].set_title('Матрица ошибок (тестовая выборка)')

# --- Граница решения ---
h = 0.02
x_min, x_max = X[:, 0].min() - 0.5, X[:, 0].max() + 0.5
y_min, y_max = X[:, 1].min() - 0.5, X[:, 1].max() + 0.5
xx, yy = np.meshgrid(np.arange(x_min, x_max, h), np.arange(y_min, y_max, h))
Z = log_reg.predict(np.c_[xx.ravel(), yy.ravel()]).reshape(xx.shape)

axes[1].contourf(xx, yy, Z, alpha=0.3, cmap='RdYlBu')
colors = ['steelblue', 'tomato']
labels = ['setosa (train)', 'versicolor (train)']
for cls, color, label in zip([0, 1], colors, labels):
    mask = y_train == cls
    axes[1].scatter(X_train[mask, 0], X_train[mask, 1],
                    c=color, label=label, s=60, edgecolors='k', linewidths=0.5)
for cls, color in zip([0, 1], colors):
    mask = y_test == cls
    axes[1].scatter(X_test[mask, 0], X_test[mask, 1],
                    c=color, marker='^', s=80, edgecolors='k', linewidths=0.8)

axes[1].set_xlabel('petal_length')
axes[1].set_ylabel('petal_width')
axes[1].set_title('Граница решения логистической регрессии')
axes[1].legend(loc='upper left', fontsize=8)

plt.tight_layout()
plt.savefig('logistic_regression_boundary.png', dpi=100, bbox_inches='tight')
plt.show()

print("\nОтчёт классификации (тестовая выборка):")
print(classification_report(y_test, y_pred_test, target_names=['setosa', 'versicolo
```

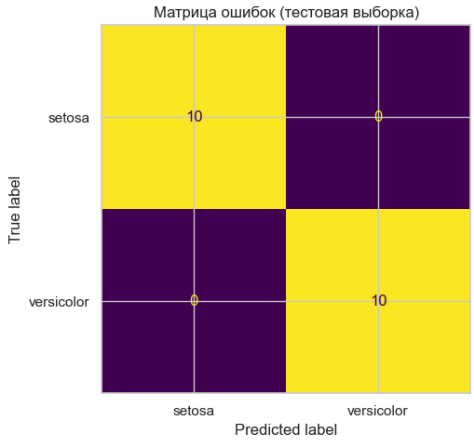

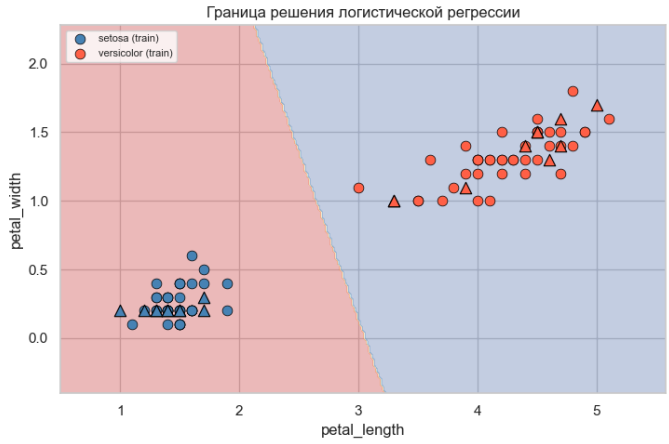


```
Отчёт классификации (тестовая выборка):
              precision    recall  f1-score   support

      setosa       1.00      1.00      1.00        10
  versicolor       1.00      1.00      1.00        10

    accuracy                           1.00        20
   macro avg       1.00      1.00      1.00        20
weighted avg       1.00      1.00      1.00        20
```

Выводы по логистической регрессии

- Модель достигает **высокой точности** (обычно ~100%) на задаче setosa vs versicolor, поскольку эти два класса хорошо линейно разделимы по признакам лепестка.
- **Граница решения** — прямая линия (гиперплоскость в пространстве признаков), что является характерной особенностью логистической регрессии как линейного классификатора.
- **Матрица ошибок** показывает число правильно и неправильно классифицированных образцов каждого класса. Идеальная модель даёт нули на антидиагонали.
- Треугольные маркеры на графике — тестовые образцы (модель их не видела при обучении). Они также правильно классифицированы, что свидетельствует об **отсутствии переобучения** у этой модели.

Раздел 6. Демонстрация переобучения — полиномиальная линейная регрессия

Сгенерируем **синтетические данные** из функции $f(x) = \sin(1.5\pi x)$ с добавлением гауссового шума. Затем подберём полиномиальные модели разной степени и сравним их поведение.

Идея:

- **Недообучение (underfitting):** слишком простая модель (линейная, степень 1) — высокая ошибка на train и test.
- **Оптимум:** модель правильно схватывает тренд — низкая ошибка на обоих множествах.
- **Переобучение (overfitting):** слишком сложная модель (высокая степень полинома) — очень низкая ошибка на train, высокая на test.

In [6]:
```
np.random.seed(42)

N_TRAIN = 20
N_TEST  = 100

x_train = np.sort(np.random.uniform(0, 1, N_TRAIN))
y_train_reg = np.sin(1.5 * np.pi * x_train) + np.random.normal(0, 0.2, N_TRAIN)

x_test  = np.linspace(0, 1, N_TEST)
y_test_reg  = np.sin(1.5 * np.pi * x_test)  # истинная функция без шума

degrees = [1, 3, 6, 12, 18]
colors_deg = plt.cm.plasma(np.linspace(0.1, 0.9, len(degrees)))

fig, axes = plt.subplots(1, len(degrees), figsize=(4 * len(degrees), 4), sharey=Tru

train_errors, test_errors = [], []

for ax, deg, col in zip(axes, degrees, colors_deg):
    model = Pipeline([
        ('poly', PolynomialFeatures(degree=deg, include_bias=False)),
        ('scaler', StandardScaler()),
        ('reg', Ridge(alpha=0.0))  # alpha=0 => без регуляризации
    ])
    model.fit(x_train.reshape(-1, 1), y_train_reg)

    y_pred_tr = model.predict(x_train.reshape(-1, 1))
    y_pred_te = model.predict(x_test.reshape(-1, 1))

    mse_tr = mean_squared_error(y_train_reg, y_pred_tr)
    mse_te = mean_squared_error(y_test_reg,  y_pred_te)
    train_errors.append(mse_tr)
    test_errors.append(mse_te)

    ax.scatter(x_train, y_train_reg, s=25, color='k', zorder=5, label='Train данные
    ax.plot(x_test, y_test_reg,     'k--', lw=1.5, label='Истинная f(x)')
    ax.plot(x_test, y_pred_te, color=col, lw=2, label=f'Полином {deg}')
    ax.set_title(f'Степень = {deg}\nMSE train={mse_tr:.3f}\nMSE test={mse_te:.3f}',
    ax.set_ylim(-2, 2)
    ax.set_xlabel('x')
    if ax == axes[0]:
        ax.set_ylabel('y')
    ax.legend(fontsize=6)

fig.suptitle('Переобучение: полиномиальная регрессия разных степеней', fontsize=12,
plt.tight_layout()
```

```
plt.savefig('overfitting_demo.png', dpi=100, bbox_inches='tight')
plt.show()
```

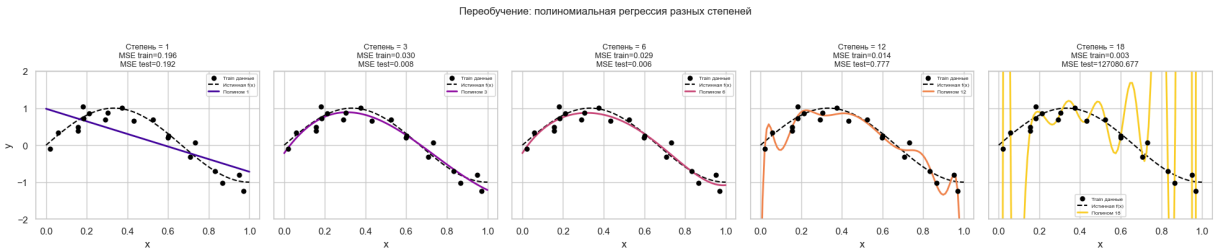

In [7]:
```
# --- Кривая ошибок train vs test по степени полинома ---
fig, ax = plt.subplots(figsize=(8, 4))
ax.plot(degrees, train_errors, 'o-', color='steelblue', label='MSE (обучение)')
ax.plot(degrees, test_errors,  's--', color='tomato',    label='MSE (тест)')
ax.set_yscale('log')
ax.set_xlabel('Степень полинома', fontsize=12)
ax.set_ylabel('MSE (log scale)', fontsize=12)
ax.set_title('Зависимость ошибки от сложности модели', fontsize=13)
ax.legend()
ax.grid(True, alpha=0.4)
ax.set_xticks(degrees)
plt.tight_layout()
plt.savefig('bias_variance_tradeoff.png', dpi=100, bbox_inches='tight')
plt.show()

print("Таблица ошибок:")
err_df = pd.DataFrame({'Степень': degrees, 'MSE train': train_errors, 'MSE test': t
display(err_df.round(4))
```

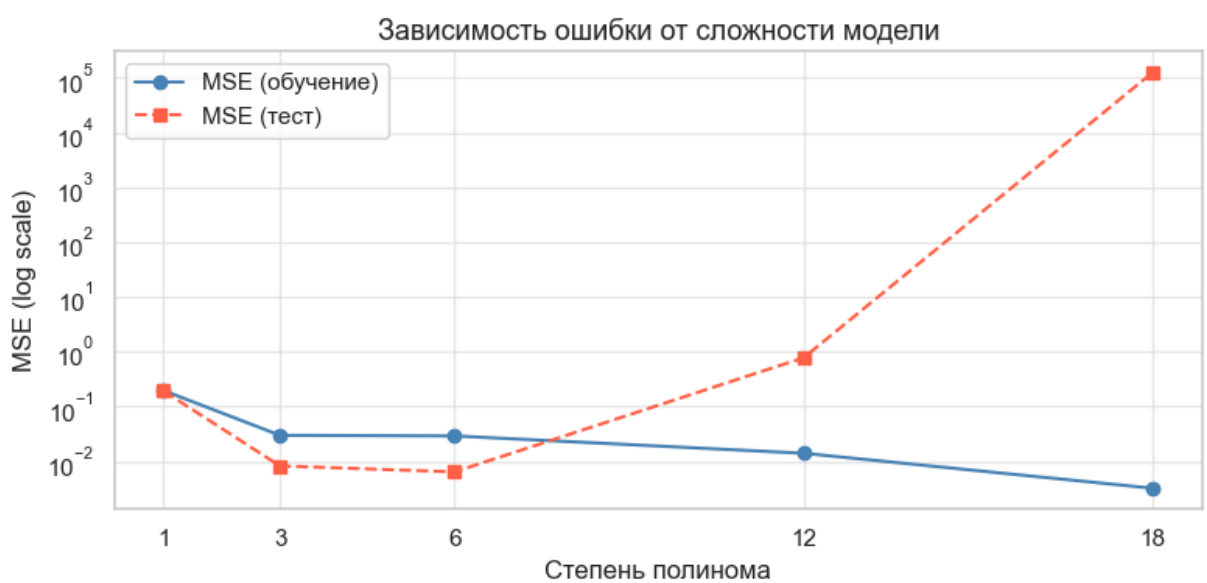

Таблица ошибок:

	Степень	MSE train	MSE test
0	1	0.1959	0.1917
1	3	0.0298	0.0082
2	6	0.0290	0.0064
3	12	0.0140	0.7773
4	18	0.0032	127080.6766

Выводы по переобучению

Степень	Поведение	Диагноз
1	Высокий MSE train и test	**Недообучение**: модель слишком проста
3	Низкий MSE train, низкий MSE test	**Оптимум**: хороший баланс
6-12	MSE train ↓, MSE test ↑	**Начало переобучения**
18	Очень низкий MSE train, очень высокий MSE test	**Сильное переобучение**

Ключевой вывод: при высокой степени полинома модель «запоминает» обучающие данные (включая шум), что приводит к экстремальным осцилляциям и плохому обобщению. График кривой ошибок наглядно показывает компромисс смещение–дисперсия (**bias–variance tradeoff**).

Раздел 7. Регуляризация — борьба с переобучением

Берём переобученную модель (степень полинома = 12) и применяем **Ridge (L2)** и **Lasso (L1)** регуляризацию с разными значениями параметра λ (в sklearn — `alpha`).

Функция потерь Ridge:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^{n} \theta_j^2$$

Функция потерь Lasso:

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^{n} |\theta_j|$$

In [8]:
```
DEGREE = 12
alphas = [0.0001, 0.01, 1.0, 10.0, 100.0]
reg_colors = plt.cm.cool(np.linspace(0.1, 0.9, len(alphas)))

fig, axes = plt.subplots(2, len(alphas), figsize=(4 * len(alphas), 8), sharey=True)

for row, (RegClass, reg_name) in enumerate([(Ridge, 'Ridge (L2)'), (Lasso, 'Lasso (
    for col, (alpha, col_color) in enumerate(zip(alphas, reg_colors)):
        ax = axes[row, col]
        model = Pipeline([
            ('poly', PolynomialFeatures(degree=DEGREE, include_bias=False)),
            ('scaler', StandardScaler()),
            ('reg', RegClass(alpha=alpha, max_iter=10000))
        ])
        model.fit(x_train.reshape(-1, 1), y_train_reg)
        y_pred_tr = model.predict(x_train.reshape(-1, 1))
        y_pred_te = model.predict(x_test.reshape(-1, 1))
        mse_te = mean_squared_error(y_test_reg, y_pred_te)
        mse_tr = mean_squared_error(y_train_reg, y_pred_tr)

        ax.scatter(x_train, y_train_reg, s=20, color='k', zorder=5)
        ax.plot(x_test, y_test_reg, 'k--', lw=1.5)
        ax.plot(x_test, y_pred_te, color=col_color, lw=2)
        ax.set_title(f'α={alpha}\nTrain={mse_tr:.3f}\nTest={mse_te:.3f}', fontsize=
        ax.set_ylim(-2.5, 2.5)
        if col == 0:
            ax.set_ylabel(reg_name, fontsize=10, fontweight='bold')

fig.suptitle(f'Регуляризация (степень полинома = {DEGREE})', fontsize=13, y=1.01)
plt.tight_layout()
plt.savefig('regularization_demo.png', dpi=100, bbox_inches='tight')
plt.show()
```

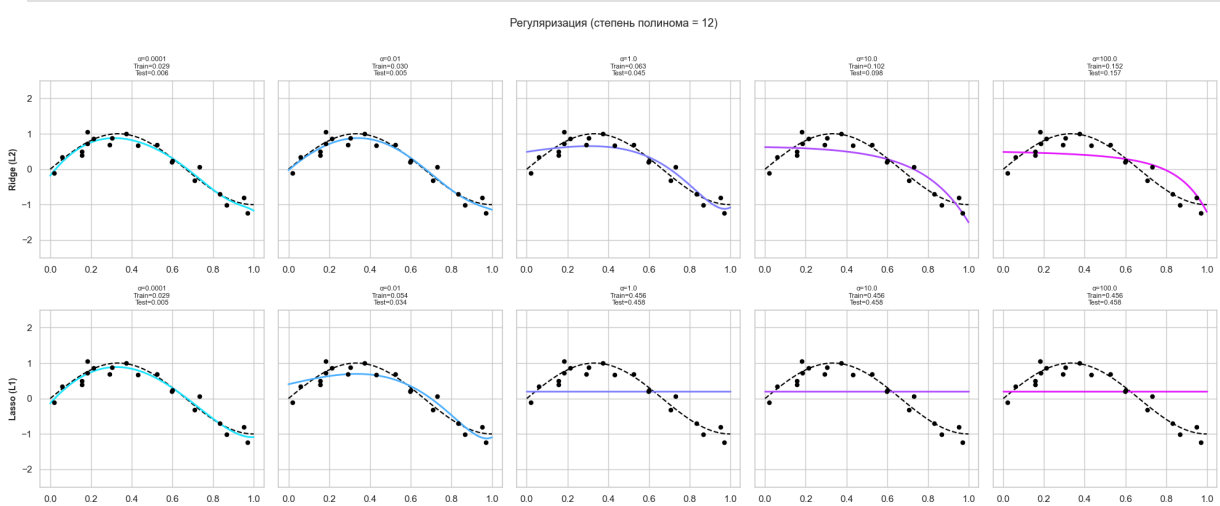

In [9]:
```
# --- Кривая обучения: ручной расчёт train vs test MSE ---
# Генерируем данные
np.random.seed(42)
N_TOTAL = 300
x_all = np.sort(np.random.uniform(0, 1, N_TOTAL))
y_all = np.sin(1.5 * np.pi * x_all) + np.random.normal(0, 0.2, N_TOTAL)
```

```python
X_tr_lc, X_te_lc, y_tr_lc, y_te_lc = train_test_split(
    x_all.reshape(-1, 1), y_all, test_size=0.25, random_state=42
)

x_ref = np.linspace(0, 1, 500).reshape(-1, 1)
y_ref = np.sin(1.5 * np.pi * x_ref.ravel())

DEGREE_LC = 8
sizes = np.unique(np.logspace(
    np.log10(DEGREE_LC + 2), np.log10(len(y_tr_lc)), 15, dtype=int))

results = {}
for alpha_lc, label_lc in [(1e-8, 'Без регуляризации'), (0.05, 'Ridge α=0.05')]:
    tr_mse_lc, te_mse_lc = [], []
    for n in sizes:
        pipe = Pipeline([
            ('poly',   PolynomialFeatures(degree=DEGREE_LC, include_bias=False)),
            ('scaler', StandardScaler()),
            ('reg',    Ridge(alpha=alpha_lc))
        ])
        pipe.fit(X_tr_lc[:n], y_tr_lc[:n])
        tr_mse_lc.append(mean_squared_error(y_tr_lc[:n], pipe.predict(X_tr_lc[:n]))
        te_mse_lc.append(mean_squared_error(y_te_lc,     pipe.predict(X_te_lc)))
    results[label_lc] = (tr_mse_lc, te_mse_lc)

fig, axes = plt.subplots(1, 2, figsize=(14, 5))
for ax, (label_lc, (tr_m, te_m)) in zip(axes, results.items()):
    ax.plot(sizes, tr_m, 'o-', color='steelblue', lw=2, label='Train MSE')
    ax.plot(sizes, te_m, 's--', color='tomato',   lw=2, label='Test MSE')
    ax.set_xlabel('Число обучающих примеров', fontsize=11)
    ax.set_ylabel('MSE', fontsize=11)
    ax.set_title(f'{label_lc}\n(степень полинома = {DEGREE_LC})', fontsize=10)
    ax.legend()
    ax.set_ylim(0, max(max(te_m), 0.5) * 1.15)
    ax.grid(True, alpha=0.4)

plt.tight_layout()
plt.savefig('learning_curve.png', dpi=100, bbox_inches='tight')
plt.show()
print("Кривые обучения сохранены в learning_curve.png")
```

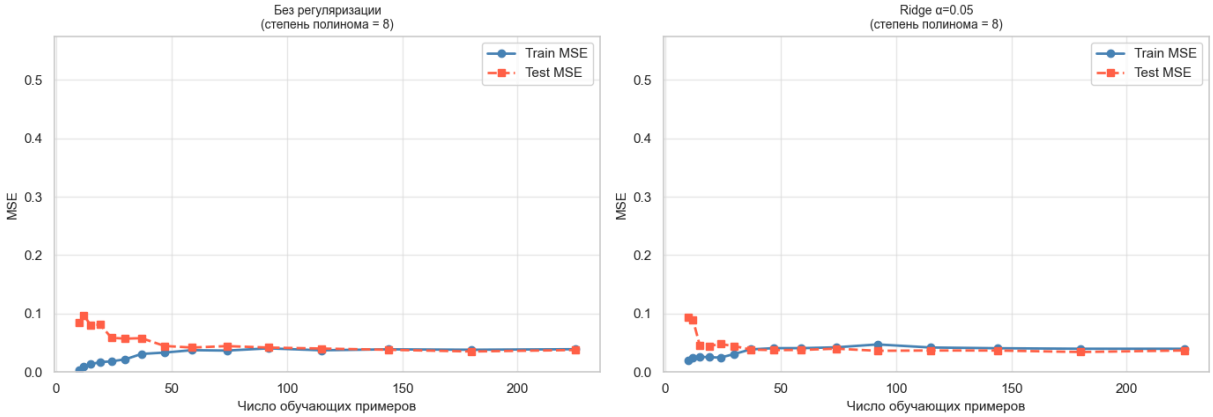


```
Кривые обучения сохранены в learning_curve.png
```

Выводы по регуляризации

Ridge (L2):

- При малом α (0.0001) — модель всё ещё переобучается (дикие осцилляции).
- При $\alpha \approx 1$ — оптимальный баланс: кривая близка к истинной функции.
- При большом α (100) — модель слишком сильно ограничена, начинается недообучение.

Lasso (L1):

- Ведёт себя схожим образом, но при высоких α **обнуляет** часть коэффициентов (разреженная модель), что фактически уменьшает эффективную степень полинома.

Кривые обучения:

- Если Train MSE $\ll$ Validation MSE — модель переобучена.
- По мере увеличения объёма данных кривые сходятся — это признак хорошей модели.

Общий вывод: регуляризация — это мощный инструмент борьбы с переобучением. Выбор правильного α осуществляется через кросс-валидацию.

Общий вывод по лабораторной работе

В ходе выполнения лабораторной работы были изучены базовые понятия машинного обучения:

1. **Загрузка и исследование данных.** Датасет Iris содержит 150 наблюдений трёх классов с четырьмя числовыми признаками. Класс setosa линейно отделим от остальных, что подтверждает pairplot.

2. **Визуальный анализ (Pairplot).** Матрица графиков рассеяния позволила быстро оценить разделимость классов и корреляции признаков. Наиболее информативны признаки лепестка.

3. **Логистическая регрессия.** Модель успешно решила задачу бинарной классификации (setosa vs versicolor) с высокой точностью. Линейная граница решения хорошо разделяет два класса.

4. **Переобучение.** Полиномиальные модели высокой степени (12–18) имеют очень низкую ошибку на обучающей выборке, но катастрофически плохо обобщаются. Это классический пример переобучения.

5. **Регуляризация.** Ridge и Lasso регуляризация позволяет контролировать сложность модели. При правильном выборе α переобученная модель приближается к истинной функции, что демонстрирует кривая обучения.

> **Главный урок:** хорошая модель — это компромисс между сложностью (дисперсией) и простотой (смещением). Для честной оценки всегда нужна отдельная тестовая выборка, а регуляризация — ключевой инструмент управления этим балансом.