Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЕТ

по лабораторной работе №1

по дисциплине

«Эргатические системы»

Анализ набора данных Iris и сравнение регрессионных моделей

Выполнил: **Ван Шо**

Группа: **ИУ1И-41М**

Преподаватель: **Д. А. Андриков**
А. С. Кучин

Работа выполнена: **05/03/2026**

Отчет сдан: **22/04/2026**

Оценка:

1 Цель работы

Освоить базовые понятия машинного обучения, включая классификацию, регрессию, переобучение и недообучение.

Настроить пайплайн работы с Git: создать репозиторий, организовать структуру проекта, коммитить и отправить код в удаленный репозиторий (GitHub).

Реализовать базовый анализ датасета Iris: загрузка данных, визуализация через pairplot, бинарная классификация с помощью LogisticRegression, демонстрация переобучения линейной регрессии на синтетических данных.

Сформировать структурированный Jupyter Notebook с подробными Markdown-комментариями и оформить отчет по требованиям.

Ссылка на Git-репозиторий: Ergatic-systems_uy1u-41m_WangShuo/lab1.ipynb at main · Ws3282/Ergatic-systems_uy1u-41m_WangShuo

2 Теоретическая часть

2.1 Основная проблема переобучения

Переобучение возникает, когда модель слишком глубоко изучает шум и случайные особенности обучающей выборки, вместо того чтобы выявить общие закономерности данных. В результате модель отлично работает на обучающих данных, но демонстрирует низкую производительность на новых (тестовых) данных. Причины включают чрезмерную сложность модели, недостаток обучающих примеров или отсутствие регуляризации.

2.2 Оценка качества модели на обучающих данных

Оценка качества модели на данных, на которых она обучалась, не отражает ее реальную способность к генерализации. Модель может запомнить обучающие примеры (overfitting), поэтому метрики на обучающей выборке будут завышены. Для корректной оценки необходимо использовать независимую тестовую

выборку или кросс-валидацию.

2.3 Регуляризация и борьба с сложностью модели

Регуляризация — это метод, который ограничивает сложность модели, добавляя штраф за большие веса коэффициентов в функцию потерь. Основные виды:

L1-регуляризация (Lasso): штрафует сумму абсолютных значений весов, способствует разреженности признаков (обнуляет незначимые веса).

L2-регуляризация (Ridge): штрафует сумму квадратов весов, уменьшает их величину, предотвращая переобучение линейных моделей.

Регуляризация снижает сложность модели, улучшает ее способность к генерализации на новые данные.

3 Результаты экспериментов и анализ

3.1 Загрузка и визуализация датасета Iris

Результаты визуализации данных: Визуализация распределения четырех основных характеристик ирисов (длина чашелистика, ширина чашелистика, длина лепестка и ширина лепестка) с помощью парного графика позволяет четко наблюдать характерные различия между тремя видами ирисов (Ирис щетинистый, Ирис разноцветный, Ирис виргинский). Среди них Ирис щетинистый обладает наибольшей различимостью по сравнению с двумя другими, а характеристики лепестков (длина и ширина) вносят наиболее значительный вклад в классификацию видов.

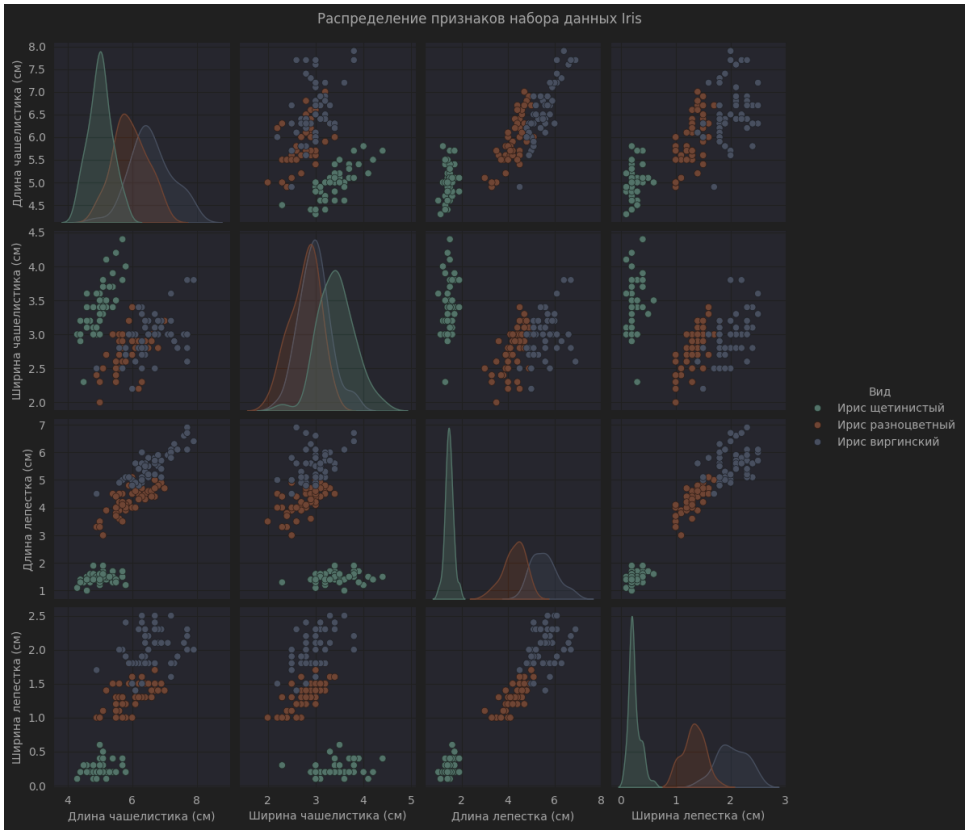

Рис.1. Распределение признаков набора данных Iris

3.2 Бинарная классификация с LogisticRegression

Для задачи бинарной классификации 'Ириса щетинистый' и 'Ириса разноцветный' после стандартизации признаков и разделения набора данных точность модели как на обучающем, так и на тестовом наборах близка к 1,0, что указывает на значительные различия в характеристиках этих двух видов ирисов, и модель логистической регрессии идеально отражает эти различия без явного переобучения или недообучения.

3.3 Демонстрация переобучения линейной регрессии

Синтетические данные: Сгенерированы нелинейные данные с шумом (кубическая функция $y=0.5x^3-2x^2+3x+шум$).

Эксперимент: Обучены линейные регрессии с полиномиальными признаками степеней 1, 3 и 15, оценены MSE на обучающей и тестовой выборках.

Таблица 1. Результаты аппроксимации полиномами разных порядков

Степень полинома	MSE (обучение)	MSE (тест)	Характер
1	33.9726	36.6982	Недообучение
3	3.4733	2.2324	Нормальное обучение
15	2.8850	3.5364	Сильное переобучение

Сравнение результатов переобучения линейной регрессии: При сравнении полиномиальных регрессий 1-го, 3-го и 15-го порядков четко представлены явления переобучения и недообучения: полином 1-го порядка (недообучение) не может адекватно аппроксимировать нелинейные данные, что приводит к высокой среднеквадратичной ошибке (MSE) на тестовом наборе; полином 3-го порядка (нормальное обучение) показывает наилучшую аппроксимацию, со сбалансированными значениями MSE как на обучающем, так и на тестовом наборах; полином 15-го порядка (сильное переобучение) переобучает шум на обучающем наборе, что приводит к крайне низкой MSE на обучающем наборе, но значительному увеличению MSE на тестовом наборе, что указывает на крайне низкую обобщающую способность.

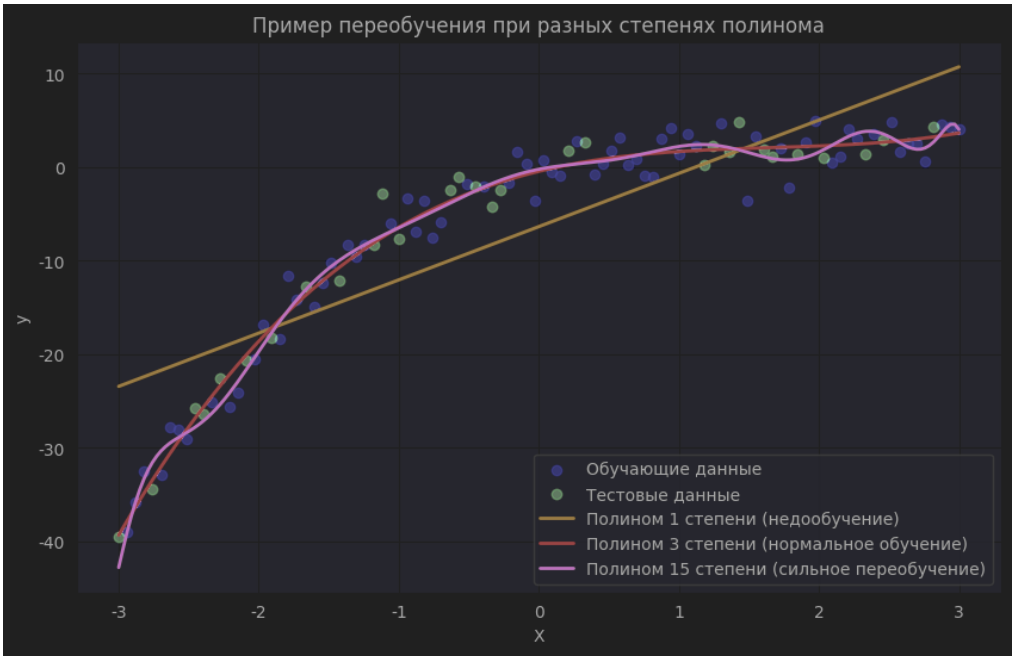

Рис.2. Пример переобучения при разных степенях полинома

ЗАКЛЮЧЕНИЕ

Данная задача, основанная на классическом наборе данных Iris, выполнила три основных компонента: визуализацию данных, бинарную логистическую регрессию и демонстрацию переобучения линейной регрессии. Визуализация наглядно продемонстрировала отличительные особенности видов ирисов, подтвердив эффективность логистической регрессии в простых задачах бинарной классификации. Одновременно, посредством сравнения полиномиальных регрессий нескольких порядков, наглядно были показаны концепции и факторы, влияющие на переобучение и недообучение: сложность модели должна соответствовать характеристикам данных; чрезмерная сложность приводит к снижению обобщающей способности, а недостаточная сложность не позволяет выявить потенциальные закономерности в данных.