



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

КАФЕДРА

ИУ-1 «Системы автоматического управления»

ОТЧЕТ О ВЫПОЛНЕНИИ ЛАБОРАТОРНОЙ РАБОТЫ

по дисциплине: «Эргатические системы»

Студент

Янь Синьюй

Группа

ИУ1И-41М

Тип задания

Задание №1

Преподаватель

А.С. Кучин

Оценка _____

1. Цель работы

Изучить применение логистической регрессии для задач бинарной классификации.

Освоить методы предобработки данных, стандартизации и оценки моделей.

Понять проблемы переобучения и недообучения на примере полиномиальной регрессии.

Научиться визуализировать результаты работы моделей и матрицу ошибок.

2. Среда выполнения

Python 3.11

Библиотеки: pandas, numpy, matplotlib, seaborn, scikit-learn

Google Colab

3. Ход работы

Часть 1 — Логистическая регрессия на датасете Iris

1. Подготовка данных

Использован датасет Iris (UCI)

Метка Iris-setosa кодируется как 1, остальные классы — 0

2. Визуализация данных

Использован sns.pairplot для отображения взаимосвязей между признаками

Просмотр распределения классов

3. Предобработка данных

Разделение на обучающую и тестовую выборки (70% / 30%)

Стандартизация признаков (StandardScaler)

4. Обучение и оценка модели

Логистическая регрессия (LogisticRegression, L2-регуляризация, C=0.5)

Вывод классификационного отчета и матрицы ошибок

Кросс-валидация (5-fold)

Вычисление точности на обучающей и тестовой выборках

5. Визуализация результатов

Матрица ошибок в виде тепловой карты

Часть 2 — Полиномиальная регрессия (переобучение/недообучение)

1. Генерация нелинейных данных

Формула: $y = 0.5 * X^2 - 3 * X + 10 + \text{noise}$

120чек, шум со стандартным отклонением 5

2. Разделение на обучающую и тестовую выборки

70% / 30%

3. Обучение моделей

Полиномиальная регрессия разной степени (1, 3, 15)

Вычисление MSE на обучающей и тестовой выборках

4. Визуализация результатов

Построение кривых для каждой степени

Сравнение предсказаний модели и исходных данных

5. Анализ результатов

Низкая степень (degree=1) → недообучение

Средняя степень (degree=3) → оптимальное приближение

Высокая степень (degree=15) → переобучение, тестовая ошибка увеличивается

5. Результаты эксперимента

Часть 1 — Логистическая регрессия

Метрика

Значение

Точность на обучении

1.0

Точность на тесте


1.0

Кросс-валидация

1.0

• Статистическое описание

Index	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	1
1	4.9	3.0	1.4	0.2	1
2	4.7	3.2	1.3	0.2	1




• **Классификационный отчёт:**

	precision	recall	f1-score	support
0	1.00	1.00	1.00	26
1	1.00	1.00	1.00	19
accuracy			1.00	45
macro avg	1.00	1.00	1.00	45
weighted avg	1.00	1.00	1.00	45

• **Матрица ошибок:**

	Predicted Non-Setosa	Predicted Setosa
Actual Non-Setosa	26	0
Actual Setosa	0	19


- Графики доступны в Notebook



Часть 2 — Полиномиальная регрессия

Степень	MSE на обучении	MSE на тесте
1	44.3337	40.5857
3	23.5376	23.7773
15	20.5165	24.8028

- degree=1 → недообучение
- degree=3 → оптимальная аппроксимация
- degree=15 → переобучение



6. Выводы

1. Логистическая регрессия

Эффективна для линейно разделимых данных (Iris бинарная классификация)

Стандартизация признаков улучшает сходимость и качество модели

2. Полиномиальная регрессия

Слишком простая модель → недообучение

Слишком сложная модель → переобучение

Средняя сложность оптимальна для баланса между обучением и тестом

3. Визуализация

Графики и матрицы ошибок помогают наглядно оценить качество моделей