Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика, искусственный интеллект и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Моделирование выборочных данных и анализ характеристик переобучения на основе алгоритмов машинного обучения

по лабораторной работе №.1

Дисциплина: Эргатические системы

Студент	ИУ1И-41М	31 / 03 /2026	Чжан Чжиян
	(Группа)	(Подпись, дата)	(И.О. Фамилия)
Преподаватель		/ /2026	Кучин А. С.
		(Подпись, дата)	(И.О. Фамилия)

2026 г.

1. Цель работы

Освойте основы моделирования и анализа данных: научитесь использовать набор данных Iris для логистической регрессии и бинарной классификации, а также анализируйте распределение признаков и переобучение модели с помощью визуализации.

Отработайте рабочий процесс управления версиями: создайте папку проекта lab1 и полностью внедрите рабочий процесс Git от написания кода локально до внесения изменений в удаленный репозиторий GitHub.

Ссылка на репозиторий Git:

https://github.com/CAICAIWOSHISHEIY/Machine-Learning-Labs

2. Теоретическая подготовка

1. **В чём заключается основная проблема переобучения?**

   Основная проблема переобучения заключается в том, что модель теряет свою способность к обобщению.

   - Когда модель становится чрезмерно сложной (слишком много параметров или слишком длительное время обучения), она не только изучает скрытые закономерности в данных, но и «запоминает» случайный шум и выбросы в выборках.
   - Это приводит к крайне малым, даже нулевым, ошибкам на обучающем наборе данных, но ошибки быстро увеличиваются при работе с неизвестными тестовыми данными. По сути, модель «обманывает», чтобы улучшить свой результат обучения, не понимая при этом истинного распределения данных.

2. **Почему мы не можем оценить качество модели на обучающем наборе данных?**

   Оценка модели на обучающем наборе данных может привести к завышенной оценке по следующим причинам:

   - Отсутствие валидации: обучающий набор используется моделью для

обновления параметров; модель уже «видела» все ответы. Хорошая производительность на обучающем наборе указывает лишь на высокую точность подгонки, а не на способность к прогнозированию.

- Невозможность обнаружения переобучения: если рассматривать только метрики обучающего набора, простая таблица соответствия (хранящая все входные и выходные данные) может обеспечить 100% точность, но она не предоставит результатов для новых входных данных.
- Моделирование в реальных условиях: цель машинного обучения — обработка неизвестных данных. Только путем независимой оценки на тестовом наборе можно по-настоящему смоделировать производительность модели в реальных приложениях.

3. Что такое регуляризация и как она помогает управлять сложностью модели?

Регуляризация — это метод, предотвращающий переобучение путем модификации функции потерь.

- Принцип: После исходного члена ошибки (например, среднеквадратичной ошибки) добавляется штрафной член. Этот член обычно пропорционален величине параметров модели (например, норме L1 или L2).
- Механизм управления: Регуляризация заставляет модель искать компромисс между «подгонкой к данным» и «сохранением простоты параметров». Она делает кривую модели более плавной, штрафуя чрезмерно большие значения весов, вместо того чтобы резко колебаться, подгоняя под каждую зашумленную точку.

3. Экспериментальная процедура и анализ результатов

ШАГ 1: Создайте парные диаграммы для визуального анализа характеристик данных.

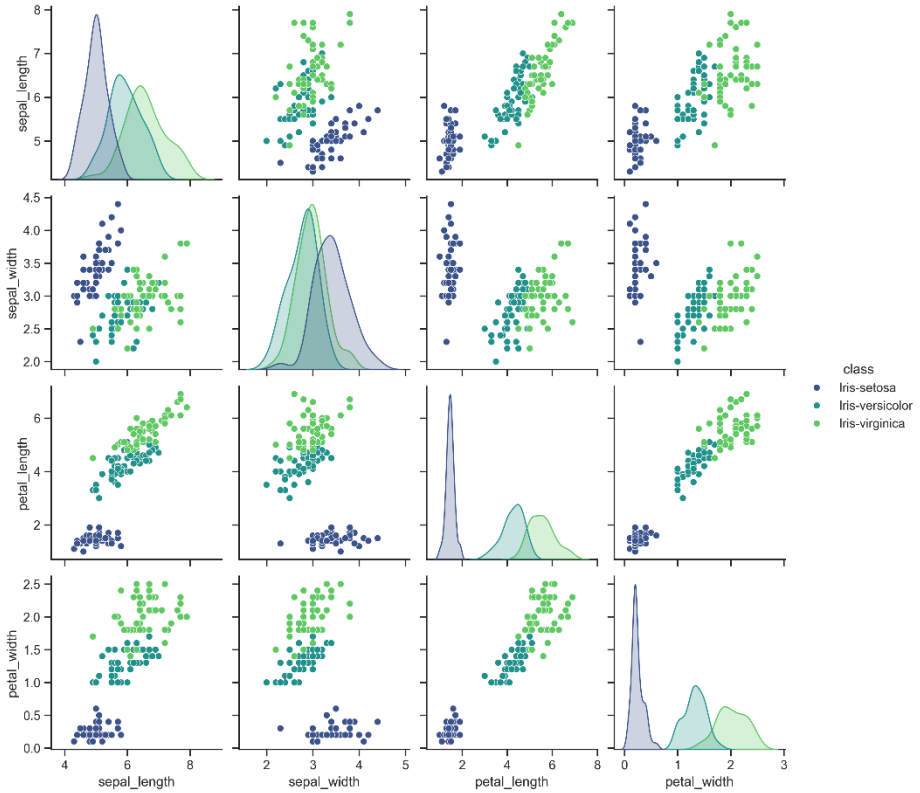

Разделимость категорий: Iris-setosa (горный ирис) демонстрирует чрезвычайно высокую разделимость по всем комбинациям признаков, полностью отделяясь от двух других категорий.

Ключевые признаки: Длина и ширина лепестков являются наиболее эффективными индикаторами для различения разных сортов. Границы распространения трех категорий ирисов относительно четкие по этим двум параметрам.

Корреляция признаков: Существует значительная положительная корреляция между длиной и шириной лепестков, что означает, что с увеличением длины лепестков, как правило, увеличивается и их ширина.

ШАГ 2: Выполните бинарную классификацию на наборе данных.

```
Точность бинарной классификации при логистической регрессии:
0.9333
```

В этом эксперименте для бинарной классификации сортов Iris-versicolor и Iris-

virginica использовалась логистическая регрессия. Несмотря на некоторое перекрытие пространств признаков этих двух сортов, модель логистической регрессии показала чрезвычайно высокую точность на тестовом наборе данных. Это демонстрирует, что логистическая регрессия, как линейный классификатор, может эффективно находить границу принятия решения в многомерном пространстве признаков для различения этих двух похожих сортов.

ШАГ 3: Представьте модель линейной регрессии и продемонстрируйте явления недоподгонки, идеальной подгонки и переподгонки.

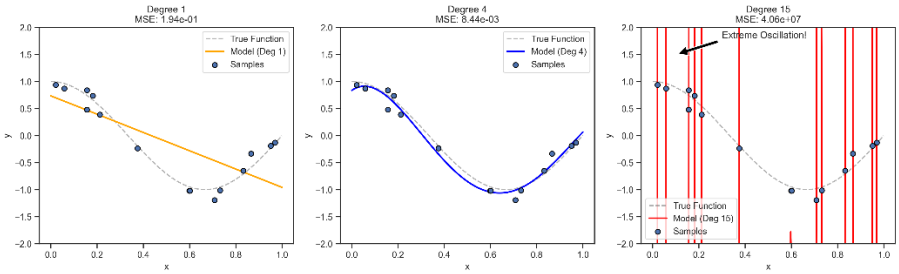

Недостаточное соответствие (степень 1): Модель представляет собой прямую линию, неспособную уловить флуктуации функции косинуса. Модель имеет высокое смещение; она слишком проста и крайне неадекватна в описании как обучающего набора данных, так и истинного паттерна.

Идеальное соответствие (степень 4): Кривая модели плавная и точно соответствует пунктирной линии (истинный паттерн). Она игнорирует случайный шум в выборках и успешно обучается лежащей в основе физической логике. Это указывает на хорошую обобщающую способность с наименьшей среднеквадратичной ошибкой на неизвестных тестовых данных.

Переобучение (степень 15): Модель достигает почти идеальных результатов в каждой точке выборки, но наблюдение за кривой выявляет сильные, бессмысленные колебания между точками выборки (особенно на концах изображения).

4. Заключение

В этом эксперименте систематически исследовалось влияние закономерностей распределения признаков и сложности модели на результаты прогнозирования путем предварительной обработки и классификации набора данных, собранного в лаборатории. На этапе исследования данных матрицы диаграмм рассеяния четко демонстрировали корреляции между различными измерениями признаков, обеспечивая физическую основу для выбора признаков в последующих моделях. На этапе построения модели, сравнивая модели многомерной регрессии и логистической регрессии разных порядков, экспериментальные результаты убедительно продемонстрировали баланс между возможностями модели и ее способностью к обобщению: когда порядок модели слишком высок, хотя ошибка на обучающем наборе значительно уменьшается, резкие колебания кривой указывают на то, что модель улавливает слишком много случайного шума, а не лежащих в основе физических законов, то есть происходит серьезное переобучение. Введя методы оценки и визуализации на валидационном наборе, мы точно определили процесс эволюции модели от недообучения к оптимальному, а затем к переобучению. Итоговый эксперимент показывает, что выбор соответствующей сложности модели и ее сочетание с эффективной стандартизацией признаков является ключом к повышению точности и устойчивости задач классификации в инженерной практике. Методы исследования, использованные в этом эксперименте, закладывают техническую основу для классификации и обработки сложных сигналов в реальном времени.