

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №2

Обработка кардиологического датасета для решения задачи бинарной классификации

Салех Али(2) ИУ1И-41М

Москва 2026 г

1. Цель работы

Подготовить кардиологический датасет с числовыми параметрами ЭКГ, выполнить его предварительную обработку, исследовать структуру данных с помощью методов PCA и t-SNE, а затем реализовать автоматизированный выбор модели для бинарной классификации признака `Healthy_Status`.

Ссылка на Git-репозиторий: [<https://github.com/abomhiar590-cyber/ml-lab2.git>]

2. Постановка задачи

Для анализа использованы первые 5000 строк исходного датасета. Обучающая выборка сформирована из признаков `Count_subj`, `rr_interval`, `p_end`, `qrs_onset`, `qrs_end`, `p_axis`, `qrs_axis` и `t_axis`. Требовалось исследовать несколько моделей, выбрать лучшую по метрике F1, а затем построить матрицу ошибок и оценить итоговое качество классификации. Количественные результаты в отчёте согласованы с ноутбуком `lab2_cardiology_automl.ipynb`.

3. Подготовка данных

Распределение классов в выборке оказалось несбалансированным: класс 0 содержит 4040 наблюдений, а класс 1 — 960 наблюдений. Поэтому в качестве ключевой метрики качества использована F1-мера, так как она лучше отражает баланс между точностью и полнотой на несбалансированных данных.




Рисунок 1. Распределение классов Healthy_Status.

Часть числовых параметров ЭКГ содержала некорректные служебные значения, не попадающие в реалистичные диапазоны. Эти значения были заменены на NaN, а затем заполнены медианой в составе конвейера обучения. Такой способ позволяет сохранить данные и при этом убрать сильное влияние артефактов.

Таблица 1. Количество значений, заменённых на NaN после проверки диапазонов.

Признак	Диапазон	Количество замен
rr_interval	[300, 2000]	11
p_end	[0, 300]	1543
qrs_onset	[0, 600]	10
qrs_end	[0, 800]	10
p_axis	[-180, 180]	911
qrs_axis	[-180, 180]	33
t_axis	[-180, 180]	69

4. PCA и t-SNE

После стандартизации и импутации пропусков была построена PCA-проекция. Первая главная компонента объясняет 25.54% дисперсии, вторая — 15.37%. Суммарно две компоненты описывают 40.91% изменчивости признакового пространства.




Рисунок 2. PCA-проекция объектов по двум главным компонентам.

Для нелинейной визуализации дополнительно использован алгоритм t-SNE. Для ускорения расчётов в ноутбуке используется случайная подвыборка из 50 строк. В коде предусмотрена совместимость с разными версиями scikit-learn: при необходимости используется параметр `n_iter` или `max_iter`.




Рисунок 3. t-SNE-проекция на подвыборке из 50 наблюдений.

5. Исследование AutoML-подхода

Под AutoML в данной лабораторной работе понимается автоматизированное сравнение нескольких классификаторов по единой схеме: одинаковая подготовка данных, одинаковая 5-fold stratified cross-validation и выбор лучшей модели по целевой метрике F1.

Таблица 2. Результаты сравнения моделей.

Модель	CV F1	Accuracy	Precision	Recall	F1
RandomForest	0.599	0.860	0.646	0.599	0.622
SVC (RBF)	0.592	0.740	0.421	0.943	0.582
GaussianNB	0.573	0.719	0.400	0.922	0.557
KNN (k=11)	0.487	0.828	0.557	0.510	0.533
LogisticRegression	0.143	0.807	0.488	0.104	0.172

Лучшей моделью по среднему значению CV F1 стала RandomForest. В ноутбуке эта модель задаётся как RandomForestClassifier с параметрами n_estimators=250, random_state=42 и class_weight='balanced'. Она была выбрана для финальной оценки на тестовой выборке.




Рисунок 4. Сравнение моделей по среднему значению CV F1.

6. Итоговая оценка лучшей модели

После повторного обучения лучшей модели (RandomForest) на обучающей части были получены следующие результаты на тестовой выборке: Accuracy = 0.8600, Precision = 0.6461, Recall = 0.5990, F1 = 0.6216.

Accuracy	Precision	Recall	F1
0.8600	0.6461	0.5990	0.6216

Матрица ошибок лучшей модели: TN = 745, FP = 63, FN = 77, TP = 115. Это означает, что модель в целом уверенно распознаёт оба класса, хотя часть объектов класса 1 всё ещё ошибочно относится к классу 0.




Рисунок 5. Матрица ошибок лучшей модели.

7. Вывод

В ходе лабораторной работы был полностью реализован цикл анализа кардиологического датасета: от очистки числовых признаков ЭКГ до визуализации структуры данных и выбора лучшего классификатора. Для снижения размерности применены PCA и t-SNE, а в рамках упрощённого AutoML-подхода проведено сравнение нескольких моделей машинного обучения.

Наилучший результат показала модель RandomForest. На тестовой выборке она достигла значения $F1 = 0.6216$, что подтверждает пригодность выбранного подхода для задачи бинарной классификации признака Healthy_Status на основе числовых параметров ЭКГ.