Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЁТ
Задание №2

Дисциплина: 《Эргатические системы》

Студент Чэнь Цзяхэ
фамилия, имя, отчество

Группа ИУ1И-41М

Преподаватель 01/04/2026 А.С. Кучин
(Подпись, дата) (И.О. Фамили

2026

1. Цель работы

Обработать кардиологический датасет для решения задачи бинарной классификации. Освоить подготовку данных, применение методов снижения размерности PCA и t-SNE, а также использование AutoML для автоматического выбора и оценки моделей.

2. Теоретические сведения

1. Метод PCA представляет собой линейный подход снижения размерности, который сохраняет максимальную дисперсию исходных данных при переходе к новому пространству признаков.
2. Метод t-SNE относится к нелинейным методам визуализации, он сохраняет локальную структуру данных и позволяет наглядно представить разделение классов.
3. Технология AutoML обеспечивает автоматический подбор, обучение и сравнение различных моделей машинного обучения с целью выбора оптимального варианта для конкретной задачи классификации.

3. Результаты экспериментов

3.1 Описание датасета

Датасет загружен из репозитория, всего было взято 5000 строк. Для обучения использовались столбцы с параметрами ЭКГ: ['Count_subj', 'rr_interval', 'p_end', 'qrs_onset', 'qrs_end', 'p_axis', 'qrs_axis', 't_axis'] и целевым признаком Healthy_Status. Целевая переменная имеет два класса: класс 0 представлен 4040 образцами, класс 1 — 960 образцами. Выборка была разделена на обучающую (4000 строк) и тестовую (1000 строк) части.

3.2 Визуализация данных с использованием методов снижения размерности

При применении метода PCA были получены две главные компоненты. Первая компонента объясняет 47,15% дисперсии, вторая — 20,77%, а общая объяснённая дисперсия составляет 67,92%. Визуализация по первым двум компонентам показала общую структуру данных и возможность разделения классов.

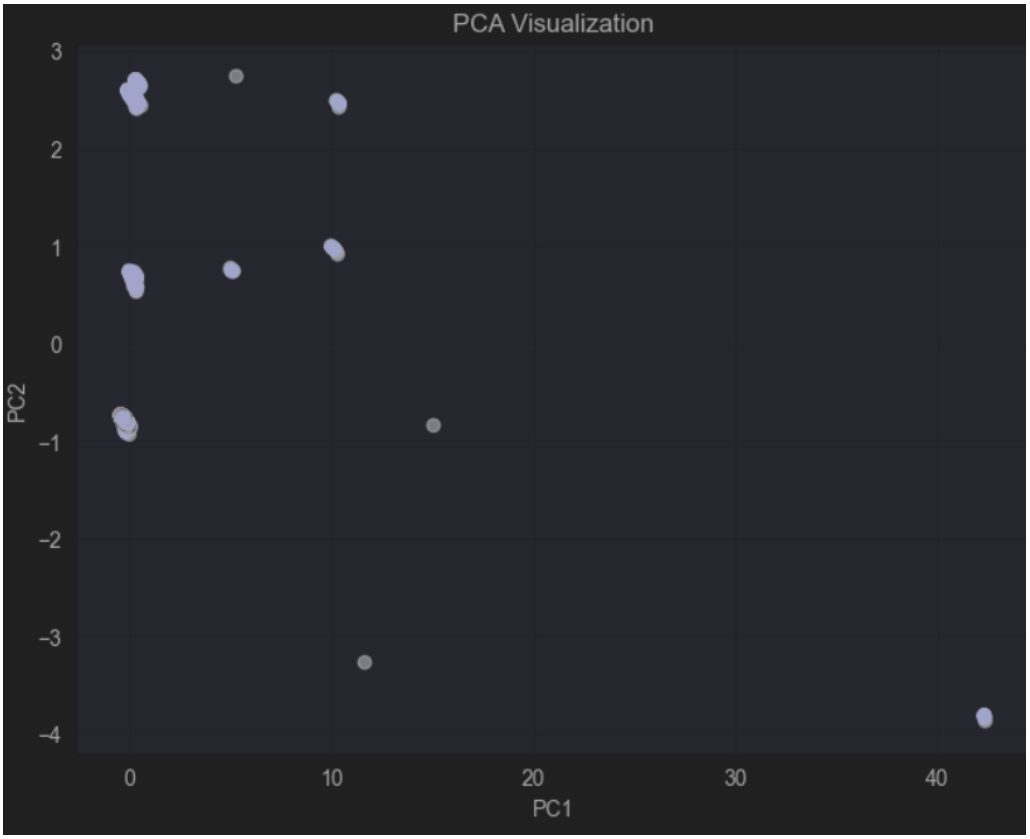

Метод t-SNE обеспечил более чёткое представление локальных структур данных. На полученной визуализации видны группы, соответствующие разным значениям целевой переменной, что подтверждает наличие разделимости между классами.

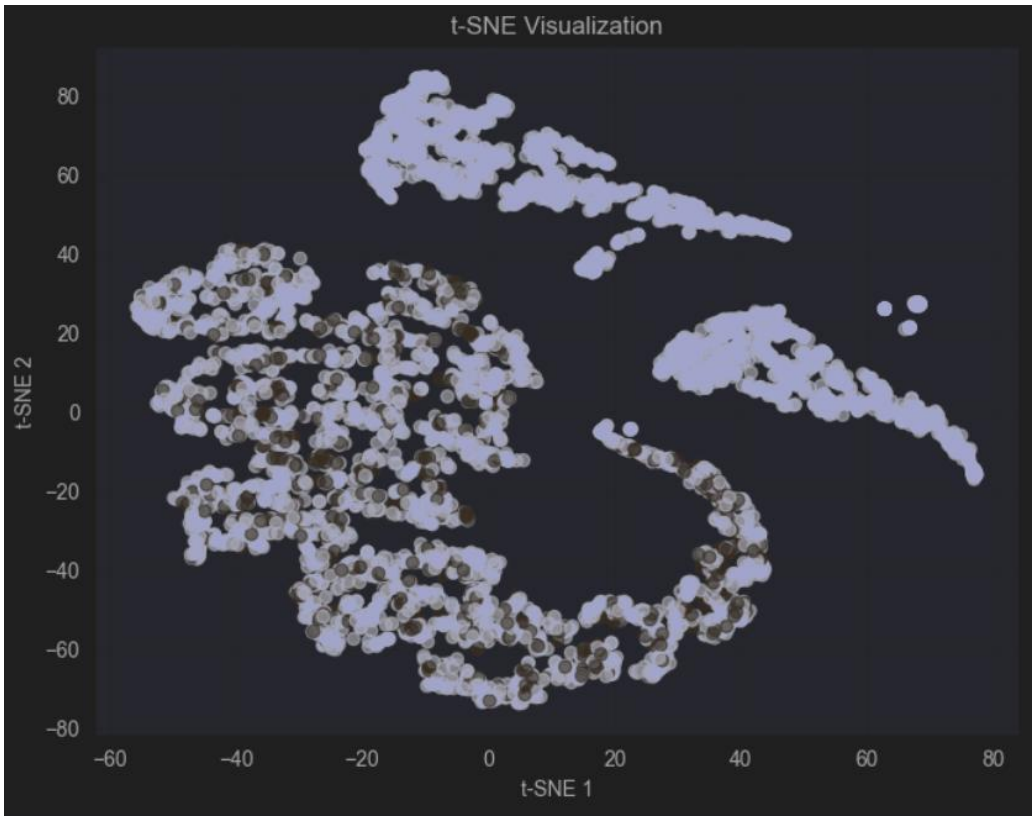

3.3 Обучение и сравнение моделей с использованием AutoML

В рамках эксперимента были протестированы несколько моделей машинного обучения. Результаты оценки представлены в таблице.

Модель	Точность	F1-score
Gradient Boosting	0.856	0.636
Random Forest	0.859	0.628
Extra Trees	0.857	0.590
KNN	0.783	0.399
Logistic Regression	0.806	0.000
SVM	0.808	0.000

На основе совокупности метрик лучшей моделью выбран Gradient Boosting.

3.4 Матрица ошибок и итоговые метрики

Матрица ошибок лучшей модели иллюстрирует количество верно и ошибочно классифицированных объектов для каждого класса. Модель корректно определяет большинство образцов доминирующего класса и показывает удовлетворительное качество распознавания второго класса.

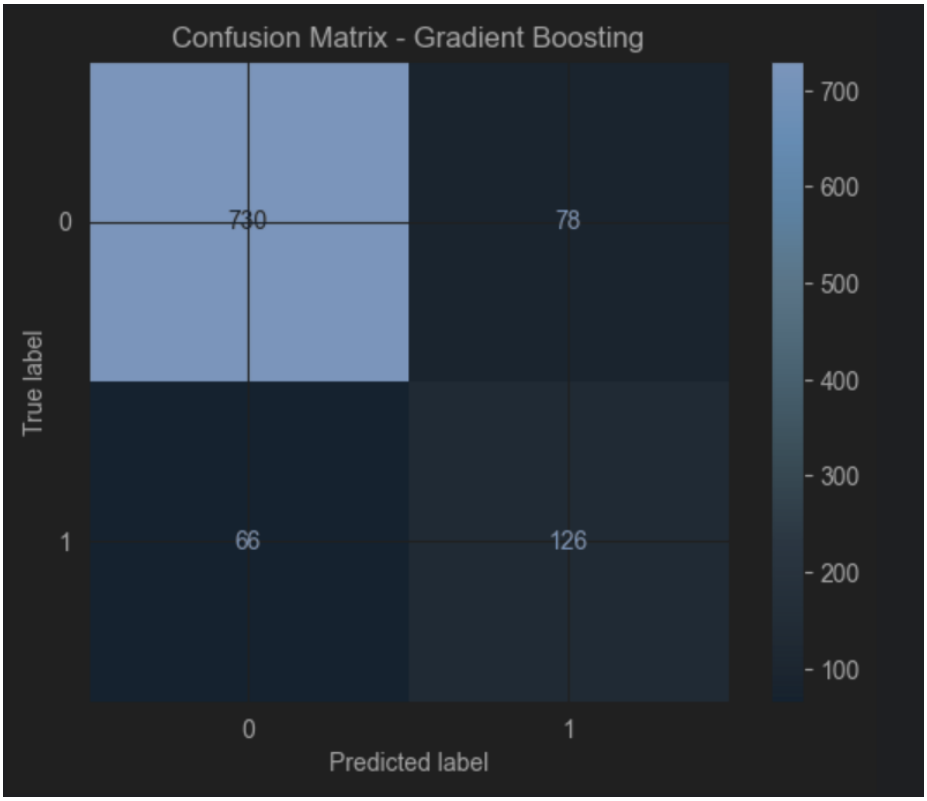

Итоговая точность модели на тестовой выборке составляет 0.86, а F1-score для целевого класса равен 0.636. Полученные значения свидетельствуют о работоспособности построенной модели и адекватности выбранного подхода.

4. Выводы

В ходе работы выполнена обработка кардиологического датасета и решена задача бинарной классификации. Методы PCA и t-SNE позволили визуализировать структуру данных и оценить разделимость классов. Применение AutoML позволило автоматически выбрать лучшую модель – Gradient Boosting. Итоговые метрики подтверждают эффективность построенной модели и корректность используемых подходов.