



Министерство науки и высшего образования Российской Федерации  
Федеральное государственное бюджетное образовательное учреждение  
высшего образования  
«Московский государственный технический университет  
имени Н.Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н.Э. Баумана)

---

ФАКУЛЬТЕТ

Информатика и системы управления

---

КАФЕДРА

Системы автоматического управления

---

**ОТЧЁТ**  
**Задание №2**

**Дисциплина: «Эргатические системы»**

Студент ИУ1И-41М

---

Дун Боян

---

преподаватель

А. С. Кучин

---

2026 г.

## 1. Цель и постановка задачи

Цель лабораторной работы - обработать кардиологический датасет и построить модель бинарной классификации по признаку `Healthy_Status` на основе числовых параметров ЭКГ.

Согласно заданию необходимо выполнить следующие действия:

1. загрузить 5000 строк из датасета, указанного в задании;
2. сформировать обучающую выборку из столбцов `Count_subj`, `rr_interval`, `p_end`, `qrs_onset`, `qrs_end`, `p_axis`, `qrs_axis`, `t_axis` и целевого признака `Healthy_Status`;
3. подготовить данные, так как датасет состоит из числовых параметров ЭКГ и классификационного признака;
4. исследовать AutoML-фреймворки, выбрать подходящий инструмент и применить его для бинарной классификации;
5. построить confusion matrix и рассчитать F1-метрику для оценки классификатора.

## 2. Исходные данные и используемые признаки

В предоставленном коде данные загружаются из CSV-файла по прямой ссылке на GitHub. Загружаются первые 5000 строк, после чего из исходной таблицы выбираются только признаки, указанные в задании.

| Тип                  | Столбцы                                                                                                                                                                                     |
|----------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Признаки X           | <code>Count_subj</code> , <code>rr_interval</code> , <code>p_end</code> , <code>qrs_onset</code> , <code>qrs_end</code> , <code>p_axis</code> , <code>qrs_axis</code> , <code>t_axis</code> |
| Целевой признак<br>у | <code>Healthy_Status</code>                                                                                                                                                                 |
| Тип задачи           | Бинарная классификация                                                                                                                                                                      |

После загрузки исходная таблица имеет размер 5000 x 36. После выбора нужных столбцов размер рабочей таблицы составляет 5000 x 9. В ходе очистки были удалены 2 дублирующие строки, поэтому итоговый набор данных содержит 4998 наблюдений.

### 3. Анализ предоставленного кода

Код оформлен как одна ячейка Jupyter Notebook и включает полный цикл работы: установку библиотек, загрузку данных, очистку, визуализацию, обучение AutoML-модели, подбор порога и оценку качества.

Основные этапы программы:

- Загрузка библиотек pandas, numpy, matplotlib, scikit-learn, imbalanced-learn и FLAML.
- Чтение 5000 строк CSV-файла и выбор требуемых столбцов.
- Преобразование признаков к числовому типу, удаление дублей и проверка пропусков.
- Кодирование целевой переменной Healthy\_Status с помощью LabelEncoder.
- Стратифицированное разбиение данных на обучающую и тестовую выборки в соотношении 80/20.
- Предобработка данных для визуализации: заполнение медианой, квантильное отсечение выбросов и стандартизация.
- Построение PCA и t-SNE для анализа структуры данных.
- Предобработка для модели: заполнение медианой и стандартизация.
- Дополнительное разбиение обучающей части на sub-train и validation, затем балансировка sub-train методом RandomOverSampler.
- Обучение AutoML-модели FLAML с оптимизацией по F1-score.
- Подбор порога классификации на validation-выборке и финальная оценка на test-выборке.

### 4. Предобработка и исследование данных

Проверка показала, что в выбранных столбцах нет пропущенных значений. Целевая переменная является бинарной: класс 0 содержит 4038 объектов, класс 1 содержит 960 объектов. Это означает, что данные несбалансированы, поэтому использование F1-score является более информативным, чем одна только ассурасу.

| Показатель      | Значение |
|-----------------|----------|
| Загружено строк | 5000     |


| Показатель                    | Значение                     |
|-------------------------------|------------------------------|
| Исходный размер таблицы       | 5000 x 36                    |
| Выбранный размер таблицы      | 5000 x 9                     |
| Удалено дублей                | 2                            |
| Итоговый размер после очистки | 4998 x 9                     |
| Пропущенные значения          | 0 во всех выбранных столбцах |
| Класс Healthy_Status = 0      | 4038                         |
| Класс Healthy_Status = 1      | 960                          |

В описательной статистике видны крупные значения 29999 и 32767 в отдельных столбцах. Они могут быть выбросами или специальными кодами датасета. В предоставленном коде для визуализации применяется квантильное отсечение, а для модели эти значения сохраняются, чтобы не потерять потенциально полезную информацию.

| Признак     | Среднее | Ст. откл. | Минимум | Медиана | Максимум |
|-------------|---------|-----------|---------|---------|----------|
| Count_subj  | 18.20   | 24.45     | 1       | 10      | 260      |
| rr_interval | 857.55  | 1183.12   | 0       | 800     | 29999    |
| p_end       | 9346.45 | 13783.73  | 48      | 158     | 29999    |
| qrs_onset   | 284.24  | 1118.38   | 0       | 200     | 29999    |
| qrs_end     | 389.23  | 1191.14   | 139     | 300     | 29999    |
| p_axis      | 5472.93 | 11585.18  | -180    | 57      | 32767    |
| qrs_axis    | 164.40  | 2116.48   | -178    | 12      | 29999    |
| t_axis      | 248.78  | 2484.83   | -180    | 45      | 32767    |


## 5. Визуальный анализ: PCA и t-SNE

Для визуального анализа данные предварительно были заполнены медианой, очищены от крайних квантилей и стандартизованы. Затем были построены двумерные проекции PCA и t-SNE.



*Рисунок 1 - PCA-визуализация признаков ЭКГ*

РСА показывает линейную проекцию признаков на две главные компоненты. На рисунке видно, что классы частично перекрываются, поэтому задача классификации не является тривиальной при использовании только линейного разделения.



*Рисунок 2 - t-SNE-визуализация признаков ЭКГ*

t-SNE позволяет оценить локальную структуру данных. На визуализации также наблюдается смешение классов, однако присутствуют отдельные области,

где один класс встречается чаще. Это подтверждает необходимость применения нелинейных моделей.

## 6. Выбор и применение AutoML

В качестве AutoML-инструмента в коде выбран FLAML. Такой выбор является обоснованным для учебной задачи, потому что FLAML позволяет быстро перебрать несколько моделей и гиперпараметров в рамках заданного временного бюджета, поддерживает задачу классификации и может напрямую оптимизировать F1-score.

| Критерий            | Обоснование выбора FLAML                                                                                       |
|---------------------|----------------------------------------------------------------------------------------------------------------|
| Скорость            | Работает в заданном <code>time_budget</code> и подходит для небольшого набора данных.                          |
| Простота интеграции | Используется через объект AutoML и совместим с массивами после <code>scikit-learn preprocessing</code> .       |
| Метрика             | В настройках указана <code>metric = "f1"</code> , что соответствует несбалансированной бинарной классификации. |
| Результат           | Лучшим алгоритмом по результатам запуска стал LGBM.                                                            |

Для борьбы с дисбалансом классов код применяет `RandomOverSampler` только на `sub-train`-выборке. Это корректно, так как тестовые данные не используются при балансировке и остаются независимыми для финальной проверки.

После балансировки `sub-train`-выборка имеет равное количество объектов обоих классов: 2584 объекта класса 0 и 2584 объекта класса 1. Далее AutoML обучается с 5-кратной кросс-валидацией и оптимизацией F1-score.

## 7. Результаты обучения и оценки качества

По результатам AutoML лучшей моделью стала LGBM. На validation-выборке был выполнен подбор порога классификации от 0.20 до 0.80. Лучший порог составил 0.20, при котором validation F1-score равен 0.6220.

| Порог | Precision | Recall | F1     |
|-------|-----------|--------|--------|
| 0.20  | 0.5862    | 0.6623 | 0.6220 |
| 0.25  | 0.5833    | 0.6364 | 0.6087 |
| 0.30  | 0.5949    | 0.6104 | 0.6026 |
| 0.35  | 0.5882    | 0.5844 | 0.5863 |
| 0.40  | 0.5867    | 0.5714 | 0.5789 |
| 0.50  | 0.5986    | 0.5519 | 0.5743 |
| 0.80  | 0.5923    | 0.5000 | 0.5423 |

На тестовой выборке итоговые метрики составили:

| Метрика                | Значение |
|------------------------|----------|
| Accuracy               | 0.8530   |
| Precision для класса 1 | 0.5991   |
| Recall для класса 1    | 0.7083   |
| F1-score для класса 1  | 0.6492   |
| Macro avg F1-score     | 0.7781   |
| Weighted avg F1-score  | 0.8575   |




Рисунок 3 - Матрица ошибок на тестовой выборке

Матрица ошибок соответствует следующим значениям:  $TN = 717$ ,  $FP = 91$ ,  $FN = 56$ ,  $TP = 136$ . Модель правильно определила 717 объектов класса 0 и 136 объектов класса 1. Ошибочно к классу 1 отнесены 91 объекта класса 0, а 56 объектов класса 1 были пропущены.

| Фактический класс / Предсказанный класс | 0   | 1   |
|-----------------------------------------|-----|-----|
| 0                                       | 717 | 91  |
| 1                                       | 56  | 136 |

## 8. Обсуждение результатов

Полученная ассигасу равна 0.8530, однако из-за дисбаланса классов основное внимание следует уделять F1-score для класса 1. Значение  $F1\text{-score} = 0.6492$  показывает, что модель обнаруживает положительный класс лучше случайного классификатора, но качество еще можно улучшить.

Снижение порога до 0.20 увеличило recall положительного класса до 0.7083. Это полезно в медицинских задачах, где пропуск потенциально важного случая может быть более критичным, чем дополнительная ложная тревога. При этом



precision класса 1 равен 0.5991, то есть часть положительных предсказаний остается ложной.

Главное ограничение эксперимента связано с возможными выбросами или специальными значениями 29999 и 32767. Для повышения качества модели в дальнейшем можно отдельно исследовать природу этих значений, заменить их на пропуски при необходимости, добавить более строгую обработку выбросов и сравнить несколько стратегий балансировки классов.

## 9. Проверка выполнения требований задания

| Требование задания                        | Выполнение в коде | Комментарий                                                                                 |
|-------------------------------------------|-------------------|---------------------------------------------------------------------------------------------|
| Загрузить 5000 строк датасета             | Выполнено         | <code>pd.read_csv(DATA_URL, nrows=5000)</code> . После удаления дублей осталось 4998 строк. |
| Сформировать выборку из заданных столбцов | Выполнено         | Список FEATURES и TARGET полностью соответствует заданию.                                   |
| Подготовить числовые параметры ЭКГ        | Выполнено         | Признаки преобразованы к numeric, пропуски обрабатываются медианной импутацией.             |
| Применить PCA и t-SNE                     | Выполнено         | Построены и сохранены <code>pca.png</code> и <code>tsne.png</code> .                        |
| Исследовать и применить AutoML            | Выполнено         | Использован FLAML AutoML, лучшая модель - LGBM.                                             |
| Построить confusion matrix                | Выполнено         | Построена матрица ошибок и сохранена <code>confusion_matrix.png</code> .                    |
| Рассчитать F1-метрику                     | Выполнено         | Итоговый F1-score для класса 1 равен 0.6492.                                                |

## 10. Вывод

В ходе лабораторной работы была выполнена обработка кардиологического датасета для задачи бинарной классификации `Healthy_Status`. Данные были очищены, проверены на пропуски и разделены на обучающую, валидационную и тестовую части. Для анализа структуры данных построены PCA и t-SNE визуализации.

Для классификации применен AutoML-фреймворк FLAML. Лучшим алгоритмом стал LGBM. С учетом несбалансированности классов была выполнена балансировка обучающей выборки и подобран порог классификации. На тестовой выборке достигнуты  $\text{accuracy} = 0.8530$  и  $\text{F1-score} = 0.6492$  для положительного класса `Healthy_Status = 1`.

Таким образом, все основные требования задания выполнены. Модель демонстрирует приемлемое качество для базового эксперимента, но дальнейшее улучшение возможно за счет более детальной обработки выбросов, дополнительной настройки моделей и анализа признаков ЭКГ.