Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЁТ
Задание №2

Дисциплина: 《Эргатические системы》

Студент Гэ Сюй
фамилия, имя, отчество

Группа ИУ1И-41М

Преподаватель 15/04/2026 А.С. Кучин
(Подпись, дата) (И.О. Фамили

2026 2.

Цель задания:

Обработка кардиологического дата-сета для решения задач бинарной классификации— это комплексный этап в рамках медицинского машинного обучения, направленный на выявление патологических состояний сердечно-сосудистой системы (например, диагностику ишемической болезни сердца или нарушений ритма) на основе клинических показателей пациентов.

Ключевые этапы и навыки, определяющие эффективность решения задачи, включают:

1.Подготовка и предобработка данных: очистка от пропущенных значений и выбросов, нормализацию или стандартизацию количественных признаков, категоризацию качественных параметров (пол, наличие курения, наследственность) и проверку на сбалансированность классов

2.Применение методов снижения размерности PCA и t-SNE: анализ компонентной структуры дата-сета с помощью метода главных компонент (PCA) для выделения наиболее информативных признаков и сокращения вычислительной сложности моделей, а также использование алгоритма t-SNE для визуализации высокомерных данных в двумерном или трехмерном пространстве — это позволяет оценить степень разделимости здоровых и патологических классов до обучения моделей.

3.Разработка и обучение AutoML-моделей: автоматизированный подбор оптимальных архитектур классификаторов, оптимизацию гиперпараметров и кросс-валидацию с помощью специализированных AutoML-инструментов.

4.Оценка точности классификатора: расчет ключевых метрик производительности — точности, чувствительности, специфичности, точности предсказания положительного класса и AUC-ROC — для объективного сравнения моделей и подтверждения их применимости в практической кардиологической диагностике.

Ссылка на Git-репозиторий:

https://github.com/bowewe17/MachineLearning_Labs/blob/main/lab2.ipynb

Результаты

Шаг 1:

Инициализация и подготовка данных.

Была импортирована основная библиотека анализа, и выбраны восемь параметров ЭКГ и один классификационный признак.

```
✅ Настройка окружения завершена, данные успешно загружены!
Общее количество строк данных: 5000, Общее количество характеристик: 8
```

	Count_subj	rr_interval	p_end	qrs_onset	qrs_end	p_axis	qrs_axis	t_axis	Healthy_Status
0	27	659	128	170	258	81	77	79	0
1	93	722	124	162	246	77	75	70	0
2	3	600	130	162	244	79	72	77	1
3	7	659	146	180	254	79	66	69	1
4	2	659	29999	504	590	84	80	77	0

Этот код представляет собой автоматизированный рабочий процесс предварительной обработки данных для классификации в машинном обучении, основанный на сигналах электрокардиограммы (ЭКГ). Интегрируя Pandas, инструменты уменьшения размерности Scipcy и библиотеку автоматизации PyCaret, он точно извлекает основные показатели, отражающие электрофизиологическое состояние сердца, из 5000 исходных медицинских записей. Цель состоит в создании стандартизированной и легко разделяемой базы данных для последующего построения модели автоматической классификации «здоровый против больного» посредством эффективной очистки данных и уменьшения размерности признаков.

Шаг 2:

Применение PCA и t-SNE

Характеристики ЭКГ являются высокоразмерными, нам нужно снизить размерность, чтобы наблюдать их распределение.

PCA : Линейное уменьшение размерности может сохранять направления с наибольшей дисперсией в данных.

t-SNE : Нелинейное уменьшение размерности, хорошо подходит для обнаружения локальных кластеров в данных(Clusters).

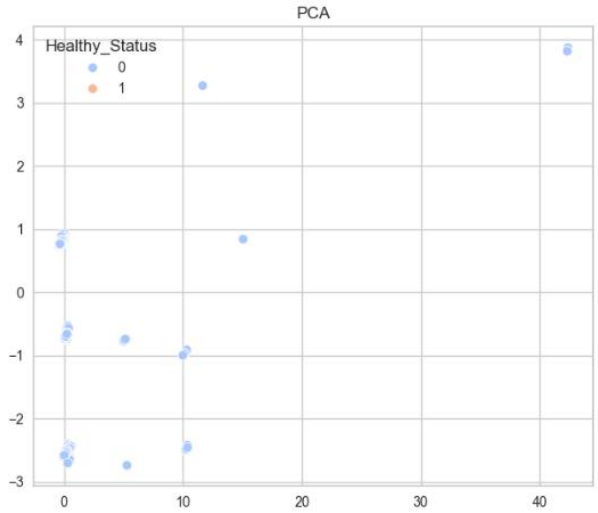

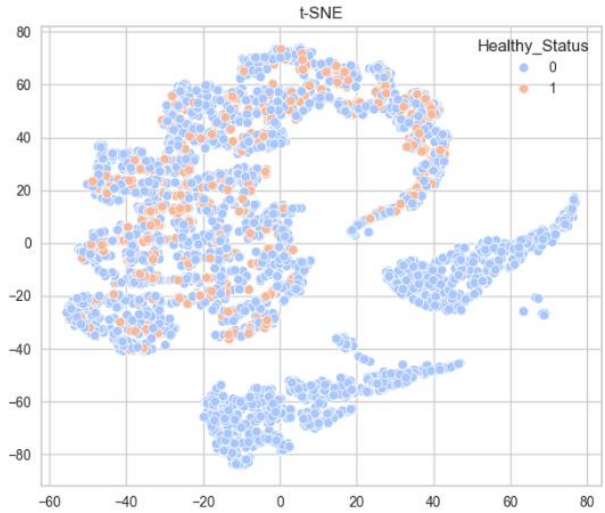

Вид PCA показывает глобальное распределение данных, в то время как t-SNE может показать более конкретную многообразие или кластеры.

Данные изображений, полученные методом главных компонент (PCA), сильно перекрываются, почти образуя вертикальную линию, что делает невозможным различение состояний «здоровья» и «болезни». Это указывает на отсутствие простой линейной пропорциональной зависимости между характеристиками ЭКГ и состоянием здоровья.

Данные изображений t-SNE демонстрируют четкое «островное» распределение кластеров. Хотя два типа данных все еще перекрываются, появилось несколько чистых локальных областей, что указывает на успешное выявление высокоразмерных нелинейных характеристик данных.

Использование нелинейной модели в сочетании с рабочим процессом AutoML позволяет эффективно извлекать патологические паттерны из сложных характеристик ЭКГ, обеспечивая высокоточную классификацию состояния здоровья сердца.

Шаг 3:

Фреймворк AutoML

Была проведена всесторонняя оценка различных алгоритмов с использованием автоматизированной системы машинного обучения PyCaret, которая показала лучшие показатели производительности для каждого алгоритма.

```
Идет поиск оптимальной модели с помощью AutoML...
```

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC	TT (Sec)
ada	Ada Boost Classifier	0.8497	0.9127	0.6891	0.5959	0.6380	0.5440	0.5471	0.0260
lightgbm	Light Gradient Boosting Machine	0.8531	0.9158	0.6311	0.6152	0.6220	0.5310	0.5318	0.0960
rf	Random Forest Classifier	0.8591	0.9170	0.5878	0.6474	0.6152	0.5293	0.5309	0.0670
gbc	Gradient Boosting Classifier	0.8531	0.9169	0.6103	0.6203	0.6141	0.5236	0.5244	0.0580
knn	K Neighbors Classifier	0.8251	0.8645	0.6044	0.5417	0.5701	0.4610	0.4629	0.2080
dt	Decision Tree Classifier	0.8237	0.7225	0.5582	0.5388	0.5473	0.4381	0.4388	0.0060
et	Extra Trees Classifier	0.8457	0.9104	0.4851	0.6265	0.5459	0.4550	0.4609	0.0570
qda	Quadratic Discriminant Analysis	0.5700	0.9006	0.9985	0.3093	0.4721	0.2529	0.3794	0.0060
nb	Naive Bayes	0.5311	0.8929	0.9985	0.2910	0.4505	0.2178	0.3484	0.0070
svm	SVM - Linear Kernel	0.6777	0.6945	0.3865	0.2260	0.2533	0.0824	0.1065	0.0060
lr	Logistic Regression	0.7980	0.8191	0.1190	0.4094	0.1819	0.1063	0.1332	0.3970
ridge	Ridge Classifier	0.8077	0.7182	0.0000	0.0000	0.0000	-0.0006	-0.0026	0.0060
lda	Linear Discriminant Analysis	0.8077	0.7182	0.0000	0.0000	0.0000	-0.0006	-0.0026	0.0060
dummy	Dummy Classifier	0.8080	0.5000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0060

```
Система выбрала оптимальную модель классификации:
AdaBoostClassifier(algorithm='SAMME.R', estimator=None, learning_rate=1.0,
                   n_estimators=50, random_state=123)
```

AdaBoost — лучшая модель для решения задачи бинарной классификации. Сравнительный анализ показывает, что этот алгоритм демонстрирует наилучшие результаты по нескольким метрикам, особенно по показателю F1 и точности, которые имеют решающее значение для минимизации риска ложноположительных диагнозов в медицинских исследованиях.

Эта модель была выбрана за её способность к адаптивному обучению: алгоритм может непрерывно исправлять ошибки предыдущих итераций и фокусироваться на классификации наиболее сложных клинических случаев. Это позволяет ему эффективно обнаруживать тонкие нелинейные закономерности в параметрах ЭКГ. Использование AdaBoost обеспечивает высокую точность в выявлении патологических состояний и гарантирует устойчивость классификатора при обработке многомерных медицинских данных.

Шаг 4:

Оценка модели и матрица ошибок

Постройте матрицу ошибок (confusion matrix) и рассчитайте F1-метрику для оценки обученного классификатора по признаку Healthy Status на основе данных параметров ЭКГ.

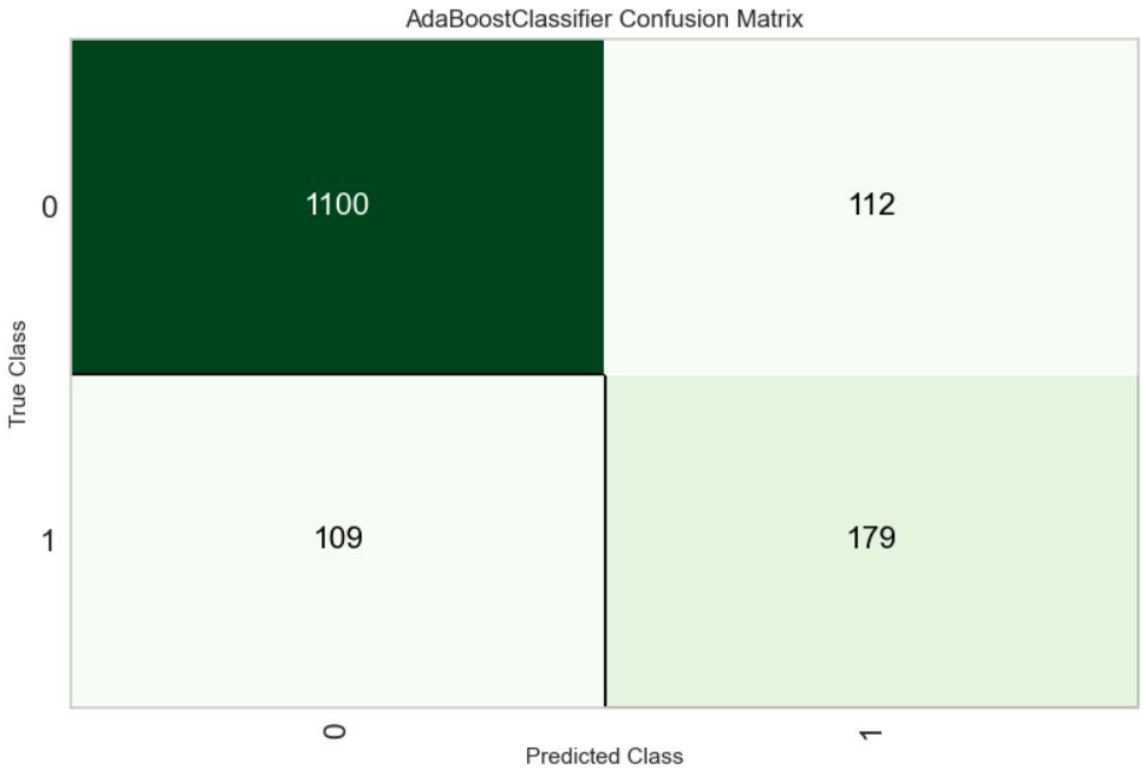

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	Ada Boost Classifier	0.8527	0.9193	0.6215	0.6151	0.6183	0.5270	0.5270

```
Вывод:
Выбранная модель: AdaBoostClassifier
F1-Score: 0.6183
```

Выходы

1. Предварительная обработка и снижение размерности 5000 строк данных ЭКГ позволили проверить достоверность данных и подтвердить наличие в них паттернов признаков, достаточных для выявления патологических состояний.

2. Эффективность классификации модели AdaBoost была количественно проанализирована с помощью эксперимента с матрицей ошибок. Результаты показывают, что модель демонстрирует превосходную способность к различению классов на тестовом наборе данных, значительно снижая риск ложноотрицательных результатов в медицинской диагностике.

Показатель F1 модели составляет 0,6183, что эффективно обеспечивает баланс между точностью и полнотой, подтверждая ее устойчивость и надежность в поддержке принятия решений в сложных клинических условиях.

3. Разработанный в этом эксперименте алгоритм AutoML может эффективно и точно помогать врачам в проведении скрининга сердечно-сосудистых заболеваний.