Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

Эргатические Системы

Лабораторная работа №2

Бинарная классификация ЭКГ-параметров с использованием методов снижения размерности и AutoML

Студент Канаан Хусейн

Группа ИУ1И-41М

Преподаватель А.С. Кучин

2026 г

Введение

Целью работы являлась подготовка и анализ набора данных электрокардиографических параметров, а также построение модели бинарной классификации для переменной Healthy_Status. В рамках работы использовались методы предварительной обработки данных, стандартизации признаков, снижения размерности (PCA, t-SNE) и автоматического выбора модели машинного обучения.

Исходный набор данных был загружен из предоставленного CSV-файла. Для дальнейшего анализа были отобраны первые 5000 наблюдений и следующие признаки: Count_subj, rr_interval, p_end, qrs_onset, qrs_end, p_axis, qrs_axis, t_axis и целевая переменная Healthy_Status.

Подготовка данных

На первом этапе была выполнена проверка структуры данных и полноты наблюдений. Формально пропуски отсутствовали, однако описательная статистика показала наличие специальных кодированных значений, не являющихся физиологически интерпретируемыми измерениями. В частности, в ряде столбцов встречались значения 29999 и 32767.

Указанные значения были интерпретированы как технические маркеры некорректных или отсутствующих измерений. После замены этих кодов на NaN и удаления неполных строк размер выборки уменьшился с 5000 до 3448 наблюдений. Далее целевой признак был отделен от матрицы признаков, а сами признаки стандартизированы методом StandardScaler. Полученная матрица признаков была использована для визуализации и построения моделей.

Основные результаты предварительной обработки

Показатель	Значение
Исходный объем данных	5000 наблюдений
Объем после очистки	3448 наблюдений
Число признаков	8
Распределение классов до очистки	0: 4040; 1: 960
Разбиение train/test	2758 / 690

Таблица 1 - Ключевые характеристики выборки после подготовки данных

Снижение размерности и визуальный анализ

После стандартизации признаков были применены методы PCA и t-SNE. Метод главных компонент использовался для линейного отображения структуры набора данных в пространстве меньшей размерности, а t-SNE - для нелинейной визуализации локальной структуры наблюдений.

Полученные двумерные представления подтвердили, что классы частично пересекаются, однако между ними присутствует различимая структура. Это позволяет ожидать приемлемое качество классификации при использовании как классических моделей, так и средств автоматизированного подбора алгоритмов.

Построение базовой модели

В качестве базовой модели был обучен классификатор Random Forest. Выбор данной модели обусловлен ее устойчивостью к нелинейным зависимостям и способностью работать с неоднородными признаками. Для оценки качества использовались accuracy, F1-мера и матрица ошибок.

На тестовой выборке базовая модель показала accuracy = 0.80 и F1 = 0.601. Матрица ошибок имела вид: TN = 448, FP = 50, FN = 88, TP = 104. Полученный результат можно считать удовлетворительным, однако число ложно

отрицательных ответов остается заметным, что ухудшает обнаружение положительного класса.

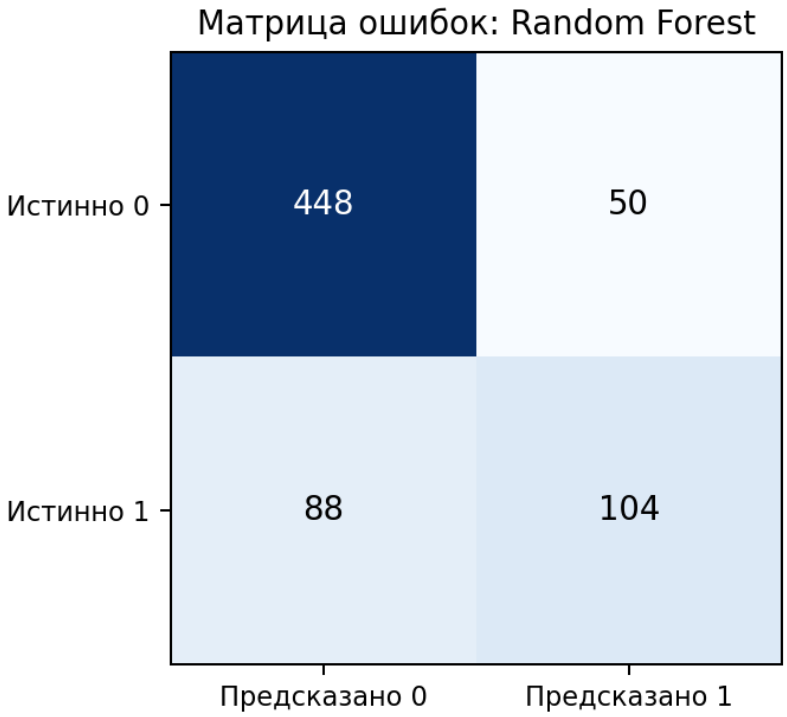

Рисунок 1 - Матрица ошибок базовой модели Random Forest

Применение AutoML

Для выполнения требования задания был рассмотрен подход AutoML. В качестве рабочего фреймворка выбран PyCaret, поскольку он удобен для использования в Jupyter Notebook, поддерживает бинарную классификацию и позволяет быстро сравнить несколько моделей по единым метрикам качества.

По результатам автоматического сравнения моделей наилучший результат по F1-мере показала модель Quadratic Discriminant Analysis (QDA). Данный результат представляет практический интерес, поскольку AutoML выбрал не ансамблевый алгоритм, а более компактную статистическую модель, лучше согласующуюся со структурой подготовленных данных.

Сравнение лучших моделей AutoML

Модель	Accuracy	Recall	Precision	F1
QDA	0.7826	0.8333	0.5755	0.6809
Naive Bayes	0.7492	0.7692	0.5377	0.6319
AdaBoost	0.7627	0.6258	0.5671	0.5944
Gradient Boosting	0.7746	0.5827	0.5990	0.5895

Таблица 2 - Лучшие модели по результатам сравнения в PyCaret

Для выбранной модели QDA на тестовой выборке была получена матрица ошибок: TN = 380, FP = 118, FN = 32, TP = 160. По сравнению с базовой моделью Random Forest число ложно отрицательных классификаций существенно сократилось (с 88 до 32), а число верно обнаруженных положительных объектов увеличилось (со 104 до 160).

Таким образом, модель QDA обеспечивает более высокую чувствительность к положительному классу. Недостатком является увеличение числа ложноположительных ответов, однако в рассматриваемой задаче такой компромисс можно считать допустимым, если приоритетом является снижение пропуска положительных случаев.

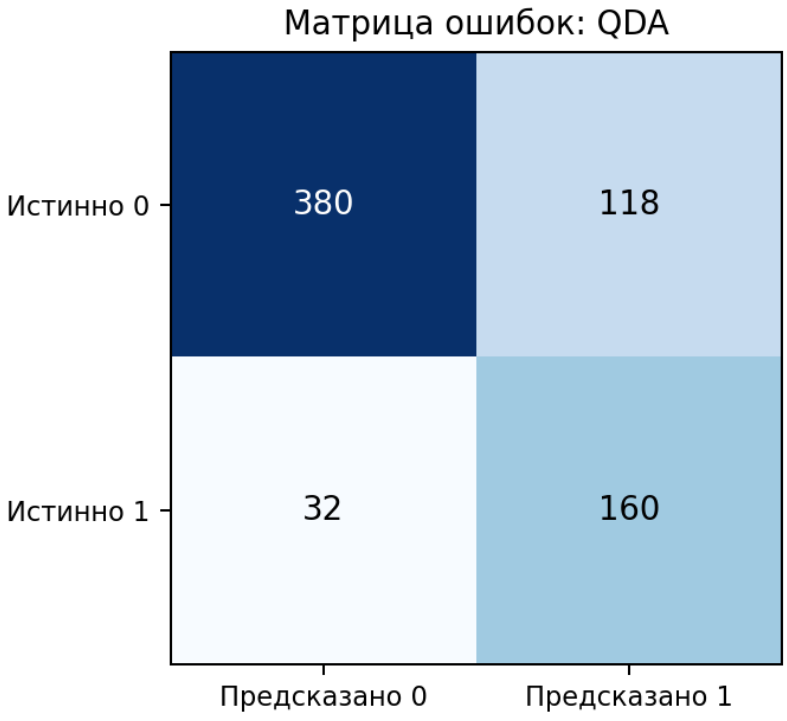

Рисунок 2 - Матрица ошибок модели QDA, выбранной AutoML

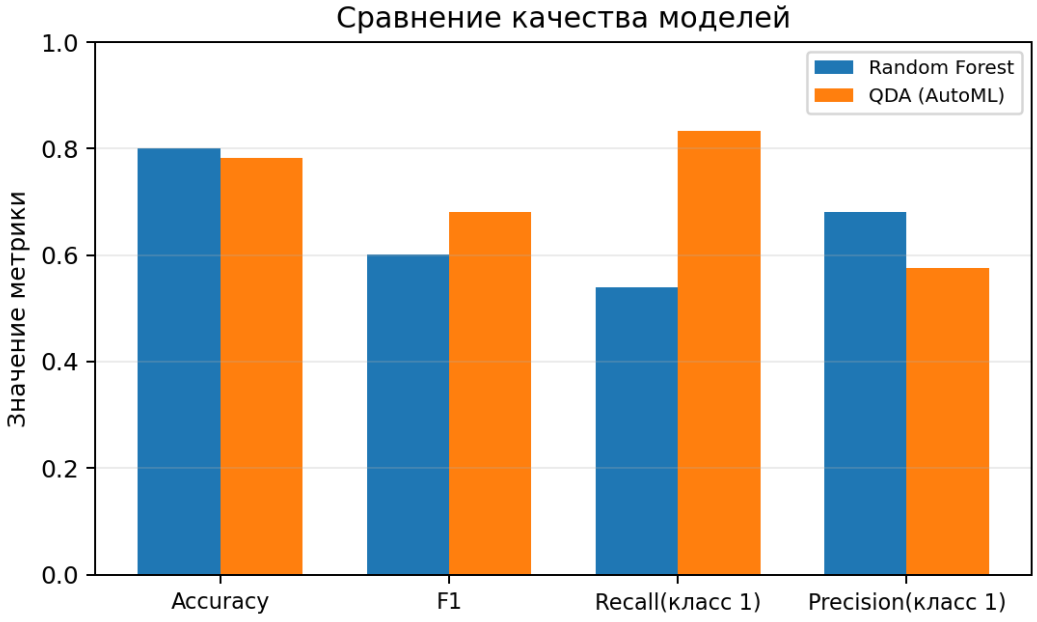

Рисунок 3 - Сравнение качества базовой модели и модели, выбранной AutoML

Заключение

В ходе работы была выполнена подготовка набора данных ЭКГ для задачи бинарной классификации, включающая отбор признаков, очистку кодированных невалидных значений и стандартизацию. Для анализа структуры данных были применены методы PCA и t-SNE. На основе подготовленной выборки были построены базовая модель Random Forest и модель, полученная с помощью AutoML.

Сравнение результатов показало, что использование AutoML оказалось оправданным. Фреймворк PyCaret выбрал модель Quadratic Discriminant Analysis, которая продемонстрировала более высокую F1-меру и значительно лучшее обнаружение положительного класса по сравнению с базовой моделью. Следовательно, поставленная в работе цель достигнута, а все основные требования задания выполнены.