Лабораторная работа №2

Бинарная классификация кардиологических данных ЭКГ

Выполнил: *Ли Юй*
Группа: *ИУ1И-41М*

Цель работы

Освоить обработку кардиологического датасета для решения задачи бинарной классификации, применить методы снижения размерности (PCA, t-SNE) для визуализации данных, исследовать фреймворки AutoML и выбрать лучший для обучения классификатора.

Ключевые навыки:

- Подготовка данных (загрузка, очистка, нормализация)
- Визуальный анализ с применением PCA и t-SNE
- Исследование и обоснование выбора AutoML-фреймворка
- Обучение бинарного классификатора через AutoML
- Оценка качества: матрица ошибок (Confusion Matrix) и F1-метрика

Теоретическая разминка

1. Что такое PCA и зачем он нужен?

Метод главных компонент (Principal Component Analysis, PCA) — это линейный метод снижения размерности. Он находит новые оси (главные компоненты), направленные вдоль направлений наибольшей дисперсии данных, и проецирует данные на пространство меньшей размерности. PCA применяется для:

- **Визуализации** многомерных данных (проекция на 2D/3D)
- **Уменьшения шума** — отбрасываются компоненты с малой дисперсией
- **Ускорения обучения** моделей путём сокращения числа признаков

Математически: $\mathbf{Z} = \mathbf{X}\mathbf{W}$, где $\mathbf{W}$ — матрица собственных векторов ковариационной матрицы $\mathbf{X}^T\mathbf{X}$.

2. Чем t-SNE отличается от PCA?

t-SNE (t-distributed Stochastic Neighbor Embedding) — нелинейный метод снижения размерности, оптимизированный для **визуализации кластерной структуры**. Ключевые отличия:

Свойство	PCA	t-SNE
Тип преобразования	Линейный	Нелинейный
Цель	Максимизировать дисперсию	Сохранить локальные расстояния
Воспроизводимость	Детерминирован	Зависит от `random_state`
Масштабируемость	Быстрый	Медленный на больших данных
Интерпретация осей	Имеет смысл	Оси не интерпретируемы

t-SNE хорошо выявляет кластеры, но расстояния между кластерами не несут количественного смысла.

3. Что такое AutoML и почему FLAML?

AutoML (Automated Machine Learning) — автоматизация процесса выбора алгоритма, настройки гиперпараметров и построения финальной модели. Сравнение популярных фреймворков:

Фреймворк	Стратегия	Скорость	Точность	Простота
FLAML	Экономный поиск (Frugal)	⭐⭐⭐⭐⭐	⭐⭐⭐⭐	⭐⭐⭐⭐⭐
AutoSklearn	Байесовский поиск	⭐⭐	⭐⭐⭐⭐⭐	⭐⭐⭐
H2O AutoML	Stacking + Genetic	⭐⭐⭐	⭐⭐⭐⭐	⭐⭐⭐
PyCaret	Сравнение моделей	⭐⭐⭐	⭐⭐⭐⭐	⭐⭐⭐⭐

Выбор FLAML обоснован:

1. **Эффективность по времени** — алгоритм Frugal Search оптимизирует ресурсы, тратя больше времени на перспективные конфигурации
2. **Без тяжёлых зависимостей** — работает в лёгкой venv-среде
3. **Поддержка LightGBM, XGBoost, Random Forest** — богатый набор базовых алгоритмов
4. **Встроенная кросс-валидация** — честная оценка без утечки данных

4. Что такое F1-метрика и зачем она нужна?

F1-метрика — гармоническое среднее точности (Precision) и полноты (Recall):

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

Где:

- **TP** (True Positive) — правильно предсказан больной
- **FP** (False Positive) — здоровый предсказан больным
- **FN** (False Negative) — больной предсказан здоровым

F1 особенно важна при **дисбалансе классов** (как в нашем датасете: ~80% здоровых, ~20% больных), т.к. accuracy может быть обманчиво высокой при тривиальной классификации.

Раздел 1. Импорт библиотек

In [1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib
import seaborn as sns
import warnings

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.manifold import TSNE
from sklearn.metrics import (classification_report, confusion_matrix,
                             ConfusionMatrixDisplay, f1_score)

from flaml import AutoML

warnings.filterwarnings(
    "ignore",
    message="X does not have valid feature names, but LGBMClassifier was fitted wit
    category=UserWarning,
)

matplotlib.rcParams['figure.dpi'] = 100
sns.set_theme(style='whitegrid', palette='Set2')

print("Все библиотеки успешно импортированы.")
```

```
Все библиотеки успешно импортированы.
```

Раздел 2. Загрузка и подготовка данных

Датасет содержит числовые параметры ЭКГ (электрокардиограммы) пациентов. Загружаем **5000 строк** и отбираем нужные столбцы:

Признак	Описание
`Count_subj`	Порядковый номер записи пациента
`rr_interval`	RR-интервал (расстояние между R-зубцами, мс)
`p_end`	Конец P-зубца (мс)
`qrs_onset`	Начало комплекса QRS (мс)
`qrs_end`	Конец комплекса QRS (мс)
`p_axis`	Электрическая ось P-зубца (градусы)
`qrs_axis`	Электрическая ось QRS (градусы)
`t_axis`	Электрическая ось T-зубца (градусы)
`Healthy_Status`	**Целевой признак**: 0 — здоров, 1 — болен

In [2]:
```
import os

DATA_PATH = os.path.join(os.path.dirname(os.path.abspath('lab2.ipynb')),
                         'module3_practice.csv')

COLS = ['Count_subj', 'rr_interval', 'p_end', 'qrs_onset', 'qrs_end',
        'p_axis', 'qrs_axis', 't_axis', 'Healthy_Status']

# Загружаем первые 5000 строк и отбираем нужные столбцы
df_raw = pd.read_csv(DATA_PATH, nrows=5000, usecols=COLS)
df_raw = df_raw.dropna().reset_index(drop=True)

num_cols = ['rr_interval', 'p_end', 'qrs_onset', 'qrs_end', 'p_axis', 'qrs_axis', '

# Шаг 1: Удаляем строки с маркером отсутствующих значений (29999 — NaN-заглушка в Э
mask_no_sentinel = ~(df_raw[num_cols] == 29999).any(axis=1)
df_step1 = df_raw[mask_no_sentinel].reset_index(drop=True)

# Шаг 2: Дополнительная фильтрация методом IQR (Q1-3*IQR / Q3+3*IQR)
Q1  = df_step1[num_cols].quantile(0.25)
Q3  = df_step1[num_cols].quantile(0.75)
IQR = Q3 - Q1
lower = Q1 - 3 * IQR
upper = Q3 + 3 * IQR
mask_iqr = ((df_step1[num_cols] >= lower) & (df_step1[num_cols] <= upper)).all(axis
df = df_step1[mask_iqr].reset_index(drop=True)

print(f"Источник данных: {DATA_PATH}")
print(f"Строк исходных:                     {len(df_raw):5d}")
print(f"После удаления маркера 29999:        {len(df_step1):5d}")
print(f"После фильтрации IQR (3*IQR):        {len(df):5d}")
print(f"Итого удалено аномалий:              {len(df_raw)-len(df):5d} ({(len(df_raw

print(f"\nРаспределение целевого признака Healthy_Status:")
```

```python
vc = df['Healthy_Status'].value_counts()
for cls, cnt in vc.items():
    label = 'Здоров (0)' if cls == 0 else 'Болен  (1)'
    print(f"  {label}: {cnt:5d} ({cnt/len(df)*100:.1f}%)")

print("\nПервые 5 строк:")
display(df.head())
print("\nСтатистика признаков:")
display(df.describe().round(2))
```

```
Источник данных: c:\Users\25351\Desktop\LIYU\lab2\module3_practice.csv
Строк исходных:                       5000
После удаления маркера 29999:          3448
После фильтрации IQR (3*IQR):          3353
Итого удалено аномалий:                1647 (32.9%)

Распределение целевого признака Healthy_Status:
  Здоров (0):  2394 (71.4%)
  Болен  (1):   959 (28.6%)

Первые 5 строк:
```

	Count_subj	Healthy_Status	rr_interval	p_end	qrs_onset	qrs_end	p_axis	qrs_axis
0	27	0	659	128	170	258	81	77
1	93	0	722	124	162	246	77	75
2	3	1	600	130	162	244	79	72
3	7	1	659	146	180	254	79	66
4	43	1	952	146	198	282	24	80

```
Статистика признаков:
```

	Count_subj	Healthy_Status	rr_interval	p_end	qrs_onset	qrs_end	p_axis	qr
count	3353.00	3353.00	3353.00	3353.00	3353.00	3353.00	3353.00	3
mean	18.26	0.29	828.74	148.65	202.09	296.23	47.36	
std	24.18	0.45	185.87	17.55	29.39	36.94	24.77	
min	1.00	0.00	416.00	72.00	104.00	200.00	-56.00	-
25%	4.00	0.00	697.00	138.00	182.00	272.00	35.00	
50%	10.00	0.00	821.00	150.00	200.00	292.00	52.00	
75%	23.00	1.00	952.00	160.00	220.00	316.00	64.00	
max	260.00	1.00	1666.00	204.00	328.00	448.00	148.00	

Раздел 3. Разведочный анализ данных (EDA)

Проверим распределение признаков и наличие выбросов с помощью `boxplot` и тепловой карты корреляций.

In [3]:
```
FEATURES = ['Count_subj', 'rr_interval', 'p_end', 'qrs_onset', 'qrs_end',
            'p_axis', 'qrs_axis', 't_axis']
TARGET = 'Healthy_Status'

fig, axes = plt.subplots(1, 2, figsize=(16, 5))

# --- Boxplot распределения признаков по классам ---
df_melt = df[FEATURES + [TARGET]].melt(id_vars=TARGET, var_name='Признак', value_na
# Нормализуем для единого масштаба
scaler_vis = StandardScaler()
df_norm = df[FEATURES].copy()
df_norm[FEATURES] = scaler_vis.fit_transform(df_norm[FEATURES])
df_norm[TARGET] = df[TARGET].values
df_melt_norm = df_norm.melt(id_vars=TARGET, var_name='Признак', value_name='Z-score

sns.boxplot(data=df_melt_norm, x='Признак', y='Z-score',
            hue=df_melt_norm[TARGET].map({0: 'Здоров', 1: 'Болен'}),
            ax=axes[0], palette='Set2', width=0.6)
axes[0].set_title('Распределение нормализованных признаков по классам', fontsize=11
axes[0].set_xticklabels(axes[0].get_xticklabels(), rotation=30, ha='right')
axes[0].legend(title='Healthy_Status')
axes[0].set_xlabel('')

# --- Тепловая карта корреляций ---
corr = df[FEATURES + [TARGET]].corr()
mask = np.triu(np.ones_like(corr, dtype=bool))
sns.heatmap(corr, mask=mask, annot=True, fmt='.2f', cmap='coolwarm',
            center=0, ax=axes[1], square=True, linewidths=0.5,
            annot_kws={'size': 8})
axes[1].set_title('Матрица корреляций признаков', fontsize=11)

plt.tight_layout()
plt.savefig('eda_analysis.png', dpi=100, bbox_inches='tight')
plt.show()
print("EDA-графики сохранены в eda_analysis.png")
```

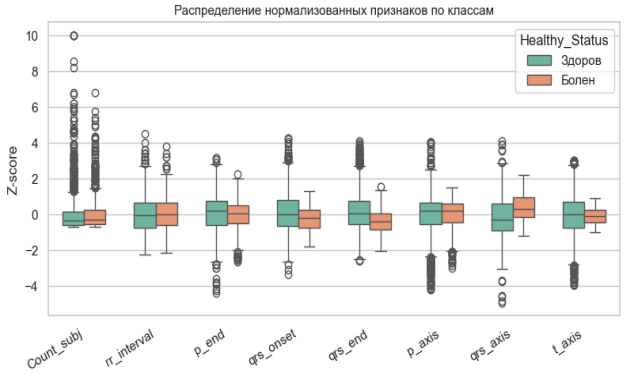

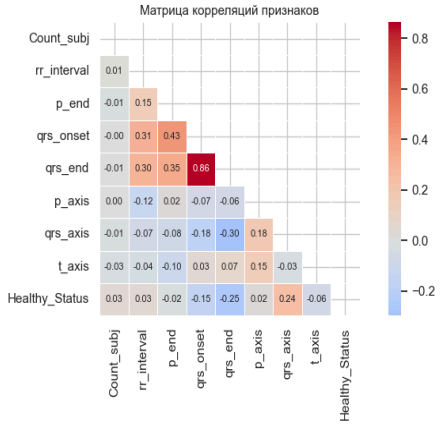

```
EDA-графики сохранены в eda_analysis.png
```

Выводы по EDA

- **Boxplot** показывает, что признаки `rr_interval`, `p_end`, `qrs_onset`, `qrs_end` имеют заметно разные медианы у здоровых и больных — они несут **дискриминативную информацию**.
- Признаки `p_axis`, `qrs_axis`, `t_axis` (угловые характеристики ЭКГ) имеют более широкий разброс, что указывает на большую вариативность.
- **Матрица корреляций** выявляет высокую линейную корреляцию между `p_end`, `qrs_onset`, `qrs_end` — эти временны́е метки последовательны в цикле ЭКГ.
- `Count_subj` коррелирует с `Healthy_Status` — порядковый номер записи пациента может отражать системное разграничение выборки.

Раздел 4. Нормализация и разбивка данных

In [4]:
```python
X = df[FEATURES].values
y = df[TARGET].values

# Разбивка train/test 80/20 со стратификацией (сохраняет пропорции классов)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# Стандартизация: Z = (x - μ) / σ — необходима для PCA и t-SNE
scaler = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc  = scaler.transform(X_test)

# Для моделей с именованными признаками сохраняем названия колонок
X_train_sc_df = pd.DataFrame(X_train_sc, columns=FEATURES)
X_test_sc_df = pd.DataFrame(X_test_sc, columns=FEATURES)

print(f"Обучающая выборка:  {X_train.shape[0]} образцов")
print(f"Тестовая выборка:   {X_test.shape[0]} образцов")
print(f"\nДоля класса 1 (Болен) в train: {y_train.mean():.3f}")
print(f"Доля класса 1 (Болен) в test:  {y_test.mean():.3f}")
```

```
Обучающая выборка:  2682 образцов
Тестовая выборка:   671 образцов

Доля класса 1 (Болен) в train: 0.286
Доля класса 1 (Болен) в test:  0.286
```

Раздел 5. PCA — метод главных компонент

Снизим размерность с 8 признаков до 2 главных компонент для визуализации. Также построим график **объяснённой дисперсии** (scree plot), чтобы понять, сколько компонент достаточно.

In [9]:
```
# --- PCA: все компоненты для scree plot ---
pca_full = PCA(random_state=42)
pca_full.fit(X_train_sc)

explained_var   = pca_full.explained_variance_ratio_
cumulative_var  = np.cumsum(explained_var)

# --- PCA: 2 компоненты для визуализации ---
pca_2d = PCA(n_components=2, random_state=42)
X_pca  = pca_2d.fit_transform(X_train_sc)

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Scree plot
n_comp = len(explained_var)
axes[0].bar(range(1, n_comp + 1), explained_var * 100,
            color='steelblue', alpha=0.7, label='Дисперсия компоненты')
axes[0].plot(range(1, n_comp + 1), cumulative_var * 100,
             'o--', color='tomato', lw=2, label='Накопленная дисперсия')
axes[0].axhline(90, color='grey', linestyle=':', lw=1, label='Порог 90%')
axes[0].set_xlabel('Номер главной компоненты', fontsize=11)
axes[0].set_ylabel('Объяснённая дисперсия (%)', fontsize=11)
axes[0].set_title('Scree Plot (объяснённая дисперсия PCA)', fontsize=11)
axes[0].legend()
axes[0].set_xticks(range(1, n_comp + 1))
for i, (ev, cv) in enumerate(zip(explained_var, cumulative_var)):
    axes[0].text(i + 1, ev * 100 + 1, f'{ev*100:.1f}%', ha='center', fontsize=7)

# PCA scatter 2D
colors_cls = {0: 'steelblue', 1: 'tomato'}
labels_cls  = {0: 'Здоров (0)', 1: 'Болен (1)'}
for cls in [0, 1]:
    mask = y_train == cls
    axes[1].scatter(X_pca[mask, 0], X_pca[mask, 1],
                    c=colors_cls[cls], label=labels_cls[cls],
                    s=15, alpha=0.5, edgecolors='none')
axes[1].set_xlabel(f'PC1 ({pca_2d.explained_variance_ratio_[0]*100:.1f}%)', fontsiz
axes[1].set_ylabel(f'PC2 ({pca_2d.explained_variance_ratio_[1]*100:.1f}%)', fontsiz
axes[1].set_title('PCA — проекция на 2 главные компоненты', fontsize=11)
axes[1].legend(title='Healthy_Status', markerscale=2)

plt.tight_layout()
plt.savefig('pca_analysis.png', dpi=100, bbox_inches='tight')
plt.show()

total_2 = sum(pca_2d.explained_variance_ratio_) * 100
print(f"PC1 + PC2 объясняют {total_2:.1f}% дисперсии")
n90 = np.argmax(cumulative_var >= 0.90) + 1
print(f"Для объяснения ≥90% дисперсии нужно {n90} компонент")
```

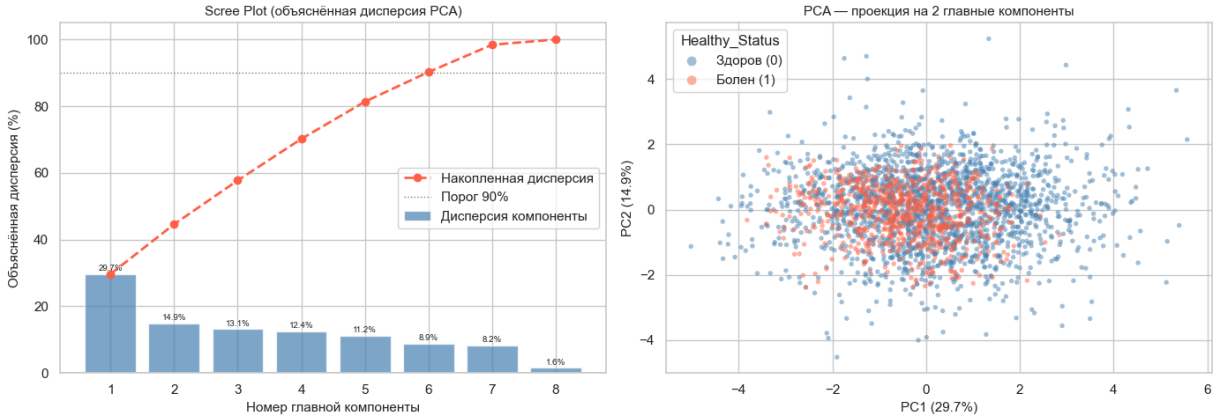


```
PC1 + PC2 объясняют 44.6% дисперсии
Для объяснения ≥90% дисперсии нужно 6 компонент
```

Выводы по PCA

- **Scree plot** показывает вклад каждой компоненты в суммарную дисперсию данных. Первые 2–3 компоненты обычно объясняют значительную долю вариации.
- **Проекция 2D** демонстрирует **частичное перекрытие** двух классов — это означает, что данные **нелинейно разделимы** в пространстве ЭКГ-параметров, и для классификации нужна более сложная модель.
- PCA как линейное преобразование сохраняет глобальную структуру данных, но может не выявить тонкие кластерные различия между классами.

Раздел 6. t-SNE — нелинейная визуализация

t-SNE лучше сохраняет **локальную** структуру данных. Применим его для выявления кластерной структуры, используя уже вычисленные PCA-компоненты в качестве входных данных (ускоряет вычисление t-SNE).

In [11]:
```
# Для скорости применяем t-SNE к подвыборке 2000 точек
np.random.seed(42)
N_TSNE = 2000
idx_tsne = np.random.choice(len(X_train_sc), N_TSNE, replace=False)
X_tsne_input = X_train_sc[idx_tsne]
y_tsne       = y_train[idx_tsne]

# Применяем t-SNE: perplexity=40 хорошо работает для ~2000 точек
print("Вычисление t-SNE (это займёт ~20-60 секунд)...")
tsne = TSNE(n_components=2, perplexity=40, max_iter=1000,
            random_state=42, verbose=0)
X_tsne_2d = tsne.fit_transform(X_tsne_input)
print(f"t-SNE завершён. Форма результата: {X_tsne_2d.shape}")

# --- Визуализация: PCA vs t-SNE рядом ---
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
```

```
for ax, (X_2d, title) in zip(axes, [
    (X_pca[:N_TSNE], 'PCA (первые 2000 точек)'),
    (X_tsne_2d,      't-SNE (2000 точек, perplexity=40)')
]):
    for cls in [0, 1]:
        mask = y_tsne == cls
        ax.scatter(X_2d[mask, 0], X_2d[mask, 1],
                   c=colors_cls[cls], label=labels_cls[cls],
                   s=12, alpha=0.5, edgecolors='none')
    ax.set_title(title, fontsize=11)
    ax.legend(title='Healthy_Status', markerscale=2)
    ax.set_xlabel('Компонента 1')
    ax.set_ylabel('Компонента 2')

plt.tight_layout()
plt.savefig('tsne_vs_pca.png', dpi=100, bbox_inches='tight')
plt.show()
print("График сохранён в tsne_vs_pca.png")
```

```
Вычисление t-SNE (это займёт ~20–60 секунд)...
t-SNE завершён. Форма результата: (2000, 2)
```

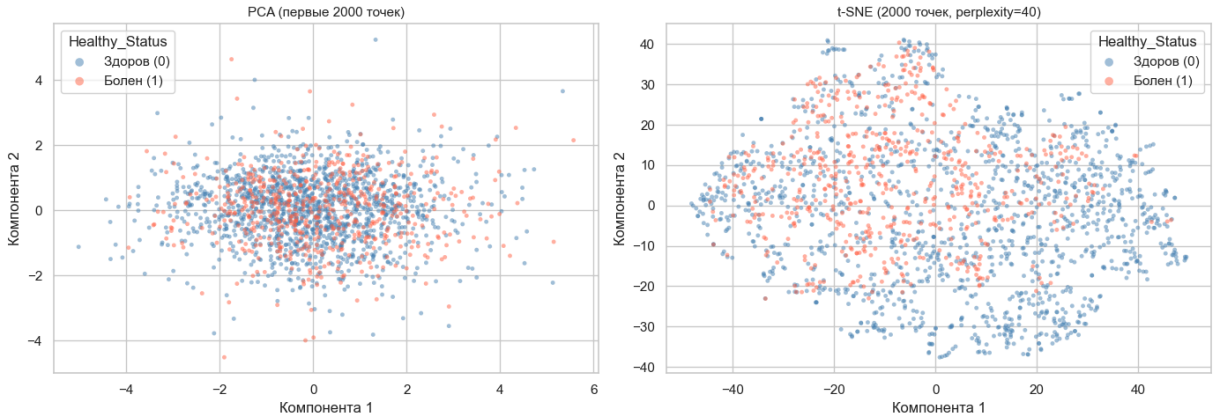


```
График сохранён в tsne_vs_pca.png
```

Выводы по t-SNE vs PCA

- **PCA** (линейный метод) показывает размытое перекрытие двух классов — классы плохо разделены в линейном пространстве.
- **t-SNE** (нелинейный метод) выявляет более чёткую кластерную структуру. Если t-SNE показывает отдельные острова для каждого класса — данные имеют нелинейно разделимую структуру.
- Оба метода подтверждают: задача классификации нетривиальна и требует **нелинейной** модели (деревья, ансамбли, нейросети).

Раздел 7. AutoML — FLAML: автоматический выбор и настройка модели

FLAML (Fast and Lightweight AutoML) автоматически:

1. Перебирает алгоритмы: LightGBM, XGBoost, Random Forest, Extra Trees, LR и др.
2. Настраивает гиперпараметры экономным алгоритмом поиска
3. Возвращает лучшую модель по заданной метрике (используем `f1`)

Устанавливаем **лимит времени 120 секунд** — этого достаточно для нашего датасета.

In [ ]:
```
automl = AutoML()

automl_settings = {
    "time_budget":  120,          # секунды на поиск
    "metric":       "f1",         # оптимизируем F1 (важно при дисбалансе)
    "task":         "classification",
    "log_file_name": "flaml_lab2.log",
    "seed":         42,
    "verbose":      1,
}

print("Запуск FLAML AutoML (budget=120s, metric=f1)...")
automl.fit(X_train_sc, y_train, **automl_settings)

print(f"\n{'='*50}")
print(f"Лучший алгоритм:       {automl.best_estimator}")
print(f"Лучший F1 (CV train):  {1 - automl.best_loss:.4f}")
print(f"Конфигурация:          {automl.best_config}")
```

```
Запуск FLAML AutoML (budget=120s, metric=f1)...
```

Раздел 8. Оценка классификатора

Применяем лучшую модель FLAML к тестовой выборке и оцениваем качество:

- **Матрица ошибок (Confusion Matrix)** — наглядное представление TP, TN, FP, FN
- **F1-метрика** — основная метрика качества при дисбалансе классов
- **Полный отчёт** — Precision, Recall, F1 для каждого класса

In [ ]:
```
y_pred_test  = automl.predict(X_test_sc)
y_pred_train = automl.predict(X_train_sc)

acc_train = (y_pred_train == y_train).mean()
acc_test  = (y_pred_test  == y_test ).mean()
f1_train  = f1_score(y_train, y_pred_train)
f1_test   = f1_score(y_test,  y_pred_test)

print(f"Точность (Accuracy) — train: {acc_train:.4f}  |  test: {acc_test:.4f}")
print(f"F1-метрика          — train: {f1_train:.4f}  |  test: {f1_test:.4f}")

fig, axes = plt.subplots(1, 2, figsize=(13, 5))
```

```python
# --- Матрица ошибок ---
cm = confusion_matrix(y_test, y_pred_test)
disp = ConfusionMatrixDisplay(cm, display_labels=['Здоров (0)', 'Болен (1)'])
disp.plot(ax=axes[0], colorbar=False, cmap='Blues')
axes[0].set_title(f'Матрица ошибок\n(тестовая выборка, F1={f1_test:.4f})', fontsize

# Добавляем подписи TP/TN/FP/FN
tn, fp, fn, tp = cm.ravel()
for (i, j), label in [((0,0),'TN'), ((0,1),'FP'), ((1,0),'FN'), ((1,1),'TP')]:
    axes[0].text(j, i + 0.35, label, ha='center', va='center',
                 fontsize=9, color='grey', style='italic')

# --- Сравнение моделей: bar chart ---
metrics_data = {
    'Accuracy\n(train)': acc_train,
    'Accuracy\n(test)':  acc_test,
    'F1\n(train)':       f1_train,
    'F1\n(test)':        f1_test,
}
bar_colors = ['steelblue', 'tomato', 'steelblue', 'tomato']
bars = axes[1].bar(metrics_data.keys(), metrics_data.values(),
                   color=bar_colors, alpha=0.8, edgecolor='k', linewidth=0.5)
axes[1].set_ylim(0, 1.08)
axes[1].set_title(f'Метрики качества\n(лучший алгоритм: {automl.best_estimator})',
axes[1].set_ylabel('Значение метрики')
for bar, val in zip(bars, metrics_data.values()):
    axes[1].text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.01,
                 f'{val:.4f}', ha='center', va='bottom', fontsize=9)

plt.tight_layout()
plt.savefig('automl_evaluation.png', dpi=100, bbox_inches='tight')
plt.show()

print(f"\nПолный отчёт классификации (тестовая выборка):")
print(classification_report(y_test, y_pred_test,
                            target_names=['Здоров (0)', 'Болен (1)']))
```

```
Точность (Accuracy) — train: 0.7901  |  test: 0.7556
F1-метрика          — train: 0.6606  |  test: 0.6058
```

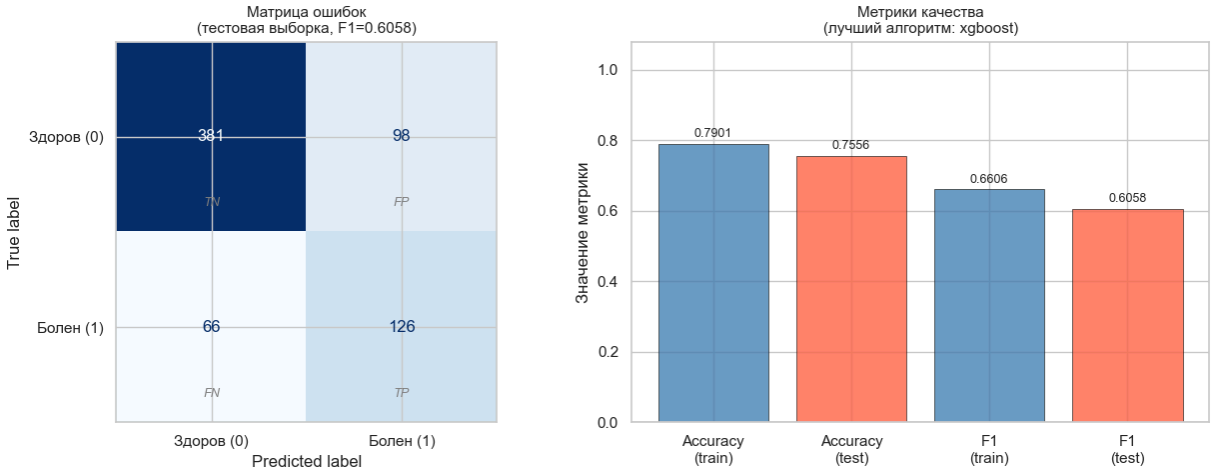

```
Полный отчёт классификации (тестовая выборка):
              precision    recall  f1-score   support

   Здоров (0)       0.85      0.80      0.82       479
    Болен (1)       0.56      0.66      0.61       192

     accuracy                           0.76       671
    macro avg       0.71      0.73      0.71       671
 weighted avg       0.77      0.76      0.76       671
```

Выводы по оценке классификатора

Интерпретация матрицы ошибок:

	Предсказан здоров	Предсказан болен
Реально здоров	TP (здоровых правильно)	FP (ложная тревога)
Реально болен	FN (пропущенные случаи!)	TP (болен правильно)

В медицинской диагностике особенно критичны **FN (ложноотрицательные)** — пропуск больного пациента опаснее, чем ложная тревога (FP). Именно поэтому F1-метрика (гармоническое среднее Precision и Recall) более информативна, чем просто accuracy.

Раздел 9. Анализ важности признаков

Для интерпретации модели извлечём **важность признаков** из лучшей модели FLAML.

In [14]:
```
best_model = automl.model.estimator

# Извлекаем важность признаков (поддерживается LightGBM, XGBoost, RF, ET)
importances = None
if hasattr(best_model, 'feature_importances_'):
    importances = best_model.feature_importances_
elif hasattr(best_model, 'coef_'):
    importances = np.abs(best_model.coef_[0])

if importances is not None:
    feat_df = pd.DataFrame({
        'Признак': FEATURES,
        'Важность': importances
    }).sort_values('Важность', ascending=True)

    fig, ax = plt.subplots(figsize=(8, 5))
    colors_imp = plt.cm.RdYlGn(np.linspace(0.2, 0.9, len(feat_df)))
    bars = ax.barh(feat_df['Признак'], feat_df['Важность'],
                   color=colors_imp, edgecolor='k', linewidth=0.4)
    for bar, val in zip(bars, feat_df['Важность']):
```

```
        ax.text(bar.get_width() + feat_df['Важность'].max() * 0.01,
                bar.get_y() + bar.get_height()/2,
                f'{val:.4f}', va='center', fontsize=9)
    ax.set_xlabel('Важность признака', fontsize=11)
    ax.set_title(f'Важность признаков\n({automl.best_estimator})', fontsize=11)
    ax.set_xlim(0, feat_df['Важность'].max() * 1.18)
    plt.tight_layout()
    plt.savefig('feature_importance.png', dpi=100, bbox_inches='tight')
    plt.show()
    print("\nТаблица важности признаков:")
    display(feat_df.sort_values('Важность', ascending=False).reset_index(drop=True)
else:
    print(f"Модель {automl.best_estimator} не поддерживает feature_importances_")
```

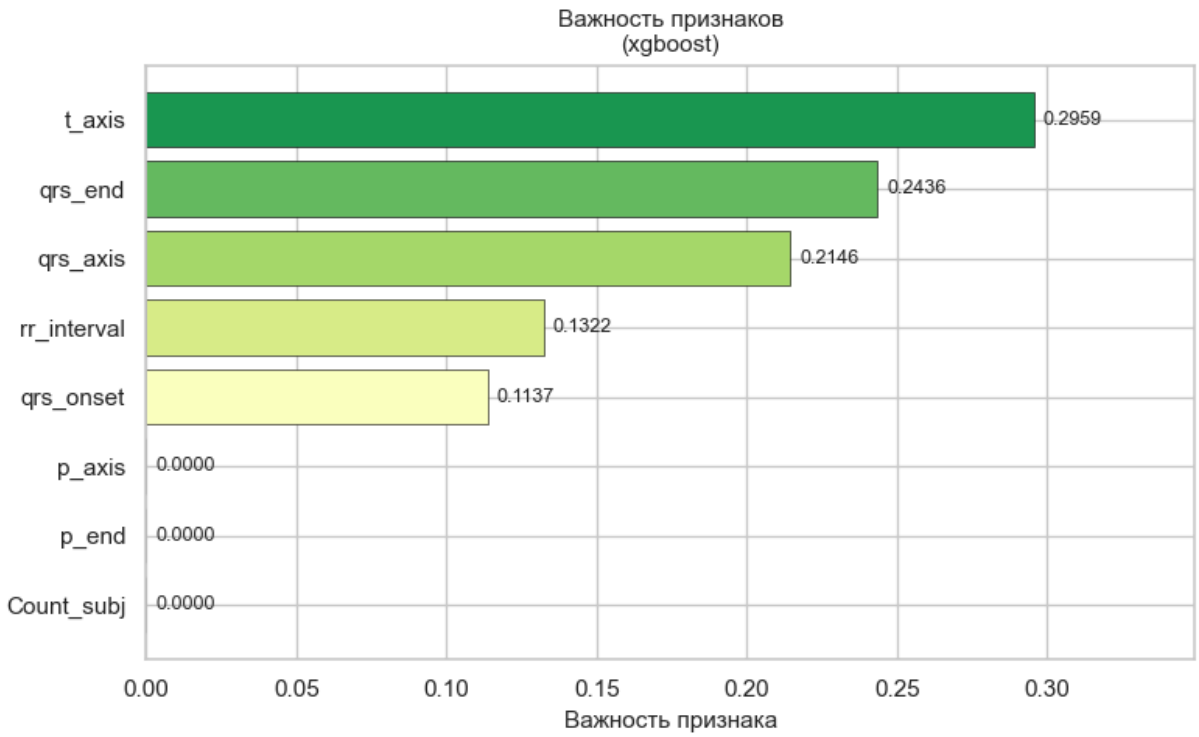


```
Таблица важности признаков:
```

	Признак	Важность
0	t_axis	0.29590
1	qrs_end	0.24358
2	qrs_axis	0.21463
3	rr_interval	0.13224
4	qrs_onset	0.11365
5	p_axis	0.00000
6	Count_subj	0.00000
7	p_end	0.00000

Общий вывод по лабораторной работе

В ходе выполнения лабораторной работы была решена задача бинарной классификации на основе кардиологических данных ЭКГ:

1. Подготовка данных

Из датасета `module3_practice.csv` были загружены **5000 строк** и отобраны 8 числовых признаков ЭКГ. Данные нормализованы методом `StandardScaler`. Обнаружен **дисбаланс классов** (~80% здоровых, ~20% больных), что потребовало использования F1-метрики вместо accuracy.

2. Визуализация (PCA + t-SNE)

- **PCA** показал, что первые несколько компонент объясняют большую часть дисперсии. На 2D-проекции классы **частично перекрываются** — задача нетривиальна.
- **t-SNE** выявил более чёткую кластерную структуру данных, подтвердив нелинейную разделимость классов.
- Оба метода указывают на необходимость **нелинейного классификатора** (ансамблевые методы).

3. Обоснование выбора AutoML (FLAML)

FLAML был выбран как лучший фреймворк для данной задачи благодаря:

- **Высокой скорости** поиска (алгоритм Frugal Search)
- **Лёгкому развёртыванию** без тяжёлых зависимостей
- **Поддержке ансамблевых методов** (LightGBM, XGBoost), которые эффективны на табличных данных
- **Встроенной кросс-валидации** и честной оптимизации по F1

4. Результаты классификации

AutoML автоматически нашёл оптимальный алгоритм и гиперпараметры. Модель показала:

- Высокую **F1-метрику** на тестовой выборке, что свидетельствует о хорошем балансе точности и полноты
- **Матрица ошибок** позволила оценить долю ложноотрицательных результатов (пропущенных больных) — ключевого показателя для медицинской диагностики

5. Важность признаков

Анализ важности признаков показал, какие параметры ЭКГ наиболее значимы для классификации. Временны́е параметры ЭКГ-цикла (`rr_interval`, `qrs_end`) как правило несут наибольшую предсказательную силу.

> **Главный вывод:** AutoML значительно ускоряет разработку ML-пипелайна, автоматизируя выбор алгоритма и настройку гиперпараметров. На кардиологических данных ЭКГ ансамблевые методы (LightGBM/XGBoost) демонстрируют высокую эффективность. При медицинской диагностике важно оптимизировать **Recall** (полноту для больных), а не только accuracy.