



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Эргатические системы

Лабораторной работе №2

Выполнил: Ван Цзюньтао

Группа: ИУ1И-41М

Проверил: Андриков.Д.А.

Москва 2026

Цель работы:. Освоить методы загрузки и предварительной обработки наборов данных по кардиологии, понять клиническое значение параметров ЭКГ;

Освоить методы визуализации и снижения размерности, такие как PCA и t-SNE, для анализа характеристик распределения высокоразмерных данных;

Изучить применение фреймворков AutoML (FLAML, AutoGluon, TPOT) в задачах бинарной классификации, оценить и сравнить показатели F1 различных фреймворков.

Теоретические основы

1. Анализ главных компонент (PCA)

Анализ главных компонент (Principal Component Analysis, PCA) — это метод линейного снижения размерности, при котором исходные признаки преобразуются с помощью ортогонального преобразования в набор линейно не связанных главных компонент, упорядоченных по величине дисперсии. Первые k главных компонент сохраняют информацию о наибольшей дисперсии исходных данных и часто используются для визуализации и извлечения признаков в многомерных данных. PCA чувствителен к масштабу признаков, поэтому обычно требуется предварительная стандартизация данных.

2. t-SNE

Вложение случайных соседей с t -распределением (t-Distributed Stochastic Neighbor Embedding, t-SNE) — это метод нелинейного снижения размерности, особенно подходящий для визуализации высокоразмерных данных. Он измеряет сходство, используя гауссово распределение в высокоразмерном пространстве и t -распределение в низкоразмерном пространстве, минимизируя KL-дисперсию между двумя распределениями, что позволяет сохранить локальную структуру данных.

3. Фреймворки AutoML

AutoML (автоматическое машинное обучение) предназначено для автоматизации процессов выбора конвейера машинного обучения и настройки гиперпараметров. В данном эксперименте используются три основных фреймворка AutoML:

- (1) FLAML: облегченный фреймворк AutoML, разработанный Microsoft, использующий недорогую стратегию настройки на основе пространства поиска, способный найти высокопроизводительную модель в сжатые сроки;
- (2) AutoGluon: AutoML-фреймворк, разработанный AWS, поддерживающий множество моделей (нейронные сети, деревья с градиентным подъемом, случайные леса и т. д.), который

автоматически комбинирует несколько моделей с помощью технологии Stacking Ensemble для повышения производительности;

(3) TPOT: AutoML-фреймворк, основанный на генетическом программировании, который с помощью эволюционных алгоритмов автоматически ищет оптимальный конвейер машинного обучения, включая выбор признаков, предварительную обработку и выбор модели.

4. Показатели оценки

В данном эксперименте в качестве основного показателя оценки используется показатель Макро F1. Показатель F1 представляет собой среднеквадратичное среднее значения точности (Precision) и полноты (Recall). Показатель Макро F1 сначала вычисляет F1 для каждой категории по отдельности, а затем вычисляет среднее значение, что позволяет объективно оценить производительность каждой категории и особенно подходит для наборов данных с несбалансированными категориями.

Практическая часть

Анализ и визуализация наборов данных

1. Описание набора данных

В данном эксперименте используется набор данных по кардиологии (ECG), содержащий 5000 записей электрокардиограмм. Каждая запись включает 8 числовых признаков и одну бинарную метку Healthy_Status. Распределение классов в наборе данных: 4040 записей для класса «здоровые» (0) и 960 записей для класса «больные» (1), что свидетельствует о некотором дисбалансе классов.

Таблица 1. Описание характеристик набора данных ЭКГ

Название характеристики	Описание
Count_subj	Количество испытуемых
rr_interval	Интервал RR (интервал между ударами сердца)
p_end	Время окончания зубца Р
qrs_onset	Время начала комплекса QRS
qrs_end	Время окончания комплекса QRS
p_axis	Электрическая ось зубца Р
qrs_axis	Электрическая ось комплекса QRS
t_axis	Электрическая ось зубца Т

2. Визуализация результатов PCA

После стандартизации 8 характеристик ЭКГ было проведено снижение размерности до 2-х измерений с помощью PCA. Суммарная доля объясняемой дисперсии первых двух главных компонент составила 67.92 % (PC1: 47.15 %, PC2: 20.77 %). На точечном графике PCA можно наблюдать примерное распределение выборок в низкоразмерном пространстве.




Рис. 1. Визуализация результатов уменьшения размерности с помощью PCA

2. Визуализация с помощью t-SNE

С помощью t-SNE было проведено нелинейное снижение размерности стандартизированных данных (perplexity=30, random_state=42). t-SNE позволяет лучше выявить локальные кластерные структуры в данных; на графике можно наблюдать особенности распределения образцов с различными состояниями здоровья.




Рис. 2. Визуализация результатов снижения размерности с помощью t-SNE

Моделирование и реализация эксперимента

1. Предварительная обработка данных

Из набора данных выбраны 8 признаков (Count_subj, rr_interval, p_end, qrs_onset, qrs_end, p_axis, qrs_axis, t_axis) и метка (Healthy_Status). Набор данных разбит на обучающую и тестовую выборки в соотношении 80%/20% с использованием стратифицированной выборки (stratify) для сохранения равномерного распределения классов. Набор для обучения содержит 4000 записей, тестовый набор — 1000 записей.

2. Автоматическое моделирование с помощью FLAML

Для обучения с помощью AutoML используется фреймворк FLAML. Время обучения установлено на 60 секунд, показателем оценки выбран Macro F1, тип задачи — классификация. FLAML автоматически ищет оптимальную модель и гиперпараметры.

3. Автоматическое моделирование с помощью AutoGluon

Для автоматического моделирования используется AutoGluon TabularPredictor, время выполнения установлено на 120 секунд, показатель оценки — f1_macro. AutoGluon автоматически обучает различные модели (нейронные сети, деревья с градиентным подъемом, случайные леса, CatBoost, XGBoost и т. д.) и объединяет оптимальные модели с помощью стратегии объединения WeightedEnsemble.

4. Автоматическое моделирование с помощью TPOT

Используем классификатор ТРОТ для поиска с помощью генетического программирования, устанавливаем максимальное время выполнения 10 минут, а показателем оценки — `f1_macro`. ТРОТ автоматически ищет оптимальный конвейер с помощью эволюционных алгоритмов.

5. Оценка моделей

Используем показатель Macro F1 для оценки классификационной способности каждой модели и строим матрицу путаницы (Confusion Matrix) для наглядного представления результатов классификации.

Результаты эксперимента и анализ

1. Визуальный анализ с понижением размерности

Визуализация с понижением размерности с помощью PCA и t-SNE показывает, что данные ЭКГ демонстрируют определенную кластерную структуру в низкоразмерном пространстве, однако между двумя классами образцов (здоровые/больные) наблюдается значительная область пересечения, что свидетельствует о том, что с помощью простых линейных методов полностью различить их сложно. Это еще раз подтверждает необходимость использования AutoML для построения сложных классификационных моделей.

2. Сравнение производительности моделей AutoML

Ниже приведено сравнение показателя Macro F1 для трех фреймворков AutoML при решении задачи бинарной классификации ЭКГ:

Таблица 2. Сравнение производительности фреймворков AutoML

Фреймворк AutoML	Оценка Macro F1	Описание
FLAML	0.7757	Вычисления за 60 секунд
AutoGluon	0.7826	Вычисления за 120 секунд, взвешенная интеграция (оптимальный вариант)
ТРОТ	0.7628	Вычисления за 10 минут, генетическое программирование

Как видно из результатов сравнения, AutoGluon продемонстрировал самый высокий показатель Macro F1 (0.7826), немного превзойдя FLAML (0.7757) и значительно опередив ТРОТ (0.7628). Стратегия взвешенной интеграции AutoGluon позволяет эффективно объединить преимущества нескольких базовых моделей и показала наилучшие результаты на данном наборе данных.

3. Анализ матрицы путаницы

Матрица путаницы наглядно демонстрирует результаты классификации модели на тестовом наборе, включая количество истинных положительных результатов (TP), истинных

отрицательных результатов (TN), ложных положительных результатов (FP) и ложных отрицательных результатов (FN). С помощью матрицы путаницы можно проанализировать склонность модели к классификации различных категорий.




Рис. 3. Матрица путаницы классификации AutoGluon

Благодаря визуализации с помощью методов снижения размерности PCA и t-SNE удалось получить первоначальное представление о характеристиках распределения данных ЭКГ в низкоразмерном пространстве; было обнаружено, что две категории образцов пересекаются, что указывает на определенную сложность задачи классификации;

Фреймворки AutoML (FLAML, AutoGluon, TPOT) способны автоматически выполнять выбор модели и настройку гиперпараметров, причем AutoGluon благодаря стратегии интегрирования продемонстрировал более высокую эффективность классификации;

Матрица путаницы и показатель F1 свидетельствуют о том, что двуклассовая модель, основанная на параметрах ЭКГ, способна эффективно прогнозировать состояние здоровья сердца, что служит ориентиром для клинической вспомогательной диагностики.