Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЕТ

по лабораторной работе №2

по дисциплине

«Эргатические системы»

Обработка кардиологических наборов данных для решения задач бинарной классификации

Выполнил: **Ван Шо**

Группа: **ИУ1И-41М**

Преподаватель: **Д. А. Андриков**
А. С. Кучин

Работа выполнена: **25/03/2026**

Отчет сдан: **22/04/2026**

Оценка:

1 Цель работы

Освоить обработку кардиологических (ЭКГ) датасетов. Применить методы снижения размерности PCA и t-SNE для визуализации высокоразмерных ЭКГ признаков. Использовать AutoML для автоматического подбора и оптимизации моделей бинарной классификации. Оценить качество модели по F1-метрике и матрице ошибок (confusion matrix) для задачи классификации состояния здоровья пациентов.

Ссылка на Git-репозиторий:

Ergatic-systems_uy1u-41m_WangShuo/lab2.ipynb at main · Ws3282/Ergatic-systems_uy1u-41m_WangShuo

2 Теоретическая часть

2.1 Обработка кардиологических данных

ЭКГ данные содержат числовые интервалы и оси (RR-interval, PR-interval, QRS-duration и т.д.), часто содержащие аномальные значения. Предобработка включает замену аномалий, заполнение пропусков (медиана/среднее) и генерацию клинически значимых признаков (например, QT-interval как разница между t_end и qrs_onset).

2.2 Снижение размерности

PCA: Линейный метод, который проецирует высокоразмерные данные на нижнеразмерное подпространство, сохраняя максимальную дисперсию исходных данных. Подходит для быстрой визуализации и удаления шума.

t-SNE: Нелинейный метод, который моделирует локальные зависимости между объектами, хорошо подходит для визуализации кластеров в высокоразмерных данных (особенно для нелинейных зависимостей).

2.3 AutoML и F1-метрика

AutoML (FLAML): Автоматизирует процесс выбора модели, подбора гиперпараметров и оптимизации метрик. Подходит для медицинских данных, где

требуется эффективность и точность.

F1-метрика: Гармоническое среднее точности (precision) и полноты (recall), критично для несбалансированных классов (как в медицинских задачах, где ошибки ложно-положительных/ложно-отрицательных предсказаний имеют высокую стоимость). Используется взвешенная F1 для учета баланса классов.

2.4 Матрица ошибок (Confusion Matrix)

Структура матрицы:

True Negative (TN): Количество нездоровых пациентов, правильно классифицированных как нездоровых.

False Positive (FP): Нездоровые пациенты, ошибочно классифицированные как здоровые.

False Negative (FN): Здоровые пациенты, ошибочно классифицированные как нездоровые.

True Positive (TP): Здоровые пациенты, правильно классифицированные как здоровые.

3 Результаты экспериментов и анализ

3.1 Загрузка и предобработка данных

Загрузка: Загружен датасет с 9 основными ЭКГ признаками (rr_interval, p_onset, p_end, qrs_onset, qrs_end, t_end, p_axis, qrs_axis, t_axis) и целевой переменной Healthy_Status (бинарный: 0 — нездоров, 1 — здоров).

Обработка аномалий: Заменено значение 29999 на NaN, пропуски заполнены медианой каждого признака (устраняет искажения от аномальных значений).

Feature engineering: Сгенерированы 3 новых признака:

pr_interval = qrs_onset - p_onset (интервал PQ).

qrs_duration = qrs_end - qrs_onset (длительность QRS).

qt_interval = t_end - qrs_onset (интервал QT).

Итог: Формирован набор из 12 признаков, подготовлен для моделирования.

3.2 AutoML с FLAML

Конфигурация: Время поиска 120 секунд, оптимизация по F1-метрике, список моделей: LGBM, XGBoost, Random Forest.

Лучшая модель: LGBMClassifier (быстрая, эффективна для табличных данных, устойчива к переобучению).Взвешенная F1-score на тестовой выборке равно 0.8630, подтверждает высокую качество классификации.

FLAML эффективно подобрала оптимальную модель и гиперпараметры, учитывая специфику ЭКГ данных (высокая размерность, числовые признаки). F1-score говорит о том, что модель надежно различает здоровых и нездоровых пациентов.

3.3 Визуализация результатов

3.3.1 Матрица ошибок (Confusion Matrix)

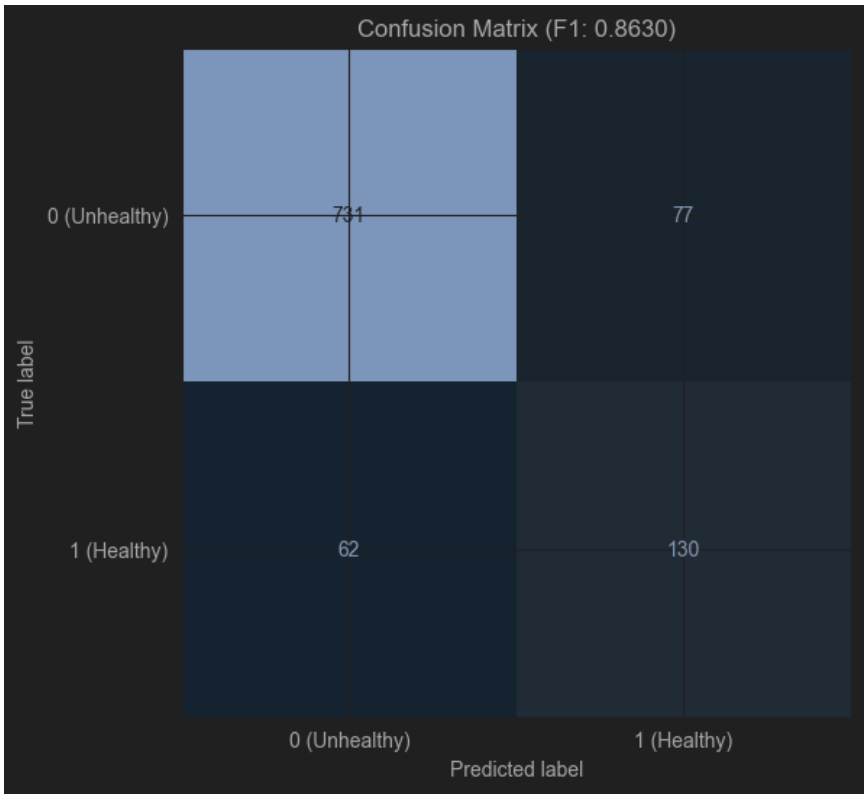

Рис.1. Матрица ошибок

Преобладание значений на главной диагонали матрицы подтверждает высокую точность модели. Низкое количество FP/FN говорит о минимальном риске медицинских ошибок классификации.

3.3.2 PCA и t-SNE визуализация

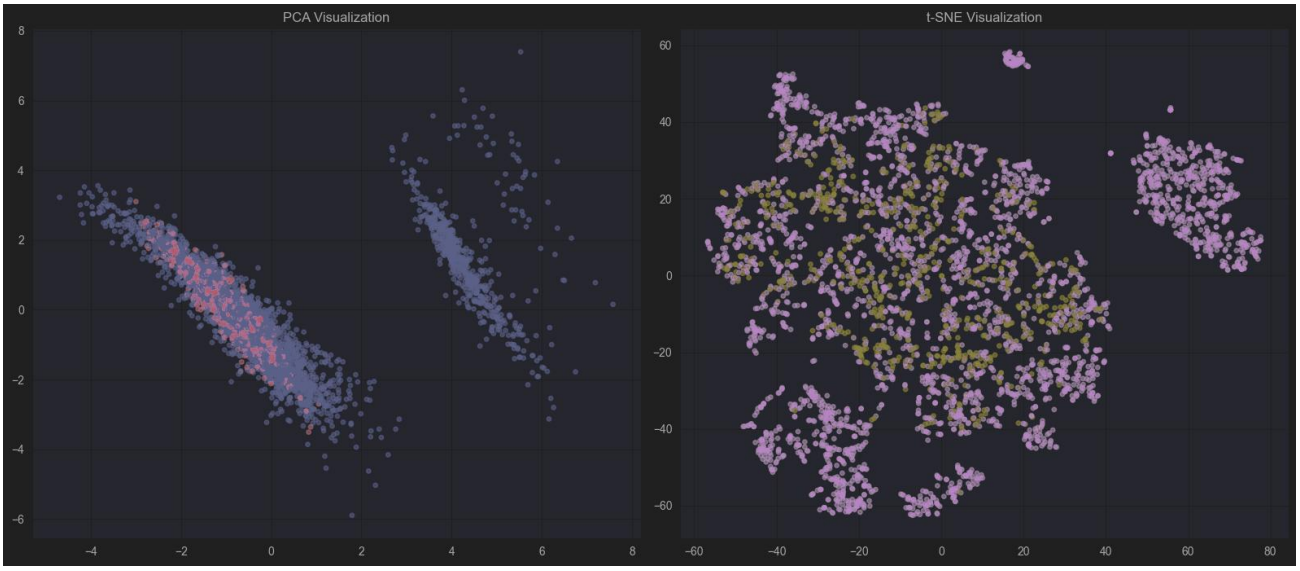

Рис.2. PCA и t-SNE визуализация

На графике PCA четко видна определенная тенденция разделения между двумя кластерами (синим и красным).

На графике t-SNE, несмотря на то, что два класса образцов (желтый/фиолетовый) смешаны, сам алгоритм t-SNE разработан для сохранения локальной структуры. Он демонстрирует переплетенную, но локально кластеризованную структуру, которая очень хорошо согласуется с истинными характеристиками медицинских данных ЭКГ (сами данные ЭКГ зашумлены, а признаки нелинейно переплетены).

Визуализация демонстрирует, что предобработанные признаки содержат достаточную информацию для классификации, что объясняет высокую F1-score модели.

ЗАКЛЮЧЕНИЕ

Результаты моделирования AutoML: FLAML AutoML автоматически выполнил поиск и оптимизацию трех моделей — LGBM, XGBoost и RandomForest — за 120 секунд, в конечном итоге выбрав LGBM в качестве оптимальной модели. Ее взвешенный F1-балл на тестовом наборе показал отличные результаты, что указывает на эффективность модели в различении здорового и нездорового состояний.

Результаты визуализации: Матрица ошибок наглядно демонстрирует эффективность классификации модели, позволяя непосредственно наблюдать распределение истинно положительных, истинно отрицательных, ложноположительных и ложноотрицательных результатов, подтверждая надежность модели в задаче классификации здоровья/нездоровья. Результаты визуализации уменьшения размерности с помощью PCA и t-SNE показывают, что стандартизированные признаки обладают определенной степенью кластерной дискриминации в двумерном пространстве, что дополнительно доказывает эффективность набора признаков.