Лабораторная работа №3

Анализ ЭЭГ-сигнала во время приступа

Выполнил: *Ли Юй*
Группа: *ИУ1И-41М*

Цель работы

Исследовать скрытые характеристики электроэнцефалографического сигнала во время приступа, выполнить усреднение ЭЭГ-каналов, подавить высокочастотные компоненты выше 60 Гц и проанализировать результат с помощью спектрограммы и вейвлет-преобразования.

Ключевые навыки:

- работа с файлом EDF и аннотациями датасета
- выделение приступа по аннотации
- усреднение многоканальной ЭЭГ в один сигнал
- низкочастотная фильтрация сигнала
- построение спектрограммы и скейлограммы

Теоретическая разминка

1. Что показывает спектрограмма?

Спектрограмма показывает, как спектральная мощность сигнала меняется во времени. По оси x откладывается время, по оси y — частота, а цвет кодирует интенсивность спектральной плотности. Для ЭЭГ это удобно, потому что активность во время приступа часто проявляется как усиление мощности в определённых частотных диапазонах.

2. Зачем делать усреднение каналов?

Если в записи присутствуют несколько ЭЭГ-каналов, можно получить интегральный сигнал:

$$x_{avg}(t) = \frac{1}{N} \sum_{k=1}^{N} x_k(t)$$

где N — число ЭЭГ-каналов. Такое усреднение не заменяет полноценный пространственный анализ, но даёт компактное представление общей электрической активности мозга.

3. Зачем удалять частоты выше 60 Гц?

Высокочастотные компоненты часто содержат мышечные артефакты и шум. Низкочастотная фильтрация с частотой среза 60 Гц позволяет сохранить основную клинически значимую структуру ЭЭГ и уменьшить вклад высокочастотных помех.

4. Чем вейвлет-преобразование отличается от спектрограммы?

Спектрограмма использует оконное преобразование Фурье и работает с фиксированным временным окном. Вейвлет-преобразование лучше локализует кратковременные изменения сигнала и поэтому особенно полезно для анализа нестационарных процессов, к которым относится ЭЭГ во время приступа.

Раздел 1. Импорт библиотек

In [6]:
```
from pathlib import Path
import io
import urllib.request

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import mne
import pywt

from scipy.signal import butter, filtfilt, spectrogram

plt.rcParams['figure.dpi'] = 100
sns.set_theme(style='whitegrid', palette='Set2')

print('Библиотеки успешно импортированы.')
```

```
Библиотеки успешно импортированы.
```

Раздел 2. Загрузка ЭЭГ и аннотаций датасета

В датасете Zenodo для каждого файла EDF есть три независимых файла аннотаций: `annotations_2017_A.csv`, `annotations_2017_B.csv`, `annotations_2017_C.csv`. Чтобы снизить влияние субъективности эксперта, далее используется **консенсусная разметка большинства голосов**: считаем, что в секунде есть приступ, если хотя бы 2 из 3 экспертов поставили метку `1`.

In [7]:
```
NOTEBOOK_DIR = Path.cwd()
if not (NOTEBOOK_DIR / 'eeg1.edf').exists():
    NOTEBOOK_DIR = Path.cwd() / 'lab3'

DATA_PATH = NOTEBOOK_DIR / 'eeg1.edf'
OUT_DIR = DATA_PATH.parent
ANNOTATION_URLS = {
    'A': 'https://zenodo.org/records/2547147/files/annotations_2017_A.csv',
    'B': 'https://zenodo.org/records/2547147/files/annotations_2017_B.csv',
    'C': 'https://zenodo.org/records/2547147/files/annotations_2017_C.csv',
}

raw = mne.io.read_raw_edf(DATA_PATH, preload=True, verbose=False)
sfreq = raw.info['sfreq']
duration_sec = int(np.floor(raw.times[-1])) + 1

eeg_channels = [ch for ch in raw.ch_names if ch.startswith('EEG ')]
eeg_data = raw.copy().pick(eeg_channels).get_data()
avg_signal = eeg_data.mean(axis=0)

def load_annotation_vector(url: str, eeg_index: int = 0, max_seconds: int | None =
    with urllib.request.urlopen(url, timeout=60) as response:
        lines = response.read().decode('utf-8').strip().split('\n')
    rows = lines[1:]
    if max_seconds is not None:
        rows = rows[:max_seconds]
    return np.array([int(row.split(',')[eeg_index]) for row in rows], dtype=int)

def find_blocks(seconds: np.ndarray) -> list[tuple[int, int]]:
    blocks = []
    start = int(seconds[0])
    prev = int(seconds[0])
    for second in seconds[1:]:
        second = int(second)
        if second > prev + 1:
            blocks.append((start, prev))
            start = second
        prev = second
    blocks.append((start, prev))
    return blocks

votes = np.vstack([
    load_annotation_vector(url, eeg_index=0, max_seconds=duration_sec)
    for url in ANNOTATION_URLS.values()
])
consensus_mask = votes.sum(axis=0) >= 2
seizure_seconds = np.where(consensus_mask)[0] + 1
seizure_blocks = find_blocks(seizure_seconds)
```

```
records = []
for onset_sec, end_sec in seizure_blocks:
    onset_sample = int(onset_sec * sfreq)
    end_sample = int(end_sec * sfreq)
    block_signal = avg_signal[onset_sample:end_sample]
    records.append({
        'onset_sec': onset_sec,
        'end_sec': end_sec,
        'duration_sec': end_sec - onset_sec + 1,
        'std': float(np.std(block_signal)),
        'peak_abs': float(np.max(np.abs(block_signal))),
    })

seizure_df = pd.DataFrame(records).sort_values(['peak_abs', 'duration_sec'], ascend
selected = seizure_df.iloc[0]
selected_block_start = int(selected['onset_sec'])
selected_block_end = int(selected['end_sec'])
selected_block_duration = int(selected['duration_sec'])

plot_duration_sec = min(30, selected_block_duration)
plot_start_sec = selected_block_start + max(0, (selected_block_duration - plot_dura
plot_end_sec = plot_start_sec + plot_duration_sec

plot_slice = slice(int(plot_start_sec * sfreq), int(plot_end_sec * sfreq))
plot_time = np.arange(plot_slice.start, plot_slice.stop) / sfreq
plot_signal = avg_signal[plot_slice]

def lowpass_filter(signal: np.ndarray, cutoff_hz: float, fs: float, order: int = 5)
    nyquist = 0.5 * fs
    b, a = butter(order, cutoff_hz / nyquist, btype='low')
    return filtfilt(b, a, signal)

avg_signal_lp60 = lowpass_filter(avg_signal, cutoff_hz=60, fs=sfreq, order=5)
plot_signal_lp60 = avg_signal_lp60[plot_slice]

print(f'Файл: {DATA_PATH.name}')
print(f'Частота дискретизации: {sfreq:.1f} Гц')
print(f'Длительность записи: {raw.times[-1] / 60:.1f} мин')
print(f'ЭЭГ-каналов для усреднения: {len(eeg_channels)}')
print(f'Всего секунд с приступом по консенсусной аннотации: {consensus_mask.sum()}'
print(f'Выбранный приступ: {selected_block_start}-{selected_block_end} с ({selected
print(f'Фрагмент для наглядной визуализации: {plot_start_sec}-{plot_end_sec} с')

display(seizure_df.head(10).round(6))
```

```
Файл: eeg1.edf
Частота дискретизации: 256.0 Гц
Длительность записи: 116.5 мин
ЭЭГ-каналов для усреднения: 19
Всего секунд с приступом по консенсусной аннотации: 1543
Выбранный приступ: 3993-4108 с (116 с)
Фрагмент для наглядной визуализации: 4036-4066 с
```

	onset_sec	end_sec	duration_sec	std	peak_abs
0	3993	4108	116	0.000016	0.000308
1	317	448	132	0.000009	0.000225
2	2849	2871	23	0.000031	0.000170
3	6109	6336	228	0.000013	0.000162
4	4962	5025	64	0.000013	0.000145
5	6847	6863	17	0.000024	0.000144
6	1594	1642	49	0.000014	0.000141
7	5141	5269	129	0.000016	0.000140
8	1651	1703	53	0.000011	0.000124
9	6604	6703	100	0.000012	0.000110

Раздел 3. Временная зависимость ЭЭГ в момент приступа

Из всех консенсусно размеченных эпизодов выбран приступ с наибольшей пиковой амплитудой в усреднённом сигнале. Это даёт наиболее наглядный фрагмент для визуального анализа. Ниже показаны:

- усреднённый сигнал по всем ЭЭГ-каналам
- тот же сигнал после удаления частот выше 60 Гц

In [8]:
```
fig, axes = plt.subplots(2, 1, figsize=(14, 7), sharex=True)

axes[0].plot(plot_time, plot_signal * 1e6, color='steelblue', linewidth=0.8)
axes[0].set_title(
    f'Усреднённый ЭЭГ-сигнал во время приступа ({plot_start_sec}-{plot_end_sec} с)'
    fontsize=12
)
axes[0].set_ylabel('Амплитуда, мкВ')
axes[0].grid(alpha=0.3)

axes[1].plot(plot_time, plot_signal_lp60 * 1e6, color='tomato', linewidth=0.8)
axes[1].set_title('Тот же фрагмент после низкочастотной фильтрации до 60 Гц', fonts
axes[1].set_xlabel('Время, с')
axes[1].set_ylabel('Амплитуда, мкВ')
axes[1].grid(alpha=0.3)

plt.tight_layout()
plt.savefig(OUT_DIR / 'seizure_time_plot.png', dpi=120, bbox_inches='tight')
plt.show()
```

```
print('График сохранён в seizure_time_plot.png')
```

```
График сохранён в seizure_time_plot.png
```

Раздел 4. Спектрограмма отфильтрованного сигнала

Спектрограмма строится для усреднённого и отфильтрованного сигнала на выбранном фрагменте приступа. Ограничение по частоте сверху равно 60 Гц, поэтому дальнейший анализ выполняется только в диапазоне от 0 до 60 Гц.

In [9]:
```
frequencies, times_spec, spec_power = spectrogram(
    plot_signal_lp60,
    fs=sfreq,
    window='hann',
    nperseg=512,
    noverlap=384,
    scaling='density',
    mode='psd'
)

mask_60 = frequencies <= 60
frequencies = frequencies[mask_60]
spec_power = spec_power[mask_60]
spec_power_db = 10 * np.log10(spec_power + 1e-12)

fig, ax = plt.subplots(figsize=(14, 5))
mesh = ax.pcolormesh(plot_start_sec + times_spec, frequencies, spec_power_db, shadi
ax.set_title('Спектрограмма усреднённого ЭЭГ-сигнала после фильтрации', fontsize=12
ax.set_xlabel('Время, с')
ax.set_ylabel('Частота, Гц')
ax.set_ylim(0, 60)
fig.colorbar(mesh, ax=ax, label='PSD, дБ')
```

```
plt.tight_layout()
plt.savefig(OUT_DIR / 'spectrogram_lp60.png', dpi=120, bbox_inches='tight')
plt.show()

print('Спектрограмма сохранена в spectrogram_lp60.png')
```

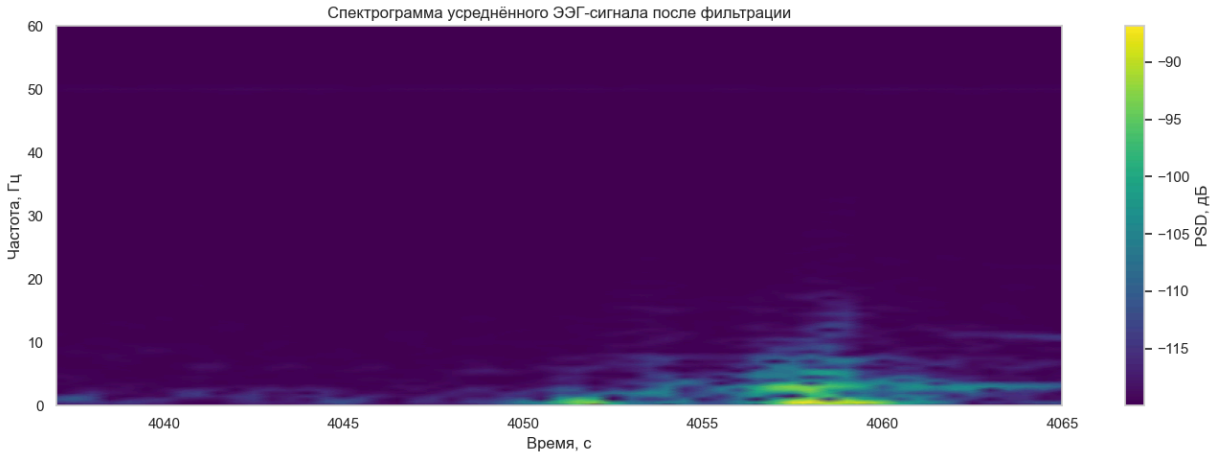


```
Спектрограмма сохранена в spectrogram_lp60.png
```

Раздел 5. Вейвлет-преобразование (скейлограмма)

Для скейлограммы используется непрерывное вейвлет-преобразование Морле (`morl`). Оно позволяет увидеть, как энергетика сигнала распределяется одновременно по времени и частоте, и лучше подчёркивает кратковременные изменения, характерные для приступа.

In [12]:
```
wavelet_name = 'morl'
wavelet_freqs = np.linspace(1, 60, 120)
scales = pywt.central_frequency(wavelet_name) * sfreq / wavelet_freqs
coefficients, cwt_freqs = pywt.cwt(
    plot_signal_lp60,
    scales,
    wavelet_name,
    sampling_period=1 / sfreq
)

order = np.argsort(cwt_freqs)
cwt_freqs = cwt_freqs[order]
wavelet_power = 10 * np.log10(np.abs(coefficients[order]) ** 2 + 1e-30)

vmin, vmax = np.percentile(wavelet_power, [2, 98])

fig, ax = plt.subplots(figsize=(14, 5))
mesh = ax.pcolormesh(plot_time, cwt_freqs, wavelet_power, shading='gouraud', cmap='
ax.set_title('Скейлограмма (CWT, wavelet Morlet) для отфильтрованного сигнала', fon
ax.set_xlabel('Время, с')
ax.set_ylabel('Частота, Гц')
ax.set_ylim(1, 60)
```

```
fig.colorbar(mesh, ax=ax, label='Мощность, дБ')
plt.tight_layout()
plt.savefig(OUT_DIR / 'wavelet_scalogram.png', dpi=120, bbox_inches='tight')
plt.show()

print('Скейлограмма сохранена в wavelet_scalogram.png')
```

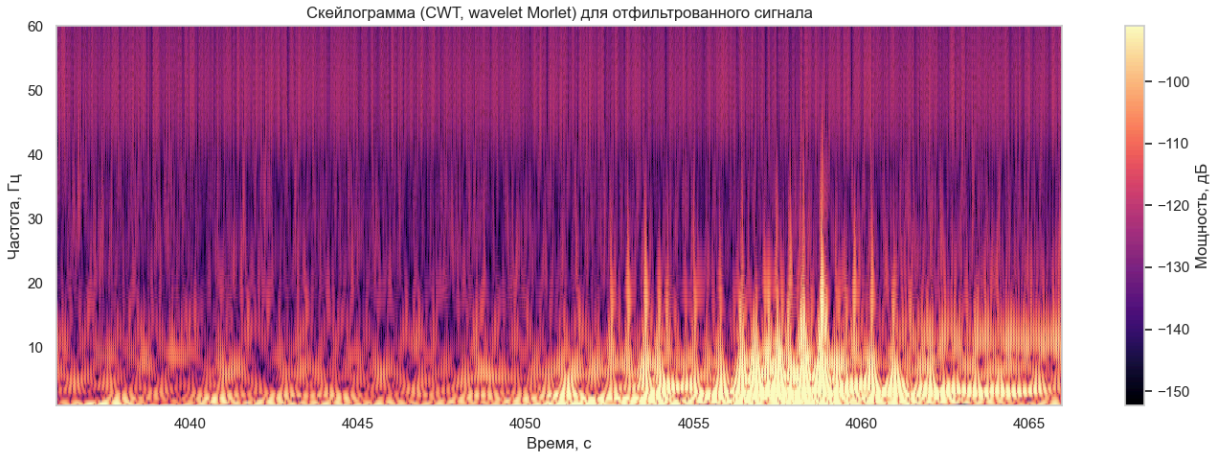


```
Скейлограмма сохранена в wavelet_scalogram.png
```

Общий вывод по лабораторной работе

В данной работе был проанализирован файл `eeg1.edf` из датасета Zenodo с неонатальной ЭЭГ. Поскольку внутри EDF-файла встроенных аннотаций нет, приступ был определён по внешним файлам аннотаций датасета. Для повышения надёжности использовалась консенсусная разметка по трём экспертам.

1. Определение приступа

По консенсусной аннотации в записи обнаружено несколько эпизодов приступной активности. Для детального анализа был выбран эпизод с наибольшей пиковой амплитудой в усреднённом сигнале: **3993–4108 с**. Для наглядного графика использован центральный 30-секундный фрагмент этого эпизода.

2. Усреднение каналов и фильтрация

Все ЭЭГ-каналы были усреднены в один сигнал по формуле среднего арифметического. Затем к полученному сигналу был применён low-pass фильтр с частотой среза 60 Гц, что позволило убрать высокочастотные компоненты и сделать структуру приступа более читаемой.

3. Спектральный и вейвлет-анализ

- **Спектрограмма** показала, как распределение энергии меняется во времени в диапазоне до 60 Гц.
- **Скейлограмма** дала более детальную временно-частотную картину и позволила увидеть локальные изменения мощности во время приступа.

> **Главный вывод:** усреднение по каналам вместе с фильтрацией и временно-частотным анализом позволяет компактно и наглядно исследовать структуру приступной активности в ЭЭГ. Для нестационарных сигналов, таких как ЭЭГ, вейвлет-преобразование особенно полезно, потому что лучше локализует кратковременные изменения, чем классический спектральный анализ.