Лабораторная работа №4

Классификация временных рядов электроэнцефалографии для определения эпилептического приступа

Салех Али 01

29 апреля 2026 г.

Аннотация

В работе выполнена классификация фрагментов электроэнцефалографии на два класса: фрагменты с эпилептическим приступом и фрагменты без приступа. В качестве исходных данных использовались записи пациента `chb08` из открытой базы CHB-MIT Scalp EEG Database. Из исходных EDF-файлов были выделены временные фрагменты фиксированной длительности, после чего для каждого фрагмента построено цветное вейвлет-изображение. Сформированная выборка включала 100 изображений: 50 изображений класса `seizure` и 50 изображений класса `non_seizure`. Для классификации была построена сверточная нейронная сеть. На валидационной выборке получена точность 0,95. Результаты показывают работоспособность предложенного вычислительного конвейера, однако эксперимент имеет учебный характер и не должен рассматриваться как клинически надёжная система диагностики.

Содержание

1 Введение **3**

2 Постановка задачи **3**

3 Исходные данные **4**

4 Формирование выборки **4**

5 Предварительная обработка сигналов **5**

6 Построение цветных вейвлет-скейлограмм **5**

7 Архитектура сверточной нейронной сети **6**

8 Обучение модели **7**

9 Результаты классификации **9**

10 Обсуждение результатов **10**

11 Ограничения эксперимента **11**

12 Выводы **11**

Список использованных источников **12**

1 Введение

Электроэнцефалография является одним из основных методов регистрации электрической активности головного мозга. Сигналы ЭЭГ широко используются при исследовании эпилептической активности, поскольку эпилептический приступ может сопровождаться изменением временной и частотной структуры сигнала.

Обычное представление ЭЭГ во временной области не всегда удобно для автоматической классификации, так как важные признаки могут быть распределены одновременно по времени и частоте. Поэтому в данной работе используется вейвлет-преобразование, позволяющее представить фрагменты ЭЭГ в виде временно-частотных изображений. Такие изображения затем используются как входные данные для сверточной нейронной сети.

Основная идея эксперимента заключается в построении полного вычислительного конвейера: от исходных EDF-записей до обученной CNN-модели, способной различать фрагменты ЭЭГ с приступом и без приступа.

2 Постановка задачи

Целью лабораторной работы является классификация временных рядов электроэнцефалографии для определения эпилептического приступа.

Для достижения цели необходимо выполнить следующие этапы:

1. загрузить записи ЭЭГ из базы CHB-MIT Scalp EEG Database;
2. выбрать EDF-файлы с приступами и без приступов;
3. сформировать обучающую выборку из временных фрагментов ЭЭГ;
4. построить для каждого фрагмента цветное вейвлет-изображение;
5. сохранить изображения в две папки: `seizure` и `non_seizure`;
6. построить сверточную нейронную сеть для бинарной классификации;
7. обучить модель и сохранить её;
8. проверить работу модели на валидационной выборке.

В рамках эксперимента под отдельной записью ЭЭГ понимается временной фрагмент фиксированной длительности, выделенный из исходного EDF-файла.

Такой подход используется из-за учебного характера задания и ограниченного объёма исходных данных.

3 Исходные данные

Для выполнения работы использовалась открытая база данных CHB-MIT Scalp EEG Database, размещённая на платформе PhysioNet. В эксперименте был выбран набор записей пациента `chb08`.

Согласно файлу `chb08-summary.txt`, частота дискретизации сигналов составляет 256 Гц. В файлах пациента `chb08` имеются записи как с зарегистрированными эпилептическими приступами, так и без приступов.

Для класса `seizure` были использованы EDF-файлы, содержащие приступы. Информация о временных интервалах приступов приведена в таблице 1.

Таблица 1: Файлы класса `seizure`

Файл	Начало приступа, с	Конец приступа, с
`chb08_02.edf`	2670	2841
`chb08_05.edf`	2856	3046
`chb08_11.edf`	2988	3122
`chb08_13.edf`	2417	2577
`chb08_21.edf`	2083	2347

Для класса `non_seizure` использовались файлы без зарегистрированных приступов. В их число вошли: `chb08_03.edf`, `chb08_04.edf`, `chb08_10.edf`, `chb08_12.edf`, `chb08_14.edf`, `chb08_15.edf`, `chb08_16.edf`, `chb08_17.edf`, `chb08_18.edf`, `chb08_19.edf`, `chb08_20.edf`, `chb08_22.edf`, `chb08_23.edf`, `chb08_24.edf` и `chb08_29.edf`.

4 Формирование выборки

Исходные EDF-записи были разделены на временные фрагменты длительностью 8 секунд. Для класса `seizure` фрагменты извлекались только из аннотированных интервалов приступов. Для класса `non_seizure` фрагменты извлекались из файлов, в которых приступы не были зарегистрированы.

Итоговая выборка была сбалансированной:

- 50 изображений класса `seizure`;

- 50 изображений класса `non_seizure`;
- всего 100 изображений.

Такое соотношение классов позволяет избежать смещения модели в сторону одного класса на этапе обучения.

5 Предварительная обработка сигналов

Каждый фрагмент ЭЭГ проходил предварительную обработку. Сначала из EDF-файла извлекался многоканальный фрагмент сигнала. Далее выбирались общие каналы, присутствующие во всех использованных файлах. Амплитуды сигналов переводились в микровольты.

Для подавления высокочастотных шумовых компонент применялась низкочастотная фильтрация с граничной частотой 60 Гц. После этого сигнал нормализовался. Нормализация необходима для уменьшения влияния различий амплитуд между фрагментами и для более устойчивого обучения нейронной сети.

Общая схема предварительной обработки включала:

1. загрузку EDF-файла;
2. выделение временного фрагмента;
3. выбор общих EEG-каналов;
4. фильтрацию сигнала до 60 Гц;
5. нормализацию;
6. построение вейвлет-скейлограммы;
7. сохранение цветного изображения.

6 Построение цветных вейвлет-скейлограмм

Для каждого временного фрагмента строилось непрерывное вейвлет-преобразовани
В работе использовался вейвлет Морле, который хорошо подходит для анализа нестационарных биомедицинских сигналов.

После вычисления коэффициентов вейвлет-преобразования рассчитывалась карта мощности:

$$P(a,b) = |W(a,b)|^2,$$

где $W(a,b)$ — коэффициенты вейвлет-преобразования, a — масштаб, b — временной сдвиг.

Полученная карта мощности нормализовалась и преобразовывалась в цветное RGB-изображение с использованием цветовой карты `turbo`. Размер каждого изображения составлял 128×128 пикселей.

Примеры цветных вейвлет-скейлограмм представлены на рисунке 1.

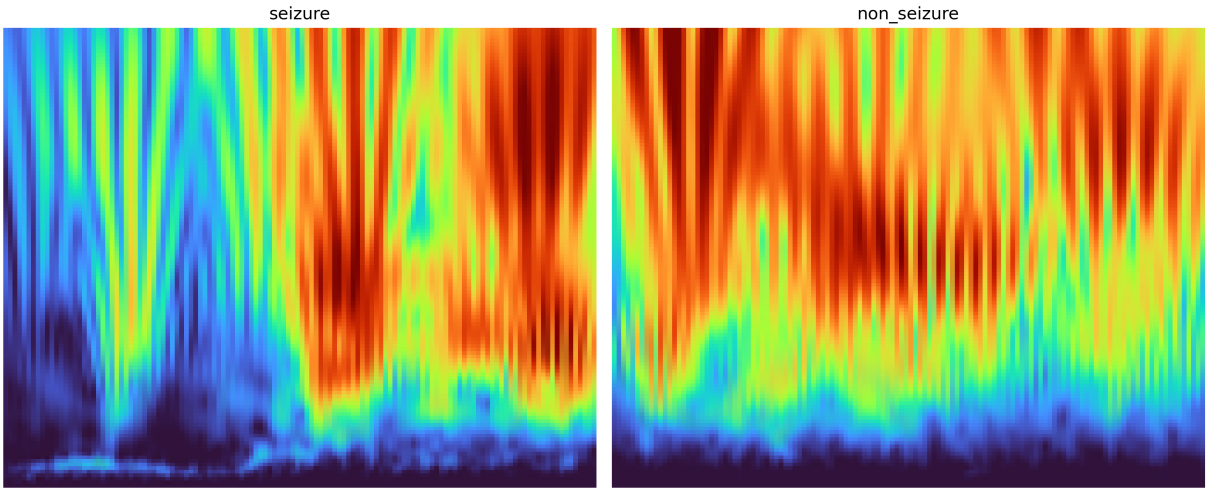

Рис. 1: Примеры цветных вейвлет-скейлограмм для классов `seizure` и `non_seizure`

Из рисунка видно, что каждый фрагмент ЭЭГ представлен как временно-частотная карта. Такое представление удобно для сверточных нейронных сетей, поскольку CNN способна выделять локальные пространственные признаки на изображении.

7 Архитектура сверточной нейронной сети

Для классификации изображений была построена сверточная нейронная сеть. Входом модели являлось цветное изображение размером $128 \times 128 \times 3$.

Обобщённая структура сети представлена в таблице 2.

Таблица 2: Структура CNN-модели

Этап	Описание
Входной слой	RGB-изображение $128 \times 128 \times 3$
Нормализация	Масштабирование значений пикселей к диапазону $[0, 1]$
Conv2D + MaxPooling	Выделение локальных признаков изображения
Conv2D + MaxPooling	Формирование более глубокого признакового представления
Conv2D + MaxPooling	Выделение сложных пространственных признаков
GlobalAveragePooling2D	Снижение размерности признакового пространства
Dropout	Снижение риска переобучения
Dense	Полносвязная классификационная часть
Выходной слой	Один нейрон с функцией активации sigmoid

Так как задача является бинарной, на выходе модели использовалась сигмоидальная функция активации. В качестве функции потерь применялась binary cross-entropy:

$$L = -\frac{1}{N} \sum_{i=1}^{N} \left[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \right],$$

где y_i — истинная метка класса, $\hat{y}_i$ — предсказанная вероятность принадлежности к классу `seizure`.

8 Обучение модели

Выборка была разделена на обучающую и валидационную части в соотношении 80/20. При разбиении использовалась стратификация, чтобы в обеих частях присутствовали изображения обоих классов.

Основные параметры обучения приведены в таблице 3.

Таблица 3: Параметры обучения

Параметр	**Значение**
Общее число изображений	100
Изображений класса `seizure`	50
Изображений класса `non_seizure`	50
Размер изображения	128×128
Тип изображения	RGB
Длительность фрагмента	8 с
Исходная частота дискретизации	256 Гц
Граничная частота фильтрации	60 Гц
Оптимизатор	Adam
Функция потерь	Binary cross-entropy
Размер batch	8

Динамика точности модели представлена на рисунке 2.

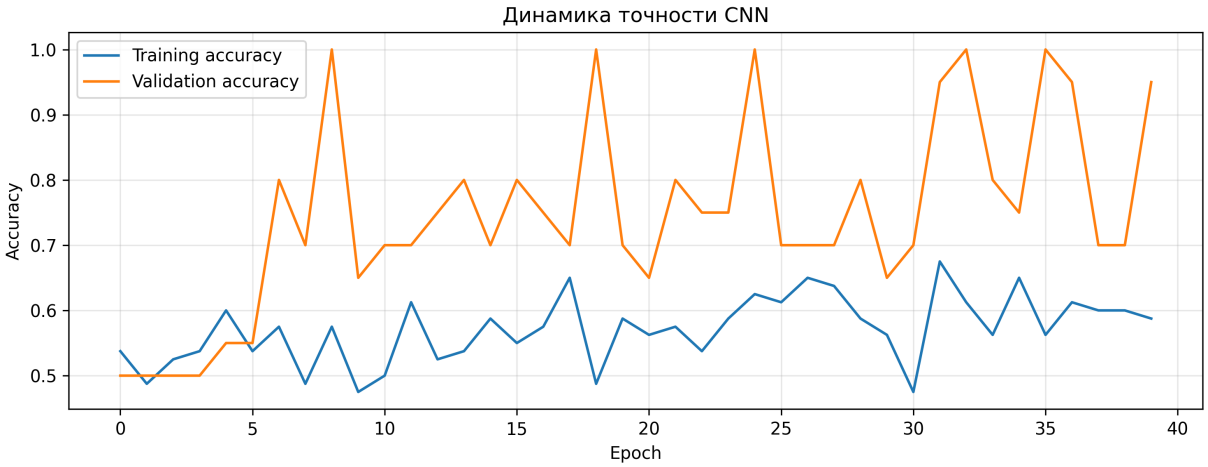

Рис. 2: Динамика точности CNN в процессе обучения

Динамика функции потерь представлена на рисунке 3.

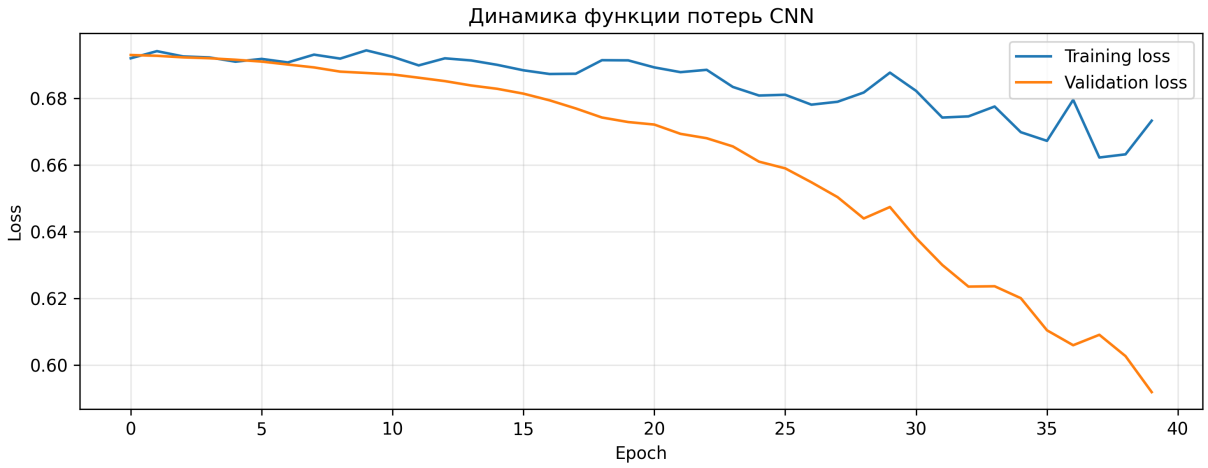

Рис. 3: Динамика функции потерь CNN в процессе обучения

Колебания валидационной точности объясняются небольшим размером валидационной выборки. При 20 изображениях изменение результата всего на один объект соответствует изменению accuracy на 0,05. Поэтому скачки между соседними эпохами не следует рассматривать как устойчивые изменения качества модели.

9 Результаты классификации

После обучения модель была проверена на валидационной выборке. Итоговая точность составила:

$$Accuracy = 0{,}95.$$

Подробные метрики классификации представлены в таблице 4.

Таблица 4: Метрики классификации

Класс	**Precision**	**Recall**	**F1-score**	**Support**
`non_seizure`	0,91	1,00	0,95	10
`seizure`	1,00	0,90	0,95	10
Accuracy	0,95			20
Macro avg	0,95	0,95	0,95	20
Weighted avg	0,95	0,95	0,95	20

Матрица ошибок приведена на рисунке 4.

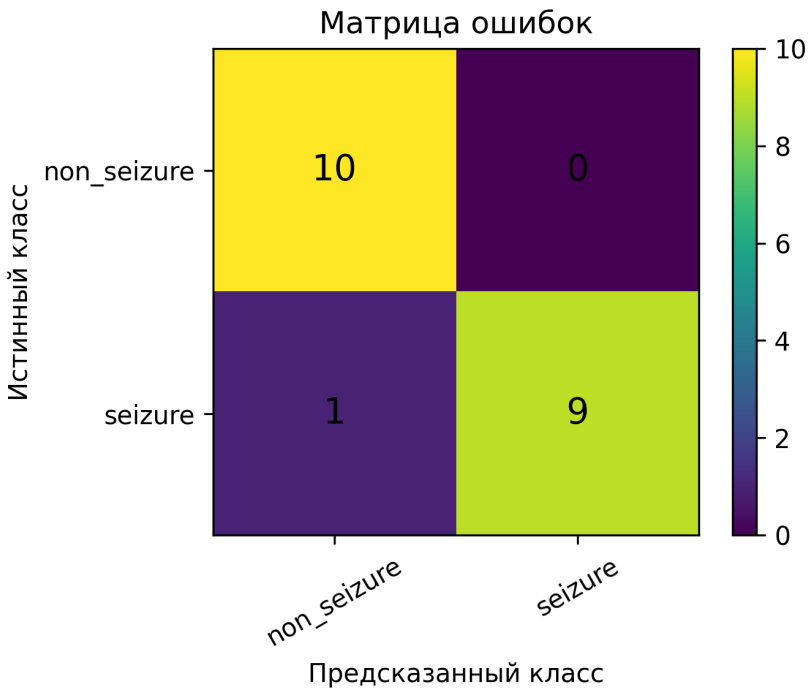

Рис. 4: Матрица ошибок CNN-классификатора

Из матрицы ошибок следует:

- все 10 фрагментов класса `non_seizure` были классифицированы правильно;
- 9 из 10 фрагментов класса `seizure` были классифицированы правильно;
- один фрагмент класса `seizure` был ошибочно отнесён к классу `non_seizure`.

Таким образом, модель показала высокую точность на валидационной выборке в рамках учебного эксперимента.

10 Обсуждение результатов

Полученные результаты показывают, что цветные вейвлет-скейлограммы являются эффективным представлением фрагментов ЭЭГ для задачи бинарной классификации. В отличие от исходного временного сигнала, скейлограмма одновременно содержит информацию о времени и частоте, что позволяет CNN выделять различия между фрагментами с приступом и без приступа.

Положительным результатом является то, что модель не сместилась в сторону одного класса. Она корректно классифицировала все фрагменты без приступа и большинство фрагментов с приступом. Значение recall для класса `seizure` составило 0,90, что означает обнаружение 9 из 10 приступных фрагментов.

Однако результат необходимо интерпретировать осторожно. Несмотря на высокую точность 0,95. Выборка была сформирована из ограниченного числа EDF-файлов одного пациента. Кроме того, изображения являются временными фрагментами исходных записей, а не полностью независимыми клиническими наблюдениями. Поэтому полученную точность нельзя рассматривать как клинически надёжную оценку качества классификатора.

11 Ограничения эксперимента

Основные ограничения проведённого эксперимента:

1. использованы данные только одного пациента `chb08`;
2. общий объём выборки ограничен 100 изображениями;
3. изображения сформированы из временных фрагментов EDF-записей;
4. валидационная выборка содержит только 20 изображений;
5. модель предназначена для демонстрации вычислительного подхода, а не для медицинской диагностики.

Для повышения надёжности классификатора в дальнейших исследованиях необходимо использовать данные нескольких пациентов, увеличить число фрагментов, выполнить разделение данных по пациентам или по EDF-файлам, а также провести более строгую перекрёстную проверку.

12 Выводы

В лабораторной работе был реализован вычислительный конвейер для классификации фрагментов ЭЭГ на два класса: `seizure` и `non_seizure`. В качестве исходных данных использовались записи пациента `chb08` из базы CHB-MIT Scalp EEG Database.

Была сформирована сбалансированная выборка из 100 цветных вейвлет-скейлограмм. Каждый фрагмент ЭЭГ длительностью 8 секунд был преобразован в RGB-изображение размером 128×128 пикселей. После этого изображения использовались для обучения сверточной нейронной сети.

На валидационной выборке была получена точность 0,95. Для класса `seizure` значение recall составило 0,90, а для класса `non_seizure` — 1,00. Это показывает, что построенная модель способна различать фрагменты ЭЭГ с приступом и без приступа в рамках сформированной учебной выборки.

Поставленная цель лабораторной работы была достигнута: обучающая выборка сформирована, цветные вейвлет-изображения построены, сверточная нейронная сеть создана и обучена, модель сохранена и проверена на валидационных данных.

Список литературы

[1] Goldberger A. L., Amaral L. A. N., Glass L., Hausdorff J. M., Ivanov P. Ch., Mark R. G., Mietus J. E., Moody G. B., Peng C.-K., Stanley H. E. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals // Circulation. 2000.

[2] Shoeb A. H., Guttag J. V. Application of Machine Learning to Epileptic Seizure Detection // Proceedings of the 27th International Conference on Machine Learning. 2010.

[3] Mallat S. A Wavelet Tour of Signal Processing. Academic Press, 1999.

[4] LeCun Y., Bengio Y., Hinton G. Deep learning // Nature. 2015. Vol. 521. P. 436–444.

[5] Goodfellow I., Bengio Y., Courville A. Deep Learning. MIT Press, 2016.