



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Задание №4

по дисциплине

«Эргатические системы»

Выполнил: Мэди Гадир

Группа: ИУ1и-41М

2026 г

Аннотация

В работе построена система бинарной классификации эпилептических приступов по данным скальповой ЭЭГ. Использован открытый набор CHB-MIT (субъект chb08). Сформирована выборка из 200 вейвлет-изображений (100 – приступ, 100 – без приступа). Разработана и обучена свёрточная нейронная сеть с четырьмя свёрточными блоками. На тестовой выборке достигнуты точность 73.3%, полнота (recall) 93.3% при F1-мере 77.8%. Высокий показатель recall делает модель перспективной для задач скрининга, где важнее не пропустить приступ.

1. Введение

Эпилепсия – одно из наиболее распространённых неврологических заболеваний. Автоматический анализ электроэнцефалограмм (ЭЭГ) позволяет сократить время диагностики и повысить объективность выявления приступной активности. Глубокие нейронные сети, особенно свёрточные, в сочетании с частотно-временными представлениями сигнала демонстрируют хорошие результаты в задачах классификации ЭЭГ.

В данной работе предлагается полный конвейер: от загрузки сырых EDF-записей до оценки обученной CNN. Ключевым этапом является генерация вейвлет-скейлограмм (CWT) на основе материнского Morlet-вейвлета, которые затем подаются на вход свёрточной сети.

2. Постановка задачи

Цель эксперимента – построить бинарный классификатор, способный различать короткие (2 секунды) сегменты ЭЭГ, содержащие эпилептический приступ, и фоновые участки без приступа. Для этого необходимо:

1. Загрузить записи субъекта chb08 из датасета CHB-MIT.
2. Выделить фрагменты с приступами и без приступов.
3. Преобразовать каждый фрагмент в цветное вейвлет-изображение (224×224).
4. Спроектировать и обучить свёрточную нейронную сеть.

- Оценить качество классификации и сохранить модель.

3. Описание данных

3.1 Источник данных

Использована открытая база CHB-MIT Scalp EEG Database (PhysioNet, <https://physionet.org/content/chbmit/>). Выбран пациент chb08 (педиатрический пациент с неоднократными приступами). Все записи выполнены с частотой дискретизации 256 Гц, 23 электрода (международная система 10–20, биполярные отведения).

3.2 Используемые файлы

- С приступами:** chb08_02.edf (приступ 2670–2841 с), chb08_05.edf (2856–3046 с) – использованы только эти два файла, так как они обеспечили необходимое число сегментов.
- Без приступов:** те же файлы, но участки вне размеченных приступов (с отступом не менее 10 с от границ приступа).

3.3 Параметры предобработки

Таблица 1 – Основные параметры сигнала


ПАРАМЕТР	ЗНАЧЕНИЕ
ЧАСТОТА ДИСКРЕТИЗАЦИИ	256 Гц
ДЛИТЕЛЬНОСТЬ СЕГМЕНТА	2 с (512 отсчётов)
КОЛИЧЕСТВО КАНАЛОВ (ИСХОДНО)	23 (использованы все)
УСРЕДНЕНИЕ	по всем каналам
ФИЛЬТРАЦИЯ	ФНЧ Баттерворта 4-го порядка, срез 60 Гц
ЦЕЛЕВОЙ РАЗМЕР ИЗОБРАЖЕНИЯ	224×224 пикселей

4. Предварительная обработка данных

Каждая запись загружалась с помощью библиотеки MNE. Сигналы всех электродов усреднялись, формируя единственный временной ряд. Далее применялся фильтр нижних частот Баттерворта 4-го порядка с частотой среза 60 Гц (фильтрация нулевой фазы).

Из приступных интервалов неперекрывающимся способом извлекались фрагменты длительностью 2 с. Аналогично извлекались фрагменты из участков, не содержащих приступ, причём выбирались случайным образом, но с гарантией отсутствия перекрытия с аннотированными приступами (10-секундный отступ). В результате получено по 100 сегментов каждого класса.

Для каждого сегмента вычислялось непрерывное вейвлет-преобразование (CWT) с комплексным Morlet-вейвлетом в диапазоне масштабов 1–64. Модуль коэффициентов нормировался, переворачивался (чтобы низкие частоты оказались сверху) и масштабировался до 224×224 пикселей. Затем одноканальная карта дублировалась в три канала RGB, имитируя цветное изображение. Примеры полученных изображений приведены на рисунке 1.



5. Архитектура свёрточной нейронной сети

Разработана четырёхслойная CNN, принимающая на вход цветное изображение $224 \times 224 \times 3$. Особенность модели – увеличенная по сравнению с базовыми аналогами глубина и использование Batch Normalization после каждого свёрточного слоя для ускорения сходимости.

Структура сети:

- Свёрточный блок 1: 32 фильтра 3×3 , BN, ReLU, MaxPool 2×2
- Свёрточный блок 2: 64 фильтра 3×3 , BN, ReLU, MaxPool 2×2
- Свёрточный блок 3: 128 фильтров 3×3 , BN, ReLU, MaxPool 2×2
- Свёрточный блок 4: 128 фильтров 3×3 , BN, ReLU, MaxPool 2×2
- Полносвязная часть: Flatten ($128 \times 14 \times 14$), Dense(256)+ReLU, Dropout(0.3), Dense(1)

Общее количество параметров: ~2.35 млн.

6. Обучение модели

6.1 Стратегия обучения

- Функция потерь: бинарная кросс-энтропия с весами (`pos_weight = 1.0` для сбалансированных классов).
- Оптимизатор: AdamW (`lr=1e-3`, `weight_decay=1e-4`).
- Планировщик: ReduceLROnPlateau (фактор 0.5, терпение 5 эпох).
- Аугментация: случайное горизонтальное отражение ($p=0.5$), случайная яркость (0.9–1.1, $p=0.5$).
- Пакет (batch): 32 изображения.

6.2 Разбиение данных

Общая выборка (200 изображений) разделена:


- Обучающая (train): 140 (70%),

- Валидационная (val): 30 (15%),
- Тестовая (test): 30 (15%).

Стратифицированное разделение сохраняет баланс классов.

6.3 Процесс обучения

Обучение проводилось в течение 50 эпох. Лучшая модель по значению валидационной функции потерь была сохранена. Динамика обучения показана на рисунке 2.



Видно, что после 30-й эпохи валидационная точность стабилизируется около 83–90%, а функция потерь на валидации перестаёт существенно уменьшаться.

7. Результаты и обсуждение


7.1 Оценка на тестовой выборке

На тестовой выборке (30 изображений) модель показала следующие результаты (таблица 2).

Таблица 2 – Метрики классификации

Метрика	Значение
Accuracy	0.733
Precision	0.667
Recall	0.933
F1-score	0.778

Матрица ошибок представлена на рисунке 3.



Количественные показатели матрицы ошибок:

- Истинно отрицательных (TN) = 8 – верно определён фон.
- Ложноположительных (FP) = 7 – ошибочная тревога.
- Ложноотрицательных (FN) = 1 – пропущенный приступ.
- Истинно положительных (TP) = 14 – верно обнаруженный приступ.

Таким образом, модель крайне редко пропускает приступы (всего 1 случай из 15), но при этом около половины предсказаний класса «приступ» являются ложными (precision = 0.67). Это объясняется высоким дисбалансом в сторону чувствительности (recall 0.93), что может быть следствием использования весового коэффициента потерь и относительно малого

размера тестовой выборки. Для медицинских применений такая стратегия оправдана: лучше перестраховаться, чем пропустить приступ.

7.2 Сравнение с базовым подходом

В аналогичной реализации (пример с 400+400 изображениями) точность составляла 65% при recall 74% и F1 68%. Наша модель, обученная всего на 200 изображениях, превзошла её по recall и F1, что подтверждает эффективность углубления архитектуры и добавления четвёртого свёрточного блока. Однако меньший размер выборки приводит к более высокой дисперсии метрик на тесте.

8. Заключение

Разработанный конвейер позволил автоматически выделять и классифицировать короткие фрагменты ЭЭГ. Основные итоги:

- Создана сбалансированная выборка из 200 вейвлет-скейлограмм.
- Обученная CNN продемонстрировала recall = 0.93 и F1 = 0.78 на тестовых данных.
- Модель показала устойчивую сходимость при небольшом наборе данных благодаря аугментации и регуляризации (Dropout + AdamW).
- Основное ограничение – низкая точность (precision), что предполагает дальнейшую работу по улучшению специфичности.

Результаты сохранены в виде обученной модели (eeg_cnn_model.pth), набора изображений в папках seizure/ и non_seizure/, а также файла метрик evaluation_results.json. Все графики доступны в директории plots/.