



Московский государственный технический университет
Факультет ИУ «Информатика и системы управления»
Кафедра ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Эргагические системы

**Классификация временных рядов электроэнцефалограмм для
выявления эпилепсии**

Лабораторной работе №4

Выполнил: Ван Цзюньтао

Группа: ИУ1И-41М

Проверил: Андриков, Д.А.

Москва 2026

Цель работы: С помощью вейвлет-преобразования преобразовать временные ряды ЭЭГ в частотно-временные изображения, чтобы получить двумерное представление сигнала.

Построить сверточную нейронную сеть (CNN) для классификации вейвлет-изображений ЭЭГ с целью распознавания эпилептических приступов и состояний, не связанных с приступами.

Освоить полный процесс обработки данных от исходного сигнала ЭЭГ до модели классификации на основе глубокого обучения.

Оценить классификационные характеристики модели CNN при распознавании эпилептических приступов (точность, коэффициент F1).

Теоретические основы

1. Непрерывное вейвлет-преобразование (CWT)

Непрерывное вейвлет-преобразование отображает одномерный временной сигнал в двумерную плоскость «время-частота», обеспечивая многоразрешающий анализ с помощью вейвлет-базисных функций Морле с переменным масштабом. CWT обладает высоким частотным разрешением в низкочастотном диапазоне и высоким временным разрешением в высокочастотном диапазоне, что позволяет эффективно улавливать переходные изменения частоты в сигналах ЭЭГ во время эпилептических приступов. Карта вейв-масштабов, представляющая собой изображение сигнала во временной и частотной областях, может быть напрямую введена в CNN для распознавания образов.

2. Сверточная нейронная сеть (CNN)

Сверточная нейронная сеть является одной из наиболее успешных архитектур для классификации изображений в области глубокого обучения. CNN извлекает локальные признаки (края, текстуру) с помощью сверточных слоев, уменьшает пространственную размерность с помощью слоев пулинга и осуществляет высокоуровневое семантическое выведение с помощью полностью связанных слоев. В данном эксперименте используется классическая структура из 4 слоев Conv2D + MaxPooling в сочетании с регуляризацией Dropout и усилением данных для предотвращения переобучения на небольших наборах данных. Для реализации бинарной классификации (эпилепсия/не эпилепсия) используется выходной слой Sigmoid.

Практическая часть

Описание набора данных

1. Источник данных

В данном эксперименте использованы записи ЭЭГ пациента chb08 из базы данных CHB-MIT. chb08 содержит несколько групп файлов EDF (каждый файл длится около 1 часа), в общей сложности 23 канала ЭЭГ с частотой дискретизации 256 Гц. В данном эксперименте использованы 8 загруженных файлов EDF, из которых 4 файла содержат достоверные экспертные аннотации эпилептических приступов, всего 4 приступа.

2. Извлечение фрагментов и статистика набора данных

Из файлов с приступами эпилепсии в пределах помеченных интервалов приступов с помощью метода скользящего окна были извлечены фрагменты ЭЭГ длиной 10 секунд с шагом окна 5 секунд. Из файлов без приступов были случайным образом извлечены фрагменты одинаковой длины. После усреднения по каналам и низкочастотной фильтрации 60 Гц для каждого фрагмента с помощью вейвлет-преобразования Морле были сгенерированы изображения масштабных карт. Для визуализации изображений использовался двухэтапный метод глобальной нормализации: сначала вычисляются глобальные 5% и 99% квантили мощности вейвлетов для всех эпилептических фрагментов, а затем все изображения визуализируются с использованием единого соотношения v_{min}/v_{max} , что обеспечивает сохранение различий в мощности между категориями «эпилептический» и «неэпилептический». Окончательный набор данных включает 146 эпилептических изображений и 150 неэпилептических изображений.

Таблица 1. Статистика набора экспериментальных данных

Категория	Количество изображений	Продолжительность фрагмента	Количество исходных файлов
Эпилептический приступ (Seizure)	146	10 с	4
Неэпилептический приступ (Non-seizure)	150	10 с	4
Всего	196	/	8

3. Примеры вейвлет-изограмм

На рисунках 1 и 2 представлены типичные вейвлет-изограммы для фрагментов с приступами эпилепсии и без них соответственно. Можно заметить, что на вейвлет-изограммах, относящихся к периоду приступа, в низкочастотном диапазоне (1–10 Гц) наблюдается значительно более сильная концентрация энергии, тогда как в фрагментах без приступов распределение энергии относительно равномерно, а уровень мощности ниже.




Рис. 1. Пример вейвлет-диаграммы ЭЭГ при эпилептическом приступе




Рис. 2. Пример вейвлет-диаграммы ЭЭГ вне приступа

Моделирование и реализация эксперимента

1. Предварительная обработка ЭЭГ и извлечение фрагментов

С помощью MNE-Python считываются файлы EDF и отбираются 23 канала ЭЭГ. Для каждого файла EDF: усредните все каналы в одноканальный сигнал, примените низкочастотный фильтр Баттерворта 6-го порядка (частота среза 60 Гц) для удаления высокочастотного шума. Из области приступа эпилепсии извлеките скользящее окно длительностью 10 секунд (шаг 5 секунд), из файлов без приступов случайным образом извлеките фрагменты одинаковой длины.

2. Получение вейвлет-изображений

Для каждого 10-секундного фрагмента ЭЭГ с помощью вейвлетов Морле (Morlet) вычисляется непрерывное вейвлет-преобразование (CWT) в диапазоне частот 1–60 Гц (224 масштаба) и получается плотность спектра мощности (в дБ). Применяется двухэтапная стратегия глобальной нормализации: сначала вычисляются глобальные 5% и 99% квантили мощности вейвлетов для всех эпилептических фрагментов в качестве унифицированных

значений v_{min}/v_{max} , а затем с помощью этого глобального цветового отображения все изображения визуализируются в виде файлов PNG размером 224×224 пикселей. Данный метод обеспечивает сохранение различий в мощности между изображениями разных категорий, предотвращая потерю информации, вызванную независимой нормализацией каждого изображения.

3. Структура и обучение CNN-модели

Используется облегченная 3-слойная сверточная нейронная сеть, адаптированная к небольшому набору данных: Conv2D(24)→BatchNorm→MaxPool → Conv2D(48)→BatchNorm→MaxPool → Conv2D(96)→BatchNorm→MaxPool → GlobalAveragePooling → Dropout(0.6) → Dense(64, $L2=2e-4$) → Dropout(0.4) → Dense(1, sigmoid). Размер входных данных 128×128 , оптимизатор Adam с затуханием скорости обучения CosineDecay (начальная $lr=2e-4$, конечная $lr=5e-6$), функция потерь Binary Cross-Entropy. Обучение 100 эпох (раннее прекращение $patience=30$, автоматическое завершение на 74-й эпохе), размер партии 16, 75/25 обучение/ тестовый набор. Использовано усиление данных (случайное горизонтальное отражение, поворот на 15° , масштабирование на 20%, сдвиг на 15%) и балансировка весов классов. Для предотвращения переобучения на небольшом наборе данных использованы BatchNormalization, L2-регуляризация и высокий уровень Dropout.

Результаты эксперимента и анализ

1. График во временной области многоканальной ЭЭГ

На рисунке 3 показаны кривые изменения потери и точности модели CNN в зависимости от эпохи. Модель достигла точности 98,65% и F1-показателя 0,9867 на тестовом наборе. Коэффициент отклика для эпилептических приступов составил 100% (37/37), а для неэпилептических образцов — 97% (36/37); только 1 неэпилептический образец был ошибочно классифицирован. В ходе обучения точность на валидационном наборе стабильно повышалась с примерно 50% до более 98%. Метод CNN на основе вейвлет-изображений продемонстрировал отличную осуществимость и перспективы применения в задаче классификации ЭЭГ при эпилепсии.




Рис. 3. Кривые потерь и точности в процессе обучения CNN

На рис. 4 представлена матрица путаницы для тестового набора, наглядно демонстрирующая результаты классификации моделью образцов с эпилепсией и без эпилепсии. Модель успешно распознала все 37 образцов эпилептических приступов (коэффициент восстановления 100%), и только 1 неэпилептический образец был ошибочно классифицирован как эпилептический (коэффициент восстановления для неэпилептических образцов 97%). Точность распознавания неэпилептических образцов достигает 100%, что свидетельствует о чрезвычайно высокой чувствительности и специфичности модели в отношении эпилептических приступов, при этом риск пропуска практически отсутствует.




Рис. 4. Матрица путаницы тестового набора

Выводы

В данном эксперименте удалось извлечь и построить набор данных вейвлет-изображений из данных пациентов chb08 базы данных CHB-MIT, включающий 296 аннотированных изображений двух типов: эпилептических и неэпилептических.

С помощью непрерывного вейвлет-преобразования (Morlet CWT) 10-секундные фрагменты ЭЭГ были преобразованы в картины временного и частотного масштабов, что позволило эффективно преобразовать одномерную задачу классификации временных рядов в двумерную задачу классификации изображений.

Построенная 3-слойная CNN-модель достигла на тестовом наборе точности 98,65% и F1-показателя 0,9867, что подтвердило осуществимость метода автоматического обнаружения эпилепсии на основе вейвлет-изображений и глубокого обучения.

Усиление данных (отражение, поворот, масштабирование) и регуляризация Dropout эффективно смягчили проблему переобучения в условиях небольшого количества образцов и повысили способность модели к обобщению..