



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

КАФЕДРА

ИУ-1 «Системы автоматического управления»

ОТЧЕТ

по лабораторной работе №4

по дисциплине

«Эргатические системы»

**Классификация сигналов ЭЭГ для диагностики эпилепсии на
основе вейвлет-анализа и сверточных нейронных сетей**

Выполнил: Ван Шо

Группа: ИУ1И-41М

**Преподаватель: Д. А. Андриков
А. С. Кучин**

Работа выполнена: 10/05/2026

Отчет сдан: 11/05/2026

Оценка:

1 Цель работы

Исследование скрытых признаков нестационарных сигналов электроэнцефалографии (ЭЭГ), выявление паттернов, соответствующих эпилептическим припадкам.

Освоение методов предварительной обработки ЭЭГ, непрерывного вейвлет-преобразования (CWT) для построения скалограмм и классификации сигналов с помощью сверточных нейронных сетей (CNN).

Ссылка на Git-репозиторий:

[Ergatic-systems_uylu-41m_WangShuo/lab4.ipynb at main · Ws3282/Ergatic-systems_uylu-41m_WangShuo](#)

2 Теоретическая часть

2.1 ЭЭГ и эпилептические припадки

Электроэнцефалография (ЭЭГ) представляет собой метод регистрации электрической активности нейронов головного мозга. Сигналы ЭЭГ относятся к классу нестационарных временных рядов, их характеристики изменяются во времени.

Эпилептические припадки сопровождаются аномальной синхронной активностью нейронов, что проявляется в виде высокоамплитудных всплесков, изменении доминантных частот и появлении специфических паттернов в сигнале. Такие особенности не всегда различимы при визуальном анализе, поэтому требуется применение методов математической обработки и машинного обучения.

2.2 Непрерывное вейвлет-преобразование (CWT)

Непрерывное вейвлет-преобразование является эффективным инструментом анализа нестационарных сигналов. Оно позволяет преобразовать одномерный временной сигнал в двумерное представление «время-частота», сохраняя высокую разрешающую способность как в низкочастотной, так и в высокочастотной областях.

Вейвлет-скалограммы, полученные в результате преобразования, наглядно отображают динамику изменения частотного состава сигнала во времени. Это делает их идеальным форматом для последующей классификации с использованием методов компьютерного зрения и сверточных нейронных сетей.

2.3 Классификация с помощью CNN

Сверточные нейронные сети демонстрируют высокую эффективность в задачах извлечения пространственных признаков из изображений. CNN способны автоматически выявлять характерные особенности без ручного задания признаков, что критически важно для анализа сложных биомедицинских данных.

В данной работе вейвлет-скалограммы сигналов ЭЭГ используются как входные изображения для обучения сверточной нейронной сети. Сеть решает задачу бинарной классификации, разделяя скалограммы на два класса: нормальная ЭЭГ и ЭЭГ с эпилептическим припадком.

3 Результаты моделирования

3.1 Набор данных и предварительная обработка сигналов

В работе использовалась открытая база данных CHB-MIT Scalp EEG Database, содержащая записи сигналов ЭЭГ пациентов с эпилепсией. Для эксперимента были отобраны следующие файлы формата EDF:

3 файла с зарегистрированными эпилептическими припадками: chb08_02, chb08_05, chb08_13.

1 файл с нормальной активностью мозга без припадков: chb08_03.

Использование нескольких записей с припадками позволило увеличить разнообразие обучающей выборки и повысить устойчивость модели.

Предварительная обработка включала несколько этапов:

Чтение EDF-файлов с использованием библиотеки MNE-Python. Фильтрация и выделение информативных каналов ЭЭГ. Разделение непрерывного сигнала на короткие фрагменты длительностью 5 секунд. Применение непрерывного вейвлет-преобразования с вейвлетом Морле. Нормализация значений и сохранение скалограмм в виде изображений размером 64×64 пикселей. Обработка выполнялась без лишних визуальных элементов, чтобы сохранить только информативные характеристики сигнала.

Изображения сохранены в отдельных каталогах для двух классов. Удалось получить сбалансированную выборку по 50 образцов в каждом классе.

3.2 Формирование обучающей и тестовой выборки

На основе обработанных фрагментов была сформирована сбалансированная выборка:

Класс 0 (нормальная ЭЭГ): 50 изображений

Класс 1 (эпилептический приступ): 50 изображений

Все изображения сохранены в структурированных каталогах, что позволяет автоматически загружать данные при обучении нейронной сети.

3.3 Архитектура сверточной нейронной сети

Была разработана легковесная, но эффективная архитектура CNN, адаптированная под задачу классификации скалограмм ЭЭГ:

Три сверточных слоя (Conv2D) с функцией активации ReLU.

Три слоя подвыборки (MaxPooling2D) для снижения размерности признаков.

Полносвязный слой с регуляризацией Dropout для предотвращения переобучения.

Выходной слой с сигмоидальной активацией для бинарной классификации.

Модель оптимизирована под небольшой объем данных и обеспечивает высокую скорость работы без потери точности.

В процессе обучения наблюдалось стабильное снижение ошибки и повышение точности на обучающей и валидационной выборках, что свидетельствует о корректной работе модели и отсутствии критического переобучения.

3.4 Метрики качества модели

По результатам тестирования получены следующие значения метрик:

Потери на тесте: 0.1000

Общая точность (accuracy): 0.9500

Precision для класса «приступ»: 1.000

Recall для класса «приступ»: 0.917

F1-мера: 0.957

Модель демонстрирует высокую точность классификации и надежное распознавание эпилептических припадков.

3.5 Матрица ошибок

Анализ матрицы ошибок показал, что модель допустила всего одно ошибочное распознавание. Все образцы нормальной ЭЭГ были классифицированы верно. Ошибка возникла только для одного образца с припадком, что подтверждает высокую устойчивость разработанного алгоритма.




Рис.1. Матрица ошибок

ЗАКЛЮЧЕНИЕ

В ходе лабораторной работы была успешно решена задача автоматического выявления эпилептических припадков по сигналам электроэнцефалографии с использованием комбинации вейвлет-преобразования и сверточных нейронных сетей.

Разработанный алгоритм позволяет преобразовать временные ряды ЭЭГ в наглядные частотно-временные представления, а затем классифицировать их с точностью до 95%. Полученные результаты подтверждают, что применение непрерывного вейвлет-преобразования эффективно выявляет скрытые характеристики нестационарных биомедицинских сигналов, а сверточные нейронные сети обеспечивают надежное разделение нормальных и патологических паттернов.

Высокие значения точности, аккуратности и полноты свидетельствуют о практической применимости предложенного подхода для систем вспомогательной диагностики эпилепсии и мониторинга состояния пациентов.