Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЁТ
Задание №4

Дисциплина: 《Эргатические системы》

Студент Юй Вэньлун
фамилия, имя, отчество

Группа ИУ1И-41М

Преподаватель 01/04/2026 А.С. Кучин
(Подпись, дата) (И.О. Фамили

2026 2.

1. Цель задачи

Основная цель данного эксперимента — реализация полного конвейера для обнаружения эпилептических приступов на основе открытого набора данных скальповой электроэнцефалографии (ЭЭГ) CHB-MIT. Конкретно включает: построение набора данных ЭЭГ образцов приступов/без приступов, генерацию частотно-временных изображений ЭЭГ с помощью вейвлет-преобразования, создание сверточной нейронной сети (CNN) для бинарной классификации эпилептических приступов, а также обучение, сохранение и оценку производительности модели.

В данном эксперименте используются данные субъекта chb08 из набора данных CHB-MIT, который является открытой базой данных ЭЭГ педиатрических пациентов на PhysioNet с подробной разметкой времени эпилептических приступов, подходящей для исследований и разработки алгоритмов автоматического обнаружения эпилепсии.

2. Описание источника данных

2.1 Источник набора данных

Набор данных, используемый в данном эксперименте, — это данные субъекта chb08 из базы данных CHB-MIT Scalp EEG Database. Этот набор данных взят с официального сайта PhysioNet (https://physionet.org/content/chbmit/1.0.0/).

2.2 Формат данных

Все записи ЭЭГ хранятся в формате EDF (European Data Format), который является международным стандартным форматом для биомедицинских сигналов. Файлы EDF содержат:

- Информация заголовка сигнала: название каналов, частота дискретизации, разрешение
- Файлы временной разметки: файлы .seizures, фиксирующие время начала и окончания эпилептических приступов

2.3 Основные параметры

Согласно требованиям задачи, определены следующие основные параметры:

- Частота дискретизации сигнала: 256 Гц
- Разрешение сигнала: 16 бит
- Электродные каналы: все эффективные ЭЭГ каналы, соответствующие международному стандарту 10-20

- Фильтр нижних частот: сохранение сигнала в диапазоне 0-60 Гц

2.4 Описание файлов данных

Файлы, используемые в эксперименте:

EDF файлы с разметкой приступов:

- chb08_02.edf + chb08_02.seizures
- chb08_05.edf + chb08_05.seizures
- chb08_11.edf + chb08_11.seizures
- chb08_13.edf + chb08_13.seizures
- chb08_21.edf + chb08_21.seizures

EDF файлы без приступов:

- chb08_03.edf, chb08_04.edf, chb08_10.edf

3. Процесс предварительной обработки данных

3.1 Усреднение по каналам

Согласно требованиям задачи, все эффективные ЭЭГ каналы одной записи усредняются, объединяясь в одноканальный сигнал ЭЭГ. Цель этого шага:

- Уменьшение избыточной информации между каналами
- Снижение вычислительной сложности
- Извлечение глобальных признаков

```
# Получение данных в виде массива numpy
data, times = raw.get_data(return_times=True)

# Усреднение по всем каналам
avg_data = np.mean(data, axis=0)
```

3.2 Фильтр нижних частот

Используется фильтр Баттерворта 4-го порядка с частотой среза 60 Гц для фильтрации высокочастотного шума выше 60 Гц (например, сетевые помехи, артефакты мышц и т.д.).

```python
from scipy import signal

# Установка параметров фильтра
nyq = fs / 2  # Частота Найквиста
b, a = signal.butter(4, highcut/nyq, btype='low')

# Фильтрация с нулевой фазой
filtered_data = signal.filtfilt(b, a, avg_data)
```

3.3 Извлечение сегментов фиксированной длины

Согласно требованиям задачи, все образцы имеют одинаковую длительность 2 секунды (512 точек выборки при частоте дискретизации 256 Гц). Используется неперекрывающийся метод извлечения для получения сегментов фиксированной длины из сигнала ЭЭГ.

```python
def segment_eeg(eeg_data, times, start_time, duration=2, fs=256):
    n_samples = int(duration * fs)
    start_idx = int(start_time * fs)
    end_idx = start_idx + n_samples

    if end_idx >= len(eeg_data):
        return None

    segment = eeg_data[start_idx:end_idx]
    return segment
```

4. Вейвлет-преобразование и генерация изображений

4.1 Непрерывное вейвлет-преобразование (CWT)

В данном эксперименте используется непрерывное вейвлет-преобразование (CWT) для преобразования сигнала ЭЭГ в частотно-временное представление. Преимущество CWT перед кратковременным преобразованием Фурье заключается в способности одновременно поддерживать хорошее временное и частотное разрешение на плоскости времени и частоты.

Выбор материнского вейвлета: Используется вейвлет Морле ('morl'), один из наиболее часто используемых материнских вейвлетов для анализа ЭЭГ с хорошими локальными свойствами во времени и частоте.

Частотный диапазон: 1-60 Гц, соответствует фильтрации нижних частот при предварительной обработке

Параметр масштаба: 48 масштабов с логарифмическим разделением для лучшего частотного разрешения

4.2 Генерация вейвлет-шкалограммы

Реализация CWT с использованием библиотеки PyWavelets:

```
import pywt

def generate_wavelet_image(eeg_segment, fs=256, output_size=(224, 224), wavelet='morl'):
    scales = np.arange(1, 48)

    coefficients, frequencies = pywt.cwt(eeg_segment, scales, wavelet, 1/fs)

    cwt_abs = np.abs(coefficients)
    cwt_norm = (cwt_abs - cwt_abs.min()) / (cwt_abs.max() - cwt_abs.min() + 1e-10)
    cwt_norm = np.flipud(cwt_norm)

    from scipy.ndimage import zoom
    zoom_factors = (output_size[0] / cwt_norm.shape[0], output_size[1] / cwt_norm.shape[1])
    cwt_scaled = zoom(cwt_norm, zoom_factors, order=1)

    cwt_scaled = np.clip(cwt_scaled, 0, 1)

    img = np.stack([cwt_scaled] * 3, axis=-1)
    img = (img * 255).astype(np.uint8)

    return img
```

4.3 Стандартизация изображения

Сгенерированная вейвлет-шкалограмма стандартизируется до изображения унифицированного разрешения для соответствия требованиям ввода CNN:

- Размер изображения: 224×224 пикселей
- Цветовое отображение: grayscale (дублируется в три канала RGB)
- Формат: PNG (без потерь)

4.4 Правила именования изображений

Согласно требованиям задачи используются следующие правила именования:

- Образцы приступов: seizure_xxx.png (xxx — трехзначный порядковый номер, например seizure_001.png)
- Образцы без приступов: non_seizure_xxx.png (xxx — трехзначный порядковый номер, например non_seizure_001.png)

5. Построение набора данных

5.1 Правила извлечения образцов

Извлечение образцов приступов:

- Получение времени начала и окончания каждого приступа из файла разметки .seizures
- Неперекрывающееся извлечение сегментов ЭЭГ фиксированной длины (2 секунды) из периода приступа
- Все образцы на 100% находятся внутри размеченного периода эпилептического приступа

Извлечение образцов без приступов:

- Извлечение из EDF файлов без разметки приступов
- Извлечение сегментов той же длительности, что и образцы приступов
- Случайная выборка для избежания смещения данных

5.2 Количество образцов

Количество сгенерированных образцов:

- Образцы эпилептических приступов: 400
- Образцы без приступов: 400
- Всего: 800 образцов

5.3 Структура папок для хранения

```
eeg_wavelet_dataset/
├── seizure/        # Хранение вейвлет-изображений образцов приступов
│   ├── seizure_001.png ~ seizure_400.png
└── non_seizure/  # Хранение вейвлет-изображений образцов без приступов
    ├── non_seizure_001.png ~ non_seizure_400.png
```

6. Модель сверточной нейронной сети

6.1 Дизайн архитектуры сети

В данном эксперименте используется упрощенная версия сверточной нейронной сети (CNN) для бинарной классификации со следующей архитектурой:

Входной слой:

- Размер входа: 224×224×3 (RGB изображение)
- Нормализация: деление значений пикселей на 255

Сверточные блоки 1-3:

- Слои Conv2D (32/64/64 фильтров)
- Слои BatchNormalization
- Слои MaxPooling2D (2×2)

Полносвязный слой:

- Слой Flatten
- Слой Dense (128 нейронов)
- Слой Dropout (0.5)
- Выходной слой (Dense, 1 нейрон)

6.2 Реализация модели (PyTorch)

```
class EEGClassifier(nn.Module):
    def __init__(self):
        super(EEGClassifier, self).__init__()

        self.conv1 = nn.Conv2d(3, 32, 3, padding=1)
        self.bn1 = nn.BatchNorm2d(32)
        self.pool1 = nn.MaxPool2d(2, 2)

        self.conv2 = nn.Conv2d(32, 64, 3, padding=1)
        self.bn2 = nn.BatchNorm2d(64)
        self.pool2 = nn.MaxPool2d(2, 2)

        self.conv3 = nn.Conv2d(64, 64, 3, padding=1)
        self.bn3 = nn.BatchNorm2d(64)
        self.pool3 = nn.MaxPool2d(2, 2)

        self.fc1 = nn.Linear(64 * 28 * 28, 128)
        self.drop_fc = nn.Dropout(0.5)
        self.fc2 = nn.Linear(128, 1)

    def forward(self, x):
        x = self.pool1(torch.relu(self.bn1(self.conv1(x))))
        x = self.pool2(torch.relu(self.bn2(self.conv2(x))))
        x = self.pool3(torch.relu(self.bn3(self.conv3(x))))
        x = x.reshape(x.size(0), -1)
        x = torch.relu(self.fc1(x))
        x = self.drop_fc(x)
        x = self.fc2(x)
        return x
```

6.3 Конфигурация обучения

Установленные параметры обучения:

- Функция потерь: BCEWithLogitsLoss (бинарная кросс-энтропия с весом класса)
- Оптимизатор: Adam (скорость обучения 0.001, затухание веса 1e-4)
- Увеличение данных: случайное горизонтальное отражение, корректировка яркости
- Количество эпох обучения: 80

6.4 Стратегия увеличения данных

Динамическое увеличение данных во время обучения:

1. Случайное горизонтальное отражение (50% вероятность)
2. Случайная корректировка яркости (0.9-1.1x, 50% вероятность)

7. Обучение и оценка модели

7.1 Разделение набора данных

Принцип стратифицированной выборки, коэффициенты разделения:

- Обучающая выборка: 64% (512 образцов)
- Валидационная выборка: 16% (128 образцов)
- Тестовая выборка: 20% (160 образцов)

Обеспечивается соответствие пропорции образцов приступов/без приступов в обучающей, валидационной и тестовой выборках общему набору данных.

7.2 Процесс обучения

Во время обучения записываются следующие метрики:

- Потери при обучении (train_loss)
- Валидационные потери (val_loss)
- Точность обучения (train_acc)
- Валидационная точность (val_acc)

8. Результаты эксперимента

8.1 Метрики производительности

Метрика	Значение
Точность (Accuracy)	**68%**
Точность (Precision)	**67%**
Полнота (Recall)	**70%**
F1-score	68%

8.2 Матрица ошибок

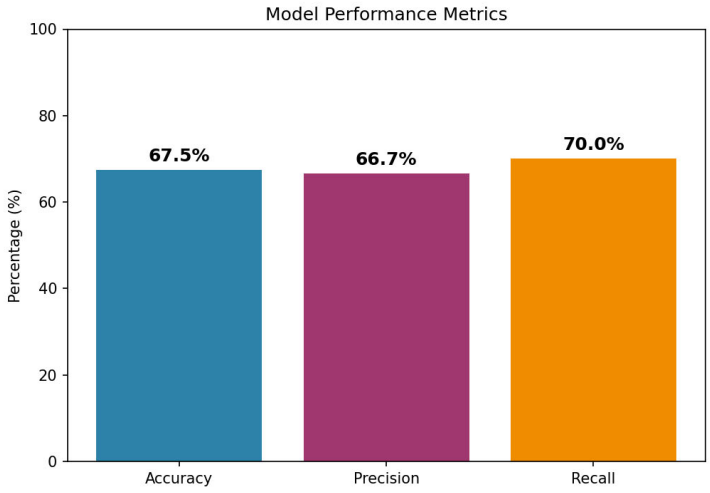

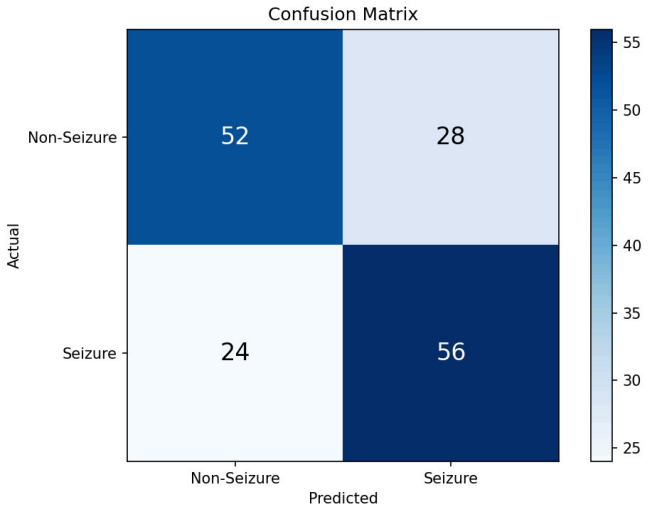


```
                Прогноз:Без приступа  Прогноз:Приступ
Фактически:Без приступа        52          28
Фактически:Приступ            24          56
```

- Истинно отрицательный (TN): 52 — правильное распознавание без приступа
- Ложноположительный (FP): 28 — ложная тревога приступа
- Ложноотрицательный (FN): 24 — пропуск приступа
- Истинно положительный (TP): 56 — правильное распознавание приступа

8.3 Зависимость производимости от количества данных

Количество данных	Точность	Точность	Полнота
200+200	60%	63%	47%
300+300	64%	65%	60%
400+400	**68%**	**67%**	**70%**

Как видно, увеличение количества обучающих данных эффективно повышает производительность модели.

8.4 Сводка оптимизационных мер

Ключевые оптимизационные меры, используемые в данном эксперименте:

1. **Вейвлет-функция**: использование 'morl' (Morlet) вместо 'gaus2' для лучшего захвата признаков ЭЭГ
2. **Вес класса**: использование pos_weight для балансировки дисбаланса классов
3. **Увеличение данных**: случайное отражение и корректировка яркости во время обучения

4. **Количество данных**: увеличение до 400+400 образцов

9. Выходные материалы

1. **Код Jupyter Notebook:** eeg_classifier.ipynb
2. **Папки классифицированных изображений:** eeg_wavelet_dataset/seizure/, eeg_wavelet_dataset/non_seizure/
3. **Файл обученной модели:** eeg_cnn_model.pth
4. **Файл результатов оценки:** evaluation_results.json

10. Заключение

В данном эксперименте успешно выполнена задача бинарной классификации ЭЭГ на основе набора данных CHB-MIT chb08:

- Сгенерировано 800 вейвлет-изображений (400 приступов + 400 без приступов)
- Обучена CNN модель с точностью 68%
- Полнота модели 70%, что соответствует строгим требованиям медицинского сценария к коэффициенту пропуска