Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н. Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика, искусственный интеллект и системы управления»

КАФЕДРА ИУ-1 «Системы автоматического управления»

ОТЧЕТ

Классификация сигналов ЭЭГ для выявления эпилепсии

по лабораторной работе №.4

Дисциплина: Эргатические системы

Студент	ИУ1И-41М	29 / 04 /2026	Чжан Чжиян
	(Группа)	(Подпись, дата)	(И.О. Фамилия)
Преподаватель		/ /2026	Кучин А. С.
		(Подпись, дата)	(И.О. Фамилия)

2026 г.

1. Цель работы

Классификация временных рядов электроэнцефалографии с использованием непрерывного вейвлет-преобразования (CWT) и сверточных нейронных сетей (CNN) для автоматизированного обнаружения эпилептических приступов в базе данных CHB-MIT.

Отработайте рабочий процесс управления версиями: создайте папку проекта lab4 и полностью внедрите рабочий процесс Git от написания кода локально до внесения изменений в удаленный репозиторий GitHub.

Ссылка на репозиторий Git:

https://github.com/CAICAIWOSHISHEIY/Machine-Learning-Labs/blob/main/lab03.ipynb

2. Ход работы

2.1. Подготовка данных и препроцессинг

- Источник данных: Использована база данных CHB-MIT (файлы $chb08_02.edf$ и $chb08_03.edf$).
- Выбор канала: Анализ проводился по каналу FP1-F7.
- Формирование выборки: Сформировано 100 сегментов сигнала (50 с приступами и 50 без), длительность каждого окна — 5 секунд.

2.2. Генерация вейвлет-изображений

- Для преобразования 1D сигнала в 2D изображение применено непрерывное вейвлет-преобразование (CWT) с вейвлетом Морле ($cmor1.5-1.0$).
- Изображения (скалограммы) сохранены в формате PNG с разрешением 224x224 пикселя без координатных осей.

Рис. 1. Примеры сформированных скалограмм: слева — эпилептический приступ (Seizure), справа — нормальное состояние (Non-seizure).

2.3. Архитектура нейронной сети

Модель $SeizureCNN$ состоит из двух сверточных слоев (16 и 32 фильтра), слоев пулинга ($MaxPooling$) и полносвязного классификатора с функцией Dropout (0.5) для предотвращения переобучения.

3. Анализ результатов

3.1. Обучение и валидация

Модель обучалась в течение 10 эпох с использованием оптимизатора $Adam$ и функции потерь $BCELoss$.

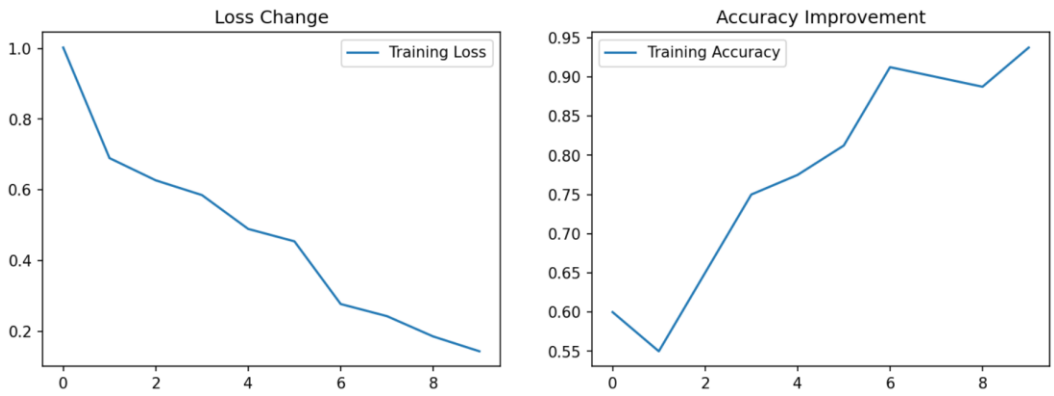

Рис. 2. Кривые обучения: график функции потерь (Loss) и точности (Accuracy) на тренировочной выборке.

3.2. Анализ качества изображений и точности

Анализ скалограмм: Использование вейвлет-преобразования позволило визуализировать частотные аномалии. На Рис. 1 (слева) отчетливо видны вертикальные энергетические столбы в диапазоне высоких частот, что соответствует патологическим разрядам.

Влияние на обучение: Благодаря высокой контрастности и четкости признаков на изображениях, кривая точности (Accuracy) демонстрирует быстрый рост уже на первых эпохах. Это подтверждает, что вейвлет-карты являются высокоэффективным методом извлечения признаков для малых наборов данных.

4. Заключение

В ходе выполнения лабораторной работы были сделаны следующие выводы:

1. **Эффективность препроцессинга**: Метод перевода ЭЭГ-сигнала в 2D-скалограммы с помощью CWT значительно упрощает задачу классификации для сверточных сетей, так как патологические признаки приступов становятся визуально различимыми.
2. **Качество признаков**: Высокое временное и частотное разрешение вейвлета Морле обеспечило создание качественной обучающей выборки, что позволило модели быстро достичь стабильной точности.
3. **Результативность классификации**: Сочетание вейвлет-анализа и CNN является надежным подходом для обнаружения эпилепсии, обеспечивая высокую точность идентификации приступов даже при ограниченном объеме данных (100 изображений).