



**Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)**

ФАКУЛЬТЕТ

ИУ «Информатика и системы управления»

КАФЕДРА

ИУ-1 «Системы автоматического управления»

ОТЧЕТ

по лабораторной работе №5

по дисциплине

«Эргатические системы»

Исследование когнитивных характеристик мозга по данным ЭЭГ

Выполнил: Ван Шо

Группа: ИУ1И-41М

Преподаватель: Д. А. Андриков

А. С. Кучин

Работа выполнена: 12/05/2026

Отчет сдан: 12/05/2026

Оценка:

1 Цель работы

Исследовать временные и частотные характеристики сигналов электроэнцефалографии (ЭЭГ) при двигательных образах (представление движения левой и правой руки). Применить непрерывное вейвлет-преобразование для построения частотно-временных диаграмм и визуализации скрытых признаков ЭЭГ.

Разработать и обучить одномерную сверточную нейронную сеть (1D-CNN) для автоматической классификации двух классов двигательных образов. Решить проблемы переобучения и дисбаланса классов с помощью регуляризации и взвешивания классов. Оценить качество классификации по точности, матрице ошибок и кривым обучения.

Ссылка на Git-репозиторий:

[Ergatic-systems_uylu-41m_WangShuo/lab5.ipynb at main · Ws3282/Ergatic-systems_uylu-41m_WangShuo](https://github.com/Ergatic-systems_uylu-41m_WangShuo/lab5.ipynb)

2 Теоретическая часть

2.1 ЭЭГ при двигательных образах

Двигательные образы (imaginary movement) вызывают специфические изменения в ритмах μ (8–13 Гц) и β (13–30 Гц) в сенсомоторной коре головного мозга. Эти изменения слабо выражены во временной области, но хорошо обнаруживаются в частотно-временном представлении.

2.2 Непрерывное вейвлет-преобразование (CWT)

Непрерывное вейвлет-преобразование является одним из наиболее эффективных методов анализа нестационарных сигналов, поскольку обеспечивает многократное разрешение во времени и частоте, в отличие от кратковременного преобразования Фурье с фиксированным размером окна. При использовании вейвлета Морле в качестве базисной функции преобразование

позволяет строить скалограммы — двумерные частотно-временные диаграммы, на которых отображается распределение энергии сигнала в зависимости от времени и частоты. Такой подход позволяет точно локализовать вспышки активности, проследить динамику спектральных компонент и выявить различия между сигналами, соответствующими разным двигательным образам, что делает вейвлет-анализ незаменимым инструментом при обработке ЭЭГ.

Для выделения информативных частот используется фильтр Баттерворта 8–30 Гц. Это подавляет шум сети 50 Гц, низкочастотные дрейфы и высокочастотные артефакты.

2.3 Одномерная сверточная нейронная сеть для классификации ЭЭГ

Одномерная сверточная нейронная сеть (1D-CNN) представляет собой эффективный инструмент для обработки временных рядов, поскольку способна автоматически выделять локальные пространственно-временные признаки без ручного формирования признакового пространства. Архитектура 1D-CNN включает последовательные слои свертки и подвыборки, а также полносвязные слои для финальной классификации. Для предотвращения переобучения в структуру сети интегрируются слои Dropout, L2-регуляризация весов и механизм ранней остановки по точности на валидационной выборке. При наличии дисбаланса классов используется автоматический расчет весов классов, что обеспечивает сбалансированное распознавание обеих категорий двигательных образов и повышает общую надежность классификатора.

3 Результаты моделирования

3.1 Загрузка и анализ исходных данных

В ходе работы были загружены обучающая и тестовая выборки ЭЭГ-сигналов, зарегистрированных при представлении движения левой и правой руки, после чего был выполнен анализ размерностей данных и распределения классов. Было установлено, что каждый сигнал имеет длину 3000 отсчетов при частоте дискретизации 250 Гц, а общее количество образцов в обучающей и тестовой выборках достаточно для обучения и объективной оценки классификатора. Анализ распределения меток показал возможный небольшой дисбаланс классов, который был учтен при дальнейшем обучении модели с помощью взвешивания классов.

3.2 Вейвлет-частотные диаграммы ЭЭГ-сигналов

С помощью непрерывного вейвлет-преобразования были построены скалограммы для образцов сигналов каждой категории, что позволило визуально оценить различия в частотно-временной структуре ЭЭГ при двигательных образах левой и правой руки. На диаграммах отчетливо прослеживаются зоны повышенной энергии в диапазоне 8–30 Гц, соответствующие активации сенсомоторной коры, причем пространственное распределение и интенсивность данных зон заметно отличаются между двумя классами, что подтверждает целесообразность использования вейвлет-анализа для выявления скрытых признаков сигналов.




Рис.1. Вейвлет-ЧД ЭЭГ: левая кулак




Рис.2. Вейвлет-ЧД ЭЭГ: правая кулак

3.3 Обучение 1D-CNN модели

Предобработка и формирование выборок:

После визуального анализа была выполнена полосовая фильтрация сигналов в диапазоне 8–30 Гц с последующей стандартизацией значений. Фильтрация обеспечила подавление помех и артефактов, а стандартизация привела сигналы к единому масштабу, что существенно улучшило условия для обучения нейронной сети. Затем исходные одномерные сигналы были преобразованы в формат, подходящий для входа 1D-CNN, с соответствующим изменением размерности тензоров, а метки классов преобразованы в категориальный вид для использования в функции потерь с кросс-энтропией.

На этапе обучения была сформирована архитектура одномерной сверточной нейронной сети, включающей три сверточных слоя с последовательным наращиванием числа фильтров, слои подвыборки и регуляризации Dropout, а также полносвязный слой с L2-регуляризацией. В процессе обучения применялись оптимизатор Adam с заданной скоростью обучения, механизм ранней остановки для сохранения лучших весов и автоматически рассчитанные веса классов для компенсации их дисбаланса. В результате обучения модель достигла стабильной работы без выраженного переобучения, что подтверждается синхронным изменением точности и потерь на обучающей и тестовой выборках.

3.4 Оценка качества классификации

По завершении обучения была выполнена комплексная оценка обученной модели на независимой тестовой выборке, в ходе которой были рассчитаны общая точность классификации, построена матрица ошибок и проанализированы кривые обучения. В результате эксперимента была получена общая точность классификации 0,8625, что свидетельствует о высокой эффективности разработанного подхода. Матрица ошибок демонстрирует сбалансированное распознавание обоих классов без существенного смещения в сторону одного из них, а общая точность классификации находится на высоком уровне, характерном для задач классификации двигательных образов по ЭЭГ. Полученные значения метрик соответствуют современным требованиям к системам классификации двигательных образов по сигналам ЭЭГ и подтверждают правильность выбора архитектуры сети и методов предобработки.




Рис.3. Матрица ошибок

ЗАКЛЮЧЕНИЕ

В ходе лабораторной работы выполнено комплексное исследование сигналов электроэнцефалограммы при двигательных образах с использованием методов частотно-временного анализа и глубокого обучения.

Были изучены особенности проявления моторной активности в спектральных характеристиках ЭЭГ, реализовано непрерывное вейвлет-преобразование для построения скалограмм и визуализации скрытых признаков сигналов, а также разработана и обучена одномерная сверточная нейронная сеть для автоматической классификации двух классов двигательных образов. Применение полосовой фильтрации, стандартизации, методов регуляризации и балансировки классов позволило стабилизировать процесс обучения, устранить переобучение и обеспечить сбалансированное распознавание классов.

В результате эксперимента достигнута итоговая точность классификации 0,8625 на тестовой выборке, что подтверждает высокую эффективность используемого подхода.