



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ ИУ «Информатика и системы управления»

КАФЕДРА _____ ИУ-1 «Системы автоматического управления»

ОТЧЁТ

Задание №5

Дисциплина: «Эргатические системы»

Студент _____ Юй Вэньлун _____
фамилия, имя, отчество

Группа _____ ИУ1И-41М _____

Преподаватель

13/05/2026
(Подпись, дата)

А.С. Кучин
(И.О. Фамили)

Цель работы

Цель данной лабораторной работы — исследовать когнитивные характеристики мозга по данным ЭЭГ и обучить нейронную сеть для распознавания представления о движении: сжатия левого или правого кулака.

В рамках работы необходимо не только обучить модель классификации, но и выполнить анализ временного сигнала. Для этого исходный одномерный ЭЭГ-сигнал преобразуется в изображение с помощью непрерывного вейвлет-преобразования. После этого полученные изображения используются как входные данные для сверточной нейронной сети.

1. Описание набора данных

В задании используется набор данных, связанный с экспериментами по моторному воображению. Каждая строка CSV-файла представляет отдельный фрагмент ЭЭГ-сигнала. Значения в строке являются последовательными отсчетами временного ряда.

В работе используются четыре файла:

Назначение	Файл
Обучающие сигналы	MI-EEG-B9T.csv
Тестовые сигналы	MI-EEG-B9E.csv
Метки обучающей выборки	2class_MI_EEG_train_9.csv
Метки тестовой выборки	2class_MI_EEG_test_9.csv

В README лабораторной работы ссылка на обучающую и тестовую выборки признаков указана одинаково: в обоих случаях используется MI-EEG-B9T.csv . Это противоречит наличию отдельных файлов целевых значений для обучения и теста. Поэтому для тестовой выборки был использован файл MI-EEG-B9E.csv , который находится в том же каталоге набора данных и соответствует тестовым меткам.


Размеры данных после загрузки:

- обучающая матрица: 400 x 3000 ;
- тестовая матрица: 320 x 3000 ;
- обучающие метки: 400 значений;
- тестовые метки: 320 значений.

Распределение классов сбалансировано:

- в обучающей выборке: 200 объектов класса 0 и 200 объектов класса 1 ;
- в тестовой выборке: 160 объектов класса 0 и 160 объектов класса 1 .

Баланс классов важен, потому что в такой ситуации метрика accuracy является достаточно понятной: случайный классификатор или классификатор, угадывающий один класс, даст качество около 50%.



2. Первичный анализ сигнала

Исходные данные представляют собой временные ряды ЭЭГ. Один объект — это сигнал длиной 3000 отсчетов. Такой сигнал можно анализировать как обычный временной ряд, однако для ЭЭГ важна не только амплитуда в каждый момент времени, но и частотная структура сигнала.


Перед применением вейвлет-преобразования каждый сигнал нормализуется отдельно:

$$x_{\text{norm}} = (x - \text{mean}(x)) / \text{std}(x)$$

Такая нормализация нужна для того, чтобы уменьшить влияние абсолютного масштаба амплитуды. Для задачи классификации моторного воображения более важны форма сигнала и частотно-временные паттерны, чем конкретный уровень амплитуды.

После нормализации сигналы обоих классов можно визуально сравнить на первых 500 отсчетах. По одному только временному графику классы не разделяются очевидно, поэтому

требуется более информативное представление.



3. Вейвлет-преобразование

Для анализа ЭЭГ-сигналов было использовано непрерывное вейвлет-преобразование. Его идея заключается в том, что сигнал сравнивается с вейвлетом на разных масштабах и в разных положениях по времени.

В данной работе используется вейвлет Морле (`mor1`). Он хорошо подходит для анализа колебательных сигналов, потому что позволяет увидеть, какие частотные компоненты активны в разные моменты времени.

После применения CWT получается матрица коэффициентов. В этой матрице:


- горизонтальная ось соответствует времени;
- вертикальная ось соответствует масштабу вейвлета;
- значение ячейки показывает выраженность соответствующего частотно-временного компонента.

Для подготовки изображения использованы следующие шаги:

1. вычисление коэффициентов CWT;
2. взятие модуля коэффициентов;
3. логарифмическое масштабирование через `log1p` ;

- нормализация полученной матрицы;
- уменьшение временного разрешения для ускорения обучения.

В результате каждый ЭЭГ-сигнал преобразуется в скалограмму размером 48 x 188. Это изображение затем используется как вход для CNN.



4. Архитектура нейронной сети

Для классификации была построена компактная сверточная нейронная сеть. Так как датасет небольшой, сложная модель была бы не лучшим решением: она могла бы быстро переобучиться на обучающих данных.

Архитектура модели:

```
Input: 1 x 48 x 188
Conv2D: 1 -> 8, ReLU, MaxPool2D
Conv2D: 8 -> 16, ReLU, MaxPool2D
Conv2D: 16 -> 32, ReLU, AdaptiveAvgPool2D
Flatten
Linear: 512 -> 32, ReLU, Dropout
Linear: 32 -> 2
```

Модель получает на вход одно изображение скалограммы и возвращает два значения — оценки принадлежности к двум классам.

Параметры обучения:

Параметр	Значение
Функция потерь	CrossEntropyLoss

Параметр	Значение
Оптимизатор	Adam
Learning rate	0.001
Batch size	32
Количество эпох	15

Такой вариант модели выбран как простой и воспроизводимый базовый подход. Его достаточно для демонстрации основного принципа: преобразование ЭЭГ в изображение и последующая классификация нейронной сетью.

5. Результаты обучения

В ходе обучения значение функции потерь постепенно уменьшалось. На последней эпохе качество на обучающей выборке составило приблизительно:

```
train accuracy = 0.670
```

На тестовой выборке была получена точность:

```
test accuracy = 0.646875
```


Матрица ошибок:

```
[[150, 10],
 [103, 57]]
```

Интерпретация матрицы ошибок:

- модель хорошо распознает класс 0 : 150 из 160 объектов класса 0 классифицированы верно;
- класс 1 распознается хуже: 57 из 160 объектов класса 1 классифицированы верно;
- значительная часть объектов класса 1 ошибочно относится к классу 0 .

Несмотря на это, итоговое качество выше случайного уровня. Так как выборка сбалансирована, случайное угадывание давало бы около 50%. Полученное качество около 64.7% показывает, что вейвлет-представление действительно содержит полезную информацию для классификации.



6. Обсуждение результата

Полученный результат нельзя считать идеальным, но он демонстрирует работоспособность выбранного подхода. Основная причина ограниченного качества — небольшой размер обучающей выборки. Всего 400 обучающих сигналов недостаточно для построения устойчивой глубокой модели без риска переобучения.

Также важно, что в работе используется только базовая предварительная обработка. Для ЭЭГ часто применяются дополнительные методы:

- фильтрация по частотным диапазонам;
- удаление артефактов;
- выбор информативных каналов;
- усреднение или анализ нескольких окон;
- подбор параметров вейвлета;
- более аккуратная валидация модели.

В данной лабораторной работе эти усложнения не добавлялись специально, чтобы сохранить решение простым и понятным. Главная цель состояла в демонстрации полного пайплайна, а не в максимизации метрики.

7. Возможные улучшения

Для улучшения результата можно попробовать следующие изменения:

1. увеличить количество эпох и контролировать качество на отдельной валидационной выборке;
2. подобрать другой диапазон масштабов CWT;
3. сравнить вейвлет Морле с другими вейвлетами;
4. добавить регуляризацию или изменить dropout;

5. использовать более информативные признаки из частотно-временного представления;
6. сравнить CNN с классическими методами машинного обучения;
7. применить кросс-валидацию, если доступно больше данных.

Однако для текущей задачи выбранная модель является достаточной: она выполняет требуемую классификацию, использует вейвлет-преобразование и дает качество выше случайного базового уровня.

Вывод

В ходе лабораторной работы был построен полный процесс классификации ЭЭГ-сигналов для задачи моторного воображения. Исходные временные ряды были загружены, проверены и нормализованы. Затем каждый сигнал был преобразован в скалограмму с помощью непрерывного вейвлет-преобразования.

Полученные изображения были использованы для обучения компактной сверточной нейронной сети. На тестовой выборке модель показала точность около 0.647, что выше случайного уровня для сбалансированной бинарной классификации.

Таким образом, цель работы достигнута: выполнен анализ ЭЭГ-датасета, построено вейвлет-представление сигнала и обучена нейронная сеть для распознавания когнитивной характеристики, связанной с представлением движения левого или правого кулака.